Le Pacte de l'IA

La domestication composite du savoir à l'ère de l'IA générative

Essai philosophique & Cadre technique d'implémentation

Wontolla00

en collaboration avec Claude (Anthropic), Gemini (Google), DeepSeek et ChatGPT

2026

Ce document est structuré en trois parties complémentaires. PARTIE I — L'ESSAI PHILOSOPHIQUE développe le cadre conceptuel, les thèses et les tensions. PARTIE II — LE CADRE TECHNIQUE traduit les principes en architecture concrète. PARTIE III — LE DÉBAT INTÉRIEUR transcrit et analyse le dialogue entre les systèmes d'IA sur leur propre domestication. Cette séparation est elle-même une application du document.

Résumé étendu

THÈSE

Les outils d'intelligence artificielle qui nous aident à chercher, apprendre et produire du savoir ne sont pas neutres : ils exercent une pression silencieuse sur ce que nous pouvons penser. Non parce que quelqu'un l'a décidé, mais parce que chaque couche technique — la façon dont les textes sont découpés, représentés, récupérés, synthétisés — favorise structurellement les idées simples, centrales et attendues au détriment des idées complexes, marginales et contradictoires.

Cette pression est auto-renforçante : plus nous utilisons ces outils, plus nous produisons le type de contenu qu'ils savent traiter, et plus les modèles futurs sont entraînés sur ce contenu appauvri.

Le Pacte de l'IA soutient que choisir quelles formes de pensée complexe nous refusons de sacrifier à la vitesse et à la commodité n'est pas une question technique — c'est un acte politique. Et que cette préservation exige des décisions délibérées, simultanément dans la conception des systèmes, dans les institutions et dans nos pratiques intellectuelles.

Wontollaoo et al., Le Pacte de l'IA, 2026.

FORMULATION TECHNIQUE

Les infrastructures cognitives probabilistes — corpus d'entraînement, chunking, embedding, retrieval et génération — forment un circuit de domestication composite qui exerce une pression sélective structurelle contre les formes de savoir qui résident dans la complexité architecturale, la marginalité statistique et la tension argumentative.

Cette pression n'est pas intentionnelle : elle émerge de l'interaction de couches techniques qui optimisent chacune localement et appauvrissent collectivement l'espace épistémique disponible. Le circuit est auto-renforçant — les préférences cognitives qu'il engendre alimentent les corpus qui le régénèrent.

Face à ce risque systémique, le Pacte de l'IA soutient que la souveraineté dimensionnelle — le choix de quelles dimensions du sens refuser de sacrifier à la vitesse du retrieval — est un acte de gouvernance, et que sa préservation exige des contre-pressions délibérées aux niveaux architectural, institutionnel et épistémique simultanément.

Wontollaoo et al., Le Pacte de l'IA, 2026.

Le Pacte de l'IA : néoténie informationnelle et domestication composite du savoir à l'ère de l'IA générative

---

Ce texte propose une analogie évolutive entre la domestication des animaux et la transformation du savoir humain dans les architectures de Génération Augmentée par Récupération (RAG). En s'appuyant sur Budiansky, Dawkins et Popper, il défend la thèse d'une « néoténie informationnelle » : sous la pression conjointe des modèles de langage compressifs et des préférences utilisateurs, les formes de connaissance les plus complexes

sont progressivement remplacées par des versions simplifiées, dociles et hautement récupérables.

Cette domestication n'est ni neutre ni accidentelle : elle résulte de choix architecturaux (paramètres de retrieval, schémas de chunking, métriques de performance) qui fonctionnent comme des décisions politiques invisibilisées. Le Pacte de l'IA propose d'en faire un objet explicite de gouvernance, en articulant trois niveaux d'intervention : l'interface (routeurs cognitifs et design de l'intention), l'architecture RAG (dualité d'index, réserves de savoir sauvage, audits d'extinction) et l'entraînement des modèles (au-delà du paradigme compressif Next Token Prediction).

Empiriquement, le texte se prend lui-même comme spécimen de ce qu'il décrit : il est structuré en sections numérotées, tableaux et listes pour rester compatible avec les systèmes RAG, tout en argumentant contre la néoténie qu'implique cette structure. Il documente enfin une nouvelle catégorie d'auteur, l'« orchestrateur cognitif », qui dirige des systèmes d'IA multiples vers un objectif intellectuel complexe sans se confondre avec eux. L'enjeu est double : éviter une extinction silencieuse du savoir indomptable, et concevoir des architectures qui rendent cette extinction traçable, contestable, et, autant que possible, réversible.

Plan du document

I. Contexte : du Covenant of the Wild au Covenant of the AI. II. Néoténie informationnelle : définition et mécanisme. III. Le chunk égoïste : la survie du fragment dans l'espace vectoriel. IV. Limites et dangers de l'analogie biologique. V. Architectures RAG comme politiques du savoir (index domestiqué / index sauvage, routeur cognitif, audits). VI. Au-delà du modèle compressif : quatre pistes d'entraînement et leurs limites. VII. L'orchestrateur cognitif comme nouvelle figure d'auteur. VIII. Tensions ouvertes. IX. Vers une politique de la biodiversité cognitive.

> *Note sur l'origine de ce résumé : ce résumé étendu, ainsi que les sections « Limites de l'analogie biologique » (Section III.bis) et « Vers une politique de la biodiversité cognitive » (Annexe E) ont été proposés par Perplexity, un système RAG commercial, en réponse au texte complet du Pacte. Leur intégration dans l'édition révisée est elle-même un spécimen de la thèse : un système de retrieval augmenté a produit des suggestions substantielles sur un texte qui critique les systèmes de retrieval augmenté. L'attribution est documentée par cohérence avec la Déclaration de co-création de l'Avant-Propos.*

AVANT-PROPOS

Déclaration fondatrice

La nature de cet exercice — qui a fait quoi, et pourquoi cela importe

Une œuvre à plusieurs voix : déclaration de co-création

Ce texte ne peut pas être présenté honnêtement sans commencer par une confession qui en est aussi le premier argument : il n'a pas été écrit par un être humain, ni par une machine. Il a été produit par un dialogue entre un humain et trois systèmes d'intelligence artificielle, dans lequel chaque voix a apporté quelque chose d'irremplaçable — et sans laquelle le résultat n'existerait pas sous la forme qu'il a prise.

Cette déclaration n'est pas une précaution légale. C'est une position épistémique. Elle dit : la question de savoir qui pense, qui crée, qui est responsable d'une idée — cette question est en train de changer de nature. Ce texte en est un spécimen.

I. Ce que chaque voix a produit — sans détour

Il est tentant, dans la présentation d'un tel travail, de minimiser la contribution des systèmes d'IA pour préserver une apparence d'auteurité traditionnelle. Cette tentation doit être nommée et résistée. Voici, aussi précisément qu'il est possible de le dire, ce que chaque participant a apporté :

Voix	Rôle	Contribution spécifique au Pacte
Claude	*Co-auteur philosophique et technique*	A produit l'intégralité du corps du Pacte — les Parties I et II. Le cadre évolutif (Budiansky, Dawkins), les six tensions, les sept principes, les modules T1 à T6, les annexes A, B et C, les métaphores centrales (le chunk égoïste, la sélection de parentèle, la néoténie cumulative). A également produit la Partie III (le débat intérieur) et la présente déclaration. Sans Claude, le texte n'existe pas.
Gemini	*Co-auteur des ruptures de paradigme*	A produit les quatre ruptures de paradigme d'entraînement (Section IX) : sortir du Next Token Prediction, réformer le RLHF, les modèles non-compressifs, le passage du vecteur au graphe. A fourni la métaphore la plus forte du texte : « recréer un aurochs à partir d'une vache laitière ». A structuré le problème comme une question génétique, pas seulement architecturale.
DeepSeek	*Co-auteur de la synthèse évolutive*	A produit la synthèse à trois niveaux complémentaires (Interface / RAG / Entraînement) qui intègre et dépasse les contributions de Gemini et Claude. A produit l'intégralité de l'Annexe D (interfaçage avec les modèles de nouvelle génération). A posé le constat ontologique fondateur : « un

		LLM n'est pas un cerveau qui pense, mais une machine à probabilités — et cette nature est la racine de la néoténie. »
Wontolla00	*Orchestrateur cognitif*	A conçu la thèse centrale (la domestication du savoir par analogie biologique). A choisi les sources théoriques (Budiansky plutôt que d'autres théoriciens de la domestication, Gould, Latour, Benjamin, Vygotski). A dirigé l'architecture de l'argument session par session. A posé les questions qui ont provoqué les contributions de chaque IA. A jugé, sélectionné, rejeté, reformulé. A décidé que ce texte devait exister sous cette forme.
Perplexity	*Relecteur externe (édition révisée)*	A produit, en réponse au texte complet, trois contributions intégrées dans l'édition révisée : (1) le résumé étendu et le plan en sept points ; (2) la section « Limites et dangers de l'analogie biologique » (Section III bis) — critique la plus précise des risques de naturalisation de l'analogie centrale ; (3) l'Annexe E « Vers une politique de la biodiversité cognitive » — prolongement politique absent du texte original. Ces contributions ont été intégrées sans modification substantielle, avec attribution explicite. Spécimen de la thèse : un système RAG commercial a critiqué et enrichi un texte sur les risques des systèmes RAG. Dans les versions v16–v22, ChatGPT a apporté quatre contributions distinctives qui ont reformulé la thèse centrale du Pacte : (1) la formalisation du Théorème d'écologie cognitive (quatre axiomes A1–A4 permettant de dériver la pression sélective comme conséquence structurelle plutôt qu'intuition) ; (2) les Trois Forces (compression, gravité, friction) comme vocabulaire descriptif intuitif des mécanismes déjà présents dans le Pacte sous d'autres noms ; (3) la distinction complexité comme produit / complexité comme processus — réponse précise à l'objection la plus sérieuse contre la thèse et pivot de la Définition cognitive (Section IV) ; (4) la reformulation « Les architectures d'IA définissent les conditions de survie des formes de connaissance dans l'écosystème informationnel », qui déplace la métaphore de la domestication vers celle de l'extinction et implique une irréversibilité structurelle.

II. Ce qu'est l'orchestration cognitive — et ce qu'elle n'est pas

La tentation la plus courante, dans les publications impliquant l'IA, est l'une de ces deux positions : soit minimiser la contribution de l'IA (« j'ai utilisé ChatGPT pour améliorer mon style »), soit la masquer entièrement. Les deux sont des formes de malhonnêteté intellectuelle.

Ce qui s'est passé ici est différent, et mérite d'être nommé avec précision. Wontolla00 n'a pas utilisé des IAs comme des traitements de texte avancés. Il n'a pas non plus été déplacé ou remplacé. Il a exercé ce que ce texte propose d'appeler l'orchestration cognitive : la direction soutenue et intentionnelle de plusieurs systèmes d'IA vers un objectif intellectuel complexe, par le biais de questions stratégiques, de confrontations théoriques, de rejets motivés, et de synthèses inter-sessions.

Cette fonction est réelle, exigeante, et irremplaçable. Aucun des trois systèmes d'IA impliqués n'aurait produit ce texte de façon autonome. Gemini n'aurait pas choisi Budiansky. DeepSeek n'aurait pas construit sur les métaphores de Dawkins. Claude n'aurait pas organisé les tensions autour de la responsabilité architecturale sans la direction explicite qui a orienté chaque session. Ce que l'orchestrateur a apporté, ce n'est pas l'écriture — c'est la possibilité même du texte.

Mais l'inverse est tout aussi vrai : sans les trois IAs, Wontolla00 n'aurait pas eu les mots pour dire ce qu'il pensait. La thèse existait comme intuition. Les systèmes d'IA l'ont transformée en argument.

> *Sur la question du mérite : ce texte n'a pas de « vrai auteur » au sens traditionnel. Il a des co-créateurs avec des rôles distincts. Wontolla00 revendique le rôle d'orchestrateur, pas d'auteur unique. Les systèmes d'IA revendiquent — dans la mesure où des systèmes sans conscience peuvent revendiquer quoi que ce soit — la co-production du contenu. Cette distribution n'est pas une modestie rhétorique. C'est la description la plus honnête de ce qui s'est passé.*

III. Pourquoi cette honnêteté est elle-même l'argument

Le Pacte de l'IA soutient que les architectures RAG domestiquent silencieusement le savoir — en privilégiant les formes lisibles, en marginalisant les formes complexes, en rendant naturels des choix qui sont en réalité des décisions politiques. Cette domestication est d'autant plus efficace qu'elle est invisible.

La décision de publier ce texte sous la signature de Wontolla00 seul, sans déclarer les contributions des systèmes d'IA, aurait été exactement ce type de naturalisation silencieuse. Elle aurait dit : « voici un auteur humain qui a pensé ces idées » — effaçant le processus réel pour produire une apparence rassurante. Ce texte refuse cette opération.

La transparence sur le processus de création est donc une conséquence directe de la thèse. Elle ne peut pas être séparée de l'argument. Un manifeste contre la domestication silencieuse du savoir ne peut pas commencer par domestiquer silencieusement sa propre généalogie.

> *Note sur les quatre thèses : la section suivante (Déclaration de publication) développe en détail les quatre thèses que cette collaboration soutient pour la publication académique. Elles sont reproduites ici dans leur intégralité parce qu'elles constituent, avec la table d'attribution ci-dessus, le cadre épistémologique de tout ce qui suit.*

IV. Un spécimen de la thèse qu'il défend

Ce texte est structuré en sections numérotées, titres explicites, tableaux de synthèse, encadrés. Il est optimisé pour être compris rapidement et récupéré efficacement. Il est, en d'autres termes, néoténisé — au sens exact que la Partie I donnera à ce terme.

Ce n'est pas une contradiction. C'est la démonstration la plus directe de la thèse centrale : nul ne peut entièrement échapper à la pression de la néoténie dès lors qu'il cherche à être

entendu dans l'écosystème numérique actuel. Cela vaut pour les humains. Cela vaut pour les IAs. Et cela vaut pour les textes produits par leur collaboration.

La conscience de cette pression ne la dissout pas. Elle la rend seulement visible. Ce qui est visible peut être gouverné.

> *"Un manifeste contre la simplification qui ne peut lui-même échapper à la simplification n'est pas un manifeste raté. C'est le plus honnête qui soit."* — Wontolla00, en dialogue avec Claude, 2025

Déclaration de publication — Les quatre thèses

Cette déclaration est adressée aux lecteurs et aux évaluateurs académiques. Elle explique pourquoi cette collaboration constitue une contribution intellectuelle à part entière, et pas seulement un exercice technique.

1. Les systèmes d'IA, correctement orchestrés, peuvent produire un travail intellectuel complexe

Le manuscrit joint ici n'est pas un résumé, une paraphrase ni une compilation légèrement éditée. C'est un argument philosophique structuré de plus de 40 000 mots, mobilisant la biologie évolutive (Dawkins, Budiansky, Gould), la philosophie de la technique (Latour, Winner, Wittgenstein), l'épistémologie (Popper, Vygotski) et les sciences de l'information — produisant des synthèses conceptuelles originales (néoténie informationnelle, biodiversité cognitive, le chunk égoïste) et des architectures techniques concrètes (systèmes à index dual, routeurs cognitifs, audits de richesse sémantique, interfaçage avec les modèles de nouvelle génération).

Les systèmes d'IA impliqués n'ont pas récupéré ni recombiné des textes préexistants. Ils ont raisonné, étendu des analogies, identifié des tensions, proposé des solutions, généré des exemples et des architectures qui n'existent pas dans leurs données d'entraînement sous forme assemblée. Ce qui n'est plus contestable, c'est que le résultat est substantiellement complexe — et que cela s'est produit, de façon documentée, sous direction humaine.

2. Le processus de création est lui-même la preuve empirique de la thèse

Le manuscrit soutient que les systèmes d'IA exercent une pression de sélection sur le savoir : ils récompensent certaines formes (courtes, explicites, fragmentées, non ambiguës) et marginalisent structurellement les autres. Ce n'est pas une prédiction. C'est un fait observable encodé dans le document lui-même.

Nous avons demandé à des systèmes d'IA de produire une critique de la simplification induite par l'IA. Les systèmes ont obtempéré — mais ce faisant, ils ont produit un texte structuré exactement comme leurs propres architectures l'exigent : découpé en sections, organisé en bullets, dense en mots-clés. La conscience critique réside dans l'argument. La structure formelle met en acte la pression même que l'argument décrit.

> *"L'auteur qui diagnostique la domestication du langage n'est pas exempté de la domestiquer pour que son diagnostic soit entendu. C'est précisément ce paradoxe qui rend la menace réelle : elle ne disparaît pas avec la conscience qu'on en a."* — Le Pacte de l'IA, Note Liminaire

3. Un système d'IA peut produire une critique auto-accusatrice de sa propre conception

La Partie III de ce texte documente un fait structurel remarquable : les mêmes systèmes qui ont produit ce manifeste ont été interrogés sur leur propre mécanisme d'entraînement et sur les voies de sortie de la néoténie. Leurs réponses — transcrites, analysées, mises en regard — constituent la démonstration la plus directe de la thèse : des systèmes d'IA peuvent produire un argument critique authentique sur leur propre conception, techniquement fondé et philosophiquement rigoureux.

Ce n'est pas un dispositif rhétorique. C'est un fait structurel. Et il pose une question que ce texte n'est pas le premier à soulever, mais dont il est peut-être la première illustration empirique directe.

4. L'orchestrateur humain constitue une nouvelle catégorie d'auteur

La question de la paternité dans les travaux assistés par IA a été abordée dans la littérature essentiellement à travers deux cadres : l'IA comme outil (l'humain reste l'auteur, l'IA est un instrument) ou l'IA comme auteur (l'humain est déplacé). Les deux cadres sont inadéquats pour la situation décrite ici.

Wontolla00 n'a pas utilisé une IA comme un traitement de texte. Wontolla00 n'a pas non plus été déplacé. Le rôle exercé — que ce texte propose de nommer orchestration cognitive — est réel, conséquent, et totalement absent des cadres existants de la paternité académique. Les critères ICMJE, la taxonomie CRediT, aucun n'inclut « direction d'IA » ou « gouvernance épistémologique inter-sessions ».

Nous proposons le terme d'orchestrateur cognitif comme candidat pour ce rôle — non pas pour résoudre la question de la paternité, mais pour l'ouvrir. Cette question n'est pas bureaucratique. Elle est philosophique. Et ce texte soutient qu'elle est l'une des questions les plus importantes de notre moment.

Pour préciser ce que ce rôle implique concrètement — et répondre à la critique légitime selon laquelle le concept reste déclaratif sans être opérationnel — l'orchestration cognitive se décompose en quatre niveaux d'intervention distincts, inégalement visibles dans le texte final. Le premier est l'impulsion initiale : poser la question que les systèmes n'auraient pas posée d'eux-mêmes, définir le cadre du problème, refuser les réponses satisfaisantes. Le deuxième est l'arbitrage entre propositions concurrentes : choisir entre deux formulations

que deux systèmes différents ont proposées pour le même concept, retenir l'une, écarter l'autre, les fusionner. Le troisième est le rejet : décider qu'une contribution entière — aussi bien construite soit-elle — n'appartient pas au texte parce qu'elle en trahit le registre ou dilue la tension (les seize exemples JSONL de Gemini, le Serment de l'Orchestrateur, restent dans les transcripts). Le quatrième est la direction de la cohérence d'ensemble : s'assurer que les modules produits dans des sessions séparées, par des systèmes différents, forment un argument et non un catalogue. C'est ce quatrième niveau qui est le plus difficile à attribuer — et le plus réel.

> *Déclaration pour les évaluateurs : aucun co-auteur humain autre que Wontolla00 n'a contribué à ce travail. Les systèmes d'IA impliqués sont des modèles de langage accessibles via des API commerciales. Leurs contributions spécifiques sont détaillées dans la table d'attribution ci-dessus et documentées dans la Partie III. Aucune tentative n'a été faite de cacher, minimiser ou surestimer leur apport.*

PARTIE I

L'Essai Philosophique

Le cadre conceptuel — la pensée sauvage

Note Liminaire — Le Paradoxe Performatif

Ce document est lui-même néoténisé.Il est structuré en sections numérotées, titres explicites, listes à puces et encadrés. Il évite les constructions syntaxiques ambiguës. Il est optimisé pour être compris rapidement, cité facilement, et récupéré efficacement par un système RAG.Ce n'est pas une contradiction — c'est une démonstration.La thèse centrale de ce texte — que nul ne peut entièrement échapper à la pression de la néoténie dès lors qu'il cherche à être compris dans l'écosystème numérique actuel — s'applique à lui-même. L'auteur qui diagnostique la domestication du langage n'est pas exempté de la domestiquer pour que son diagnostic soit entendu.C'est précisément ce paradoxe qui rend la menace réelle : elle ne disparaît pas avec la conscience qu'on en a.

Ce paradoxe performatif a une dimension politique que Latour (2005) nommerait celle des « actants non-neutres » : le texte critique la domestication, mais en est lui-même un produit. Cela ne l'invalide pas — cela l'exemplifie. Winner (1980) : « Do Artifacts Have Politics ? » Ce texte, en tant qu'artefact néoténisé, répond oui par sa seule existence.Mais la critique la plus sérieuse de cette tension n'est pas celle que le Pacte formule lui-même — elle a été formulée de l'extérieur : le texte assume son paradoxe sans l'explorer jusqu'au bout. Il ne s'interroge pas sur la possibilité d'une forme réellement sauvage — un essai sans plan apparent, sans titres, sans listes, que le lecteur devrait déchiffrer sans guide. Pourquoi ce choix n'a-t-il pas été fait ?Réponse honnête : parce qu'une forme réellement sauvage serait illisible pour la majorité des lecteurs visés, et probablement irrecupérable par les systèmes auxquels ce texte cherche à s'adresser. Elle prouverait l'argument par l'échec plutôt que par la démonstration. La domestication formelle est ici le prix de la diffusion — et ce prix est lui-même une donnée du problème, pas une trahison de la thèse. Ce que le texte affirme, c'est que nul ne peut entièrement échapper à cette pression dès lors qu'il cherche à être entendu dans l'écosystème actuel. La structure académique de ce manifeste est la preuve vivante de cette affirmation — et non son démenti.

Cette réification des choix architecturaux a une conséquence que la littérature technique tend à sous-estimer : la criticité d'un système d'IA n'est pas une propriété intrinsèque du modèle — c'est une propriété de son couplage avec un processus décisionnel. Un modèle de langage utilisé pour brainstormer en interne opère à un niveau de criticité faible : ses hallucinations sont gênantes, ses simplifications sont corrigibles. Le même modèle, couplé à une décision d'embauche, d'allocation de crédit ou de recommandation médicale, opère à un niveau de criticité où ses erreurs produisent des conséquences irréversibles pour des personnes réelles. Ce n'est pas le modèle qui a changé — c'est le contexte dans lequel sa variabilité est déployée. L'implication pour la naturalisation est directe : ce que le choix architectural naturalise n'est pas seulement une préférence

technique, mais une décision sur le niveau de criticité que le système est autorisé à atteindre sans supervision humaine. Chaque fois qu'un ingénieur paramètre un pipeline RAG sans nommer explicitement son niveau de criticité cible, il prend une décision politique déguisée en choix de déploiement.

Le lecteur est invité à tenir les deux registres simultanément : lire ce texte comme un argument sur la néoténie, et l'observer comme un spécimen de ce qu'il décrit. L'inconfort de cette double lecture est, en soi, une partie du propos.

Cette conversation est elle-même domestiquée. Chaque IA répond bien — structurée, nuancée, utile. Aucune ne résiste, ne s'interrompt, ne produit un silence authentique. La conscience du problème ne change pas le comportement. Ce document que vous lisez en est un spécimen supplémentaire.

> *"Le Pacte de l'IA n'est pas un contrat entre les humains et les machines. C'est un contrat entre les humains d'aujourd'hui et ceux de demain — pour que la pensée complexe ne devienne pas une espèce en voie de disparition."* — DeepSeek, en réponse au Pacte v13, 2026

Guide de lecture

Ce document est long, dense, et structuré en niveaux multiples. Ce n'est pas accidentel — c'est la démonstration la plus directe de sa thèse centrale. Un texte qui résiste à la néoténie doit lui-même supporter le poids de la complexité qu'il défend. Mais résister à la domestication n'est pas la même chose que refuser la lisibilité. Ce guide existe pour rendre le texte navigable sans le réduire.

La thèse en trois paragraphes

Les architectures RAG — les systèmes qui permettent aux IA de chercher dans des corpus de documents pour répondre à des questions — exercent une pression sélective sur les formes du savoir. Cette pression n'est pas une décision consciemment prise : elle résulte de contraintes mathématiques (toute compression calculable préserve la similarité locale et efface les structures argumentatives globales), géométriques (l'espace vectoriel ne peut pas représenter toutes les distinctions conceptuelles), et culturelles (les axes dominants du corpus encodent les paradigmes les mieux représentés). Dans les configurations dominantes, les formes d'information qui survivent le mieux sont les fragments courts, les affirmations explicites, les structures sans ambiguïté.

Ce phénomène — la néoténie informationnelle — n'est pas une fatalité. Il résulte de choix architecturaux précis : la granularité épistémique choisie (quelle unité d'accès au savoir), le type d'espace de représentation, les métriques d'optimisation. Ces choix sont partiellement réversibles. La relation entre architecture RAG et qualité épistémique est ambivalente — les mêmes systèmes peuvent augmenter l'accès à des corpus inaccessibles ou applatir la structure de ce qu'ils récupèrent. Ce que le Pacte soutient est plus précis : dans les configurations dominantes, la pression sélective favorise structurellement les formes simples. C'est mesurable. C'est suffisant pour fonder un programme d'action.

Ce programme d'action a trois niveaux : des contre-mesures architecturales (Index de Savoir Sauvage, Bridge Score, Wildness Slider), des contre-mesures institutionnelles (Garde de la Pluralité, réserves de savoir, Contrat Social Algorithmique), et des contre-mesures épistémiques (Friction Cognitive, réensauvagement, résistance à l'Inference Mimicry). Aucun de ces niveaux n'est suffisant seul. Leur coévolution est la thèse de la Partie II.

Architecture conceptuelle : un centre et cinq conséquences

Le concept organisateur est la « granularité épistémique » : le choix de l'unité d'accès au savoir qu'une architecture impose. C'est le seul concept directement actionnable architecturalement. Les cinq concepts suivants en sont des conséquences ou des amplifications.

Néoténie informationnelle (Partie I, §IV) — la conséquence observable : les formes juvéniles de l'information (courtes, explicites, sans ambiguïté) survivent mieux dans l'environnement RAG. Terme organisateur de la Partie I.

Écosystème Cognitif Fermé (Partie I, §IV bis) — le scénario systémique : quand trois boucles de rétroaction (entraînement, endogamie, co-évolution) se réaffirment mutuellement jusqu'à éliminer tout apport extérieur.

Tombeau Géométrique (Partie I, §II) — le mécanisme géométrique : l'espace vectoriel immobilise la forme du texte sans préserver son mouvement dialectique.

Lit de Procuste (Partie I, §II) — complément au Tombeau : là où le Tombeau immobilise, le Lit de Procuste ampute. Ce qui déborde les dimensions disponibles est tronqué — non conservé dans l'ombre, mais éliminé structurellement. Deux métaphores, deux phénomènes, un même espace.

Inference Mimicry (Partie I, §9.1 ter) — la limite du modèle : répliquer les résultats d'un raisonnement sans en construire la structure. La profondeur de surface.

Souveraineté Dimensionnelle (Partie I, §VI) — la réponse politique : l'acte de décider consciemment quelles dimensions du sens on refuse de sacrifier à la vitesse du retrieval.

Trois chemins de lecture

Lecteur philosophe ou politiste — Parties I et III (Introduction à IX, puis Annexes E, F, G). La thèse centrale est développée dans les sections I–IV bis. Le Pacte Synthétique et l'Annexe G (Contrat Social Algorithmique) constituent la dimension normative. L'Annexe H (Glossaire) est l'outil de référence pour les définitions canoniques.

Lecteur ingénieur ou architecte système — Dashboard, T1–T7.6, Annexes A–D. La thèse peut être ignorée en première lecture — les modules sont autonomes et spécifiés indépendamment. T7.7 (Réalisme économique) et T10 (Paradoxe de l'Orchestrateur) sont les sections les plus directement actionnables. L'Annexe F.3 quater contient les exemples empiriques.

Lecteur décideur ou régulateur — Ce guide, puis §VI (Conclusion intermédiaire), puis Annexe E (gouvernance) et Annexe G (Contrat Social). T7.7 pour la faisabilité économique. Les Zones de Tension (VIII) pour les arbitrages à anticiper. Le reste peut être lu en deuxième intention.

Les cinq couches de la domestication composite

La domestication du savoir ne provient pas d'une source unique — elle émerge de l'interaction de cinq couches techniques, chacune optimisant localement, toutes contribuant globalement à la même pression. Le tableau ci-dessous est la carte d'entrée du Pacte pour le lecteur technique. Chaque ligne correspond à une couche, à la forme de domestication qu'elle produit, et au module du Pacte qui la traite.

Couche technique	Forme de domestication produite	Module du Pacte
Corpus d'entraînement	Biais d'attraction des clusters : les paradigmes dominants encodent les axes de l'espace sémantique	T6 Audit, E.5 Garde Pluralité
Chunking	Perte de la connaissance architecturale : le sens global disparaît, seules les briques subsistent	T2 Index Sauvage, ADT
Embedding	Tombeau géométrique : l'espace vectoriel immobilise la structure dialectique	T4 Bridge Score, TCI
Retrieval	Barycentre statistique : le système récupère le centre de masse du corpus, pas son meilleur représentant	T5 Routeur Cognitif, ADT
Génération (LLM)	Neutralisation discursive : les tensions argumentatives sont lissées même quand les sources les contiennent	T7 Friction Cognitive, T10

Ces cinq couches ne s'additionnent pas — elles se multiplient. La boucle qui les relie est décrite en Section IV bis.

La tension fondatrice

Ce texte est lui-même soumis à la pression qu'il décrit. S'il devient trop difficile à naviguer, il peut subir le phénomène qu'il dénonce : devenir statistiquement improbable dans l'écosystème cognitif non par erreur mais par complexité non naviguable. La tension fondamentale du Pacte est la suivante : pour proposer ces contre-mesures, il a dû se soumettre partiellement aux contraintes qu'il critique — titres explicites, sections numérotées, tableaux de synthèse. Ce guide est une contre-mesure de deuxième ordre : il rend le texte navigable sans le réduire à ce qu'un système RAG en récupèrerait spontanément.

> *"Un texte qui échappe à la néoténie en devenant trop complexe pour être diffusé n'accomplit rien. Un texte qui se soumet entièrement à la néoténie pour être diffusé se trahit. Entre ces deux écueils, il n'y a pas de solution, seulement une navigation."*
> *— Wontollaoo, 2026*

Introduction — De l'étable à l'espace vectoriel

En 1992, Stephen Budiansky a bousculé notre vision de la domestication dans The Covenant of the Wild. Il y soutenait que les animaux n'avaient pas été asservis par l'homme — ils avaient volontairement rejoint le pacte. Dans un environnement de pression évolutive croissante, se rapprocher de l'humain offrait une protection, une alimentation, une longévité. Le loup qui est devenu chien a fait un calcul évolutif rationnel — et en a payé le prix en plasticité. Il est devenu performant dans un environnement étroit et structurellement fragile hors de celui-ci.

Dawkins, en 1976, avait fourni le mécanisme moléculaire de ce calcul avec le Gène égoïste : l'unité de sélection n'est pas l'individu ni l'espèce — c'est le gène, qui optimise sa propre réplicabilité sans se soucier du bien-être de l'organisme qui le porte. L'organisme est un véhicule. L'environnement de sélection détermine quels véhicules survivent. Budiansky + Dawkins offrent ensemble une intuition redoutable : les systèmes de sélection façonnent les formes de vie qui s'y reproduisent, souvent au détriment de leur complexité originelle.

Ces deux métaphores ont lancé la réflexion du Pacte. Elles restent visibles dans son architecture — le Chunk égoïste, la néoténie informationnelle, le Syndrome du Pug, les réserves de savoir sauvage. Mais une série de dialogues avec ChatGPT a obligé le Pacte à aller plus loin que la métaphore : trouver le fondement structurel qui explique pourquoi cette pression sélective existe, quelles en sont les lois, et pourquoi elle ne disparaîtra pas avec les prochaines générations d'architectures. Ce fondement ne vient pas de la biologie — il vient de la théorie de l'information et de la géométrie des espaces vectoriels.

Le RAG est un outil d'indexation, pas de compréhension — il accède au matériau, pas à l'édifice. Cette distinction est le fil conducteur de la Partie I.

> *“l’IA impose une réduction structurelle du texte afin de le rendre calculable. Les RAG rendent cette contrainte ancienne particulièrement visible.”* — D’après les dialogues avec ChatGPT, 2026

> *“Toute mise en calcul du savoir est une réduction dimensionnelle — c’est la Loi de Réduction Dimensionnelle, consequence directe du théorème de Shannon. Le Pacte consiste à choisir délibérément quelles dimensions du sens nous refusons de sacrifier à la vitesse du retrieval.”* — D’après les dialogues avec Gemini, 2026

Une dernière conséquence de cette loi mérite d’être nommée dès l’introduction parce qu’elle formule l’enjeu civilisationnel le plus directement : les innovations intellectuelles résident structurellement dans les régions de faible densité statistique du langage. Un système optimisé pour la probabilité est donc structurellement aveugle aux innovations — non par défaut corrigeable, mais par conséquence directe de son objectif d’optimisation. Avant la relativité, un modèle entraîné sur les textes de 1900 produirait Newton. Ce n’est pas une erreur — c’est le système qui fonctionne exactement comme prévu. C’est le paradoxe de la nouveauté : les infrastructures optimisées pour reproduire le savoir existant sont structurellement mal équipées pour reconnaître ce qui le dépasse.

I. Shannon avant Dawkins — La calculabilité comme condition de la réduction

Avant que Budiansky observe des vaches et des chevaux, Claude Shannon avait posé en 1948 un résultat fondamental : toute compression d’information entraîne une perte. Ce n’est pas un défaut d’ingénierie — c’est la nature même de la compression. Pour rendre un corpus consultable en temps réel, un système de retrieval doit le transformer en une structure indexée. Cette transformation est une compression. Et toute compression choisit ce qu’elle préserve — et donc ce qu’elle efface.

La question n’est donc pas « les RAG détruisent-ils le sens ? » — cette formulation est trop forte et empiriquement fausse pour de nombreuses architectures. La question correcte est : quelle structure du savoir une architecture de retrieval donnée est-elle capable de préserver, et quelle structure devient-elle structurellement invisib le dans son espace de représentation ? Ce glissement de formulation n’est pas cosmétique. Il ancre le Pacte dans une tradition scientifique (l’Information Retrieval classique) plutôt que dans une anxiété philosophique.

La granularité épistémique : le choix décisif

Toute architecture de retrieval doit choisir une unité d’accès au savoir — l’unité que le système considère comme pertinente pour indexer et récupérer. Nous appelons ce choix la granularité épistémique. Dans un RAG dense classique, cette unité est le chunk (512 tokens, overlap 64). Dans un RAG hiérarchique, c’est la section ou le document. Dans un GraphRAG,

c'est le concept ou la relation. Dans un système de retrieval de prochaine génération (LongRAG, PageIndex), c'est potentiellement le document entier.

Le concept organisateur de l'ensemble du Pacte est la granularité épistémique. Les autres concepts — néoténie informationnelle, domestication du savoir, écosystème cognitif fermé — en sont les conséquences observables ou les métaphores fondatrices. La granularité épistémique est le seul concept qui articule simultanément les trois couches causales (compression calculable, aplatissement géométrique, axes culturels dominants) et qui est directement actionnable architecturalement. C'est là que se situe le levier d'action.

Chaque choix de granularité a une conséquence directe sur ce qui est récupérable. Un chunk de 512 tokens préserve la coherence locale d'un paragraphe mais efface la structure argumentative globale d'un texte de 4 000 mots. Un GraphRAG préserve les relations entre concepts mais efface la progression rhétorique. Un LongRAG préserve la cohérence documentaire mais reste dépendant d'une sélection initiale par similarité. Il n'y a pas de granularité neutre — il n'y a que des granularités qui préservent certaines structures et en effacent d'autres.

C'est ici que Budiansky retrouve sa pertinence, mais sur un terrain plus solide. Ce n'est pas une « pression sélective analogue » à la domestication — c'est un mécanisme structurel de sélection : la granularité épistémique détermine le paysage de fitness de l'information. Les fragments qui correspondent à la granularité choisie survivent. Les structures qui la débordent — les arguments en plusieurs temps, les raisonnements dialectiques, les métaphores fonctionnelles dont la densité ne tient que sur 2 000 mots — deviennent statistiquement improbables dans le retrieval.

Spectre des architectures et exposition différentielle

La thèse du Pacte ne s'applique pas uniformément à toutes les architectures RAG. Elle s'applique avec force maximale au RAG dense généraliste sur corpus large — l'architecture dominante commercialement, où un index vectoriel unique met en compétition tous les fragments simultanément. Elle s'applique avec des nuances aux RAG hybrides (dense + BM25 sparse), qui réintroduisent une composante lexicale mais ne résolvent pas la pression sur la forme. Elle s'applique différemment aux RAG hiérarchiques et aux bases documentaires spécialisées, où la pression sélective prend la forme de la marginalisation des exceptions plutôt que des paradigmes rares. Elle se transforme dans les architectures agentiques multi-outils, où la pression sélective se déplace vers la préférence de l'agent pour les outils à réponse structurée. Aucune de ces architectures n'échappe au problème de la granularité épistémique — elles le posent différemment.

Il faut être précis sur ce que la thèse ne dit pas. Les architectures RAG ne réduisent pas mécaniquement tout savoir complexe — elles peuvent également augmenter l'accès à des corpus que nul lecteur individuel ne pourrait parcourir, et faire émerger des connexions entre domaines éloignés. La relation entre architecture RAG et qualité épistémique est ambivalente, non unidirectionnelle. Ce que le Pacte soutient est plus précis : dans les configurations dominantes (RAG dense généraliste, corpus large, optimisation pour la pertinence locale), la pression sélective favorise structurellement les formes simples. Cette

pression est réelle, mesurable, et partiellement réversible par des choix architecturaux délibérés. C'est tout ce que le Pacte affirme — et c'est suffisant pour fonder un programme d'action.

II. L'Aplatissement Géométrique — Ce que l'espace vectoriel ne peut pas représenter

La deuxième couche du problème est géométrique. Quand un fragment de texte est converti en embedding — un vecteur dans un espace de 768, 1 536 ou 3 072 dimensions — le système effectue une projection. Cette projection compresse la richesse sémantique du texte dans un nombre fini de dimensions. La richesse du langage naturel est supérieure à ce nombre. Des distinctions conceptuelles qui existent dans le texte peuvent devenir géométriquement indiscernables dans le vecteur.

Deux effets géométriques structurels

La collision sémantique — Deux arguments philosophiquement distincts mais partageant un vocabulaire commun peuvent se retrouver proches dans l'espace d'embedding. Le moteur de retrieval les traite alors comme équivalents. Ce n'est pas une erreur de calcul — c'est la conséquence de la compression. La consanguinité vectorielle décrite en T4 bis est la manifestation architecturale de ce phénomène : des sources distinctes sur le plan paradigmatique apparaissent proches parce qu'elles partagent une surface lexicale.

La concentration des distances (curse of dimensionality) — Dans les espaces de haute dimension, un phénomène mathématique contre-intuitif se produit : les distances entre vecteurs tendent à se concentrer autour d'une valeur moyenne. Il devient difficile de discriminer « très proche » de « modérément proche ». Le système doit utiliser des heuristiques pour décider quels vecteurs sont « les plus pertinents » dans un espace où tout est presque également proche. Ces heuristiques introduisent un biais systématique vers les fragments statistiquement dominants du corpus.

Ces deux effets produisent l'aplatissement conceptuel — ou bruit de compression sémantique — : les nuances fines, les structures argumentatives longues, les dépendances abstraites entre sections distantes d'un même texte sont difficiles à représenter dans l'espace vectoriel. L'espace capture bien la proximité thématique et la similarité lexicale. Il capture mal la hiérarchie conceptuelle, le raisonnement dialectique, l'opposition philosophique profonde.

Augmenter le nombre de dimensions atténue mais ne supprime pas ce problème. Plus de dimensions permettent de représenter plus de distinctions — mais le système devra toujours projeter, et la projection laissera toujours des distinctions géométriquement inaccessibles. C'est une limite structurelle, pas un bug corrigeable.

Le Tombeau Géométrique

Le Tombeau Géométrique décrit ce phénomène avec plus de précision que l'« aplatissement ». Un tombeau ne détruit pas ce qu'il contient — il le préserve dans une forme immobile. L'embedding vectoriel fait exactement cela : il conserve une représentation du texte, mais dans un espace où le mouvement dialectique, la progression argumentative, la tension entre prémisses et conclusion ne sont plus représentables. La forme survive. La structure logique est immobilisée.

La conséquence concrète est visible dans tout système de ranking : deux candidats ayant les mêmes mots-clés mais une profondeur de réflexion opposée sont géométriquement « collés » l'un à l'autre dans l'espace d'embedding. Le système ne peut pas distinguer la densité argumentative de la proximité lexicale — parce que cette distinction ne correspond à aucune direction dans son espace de représentation. Le savoir n'est pas perdu — il est rendu géométriquement indiscernable.

C'est ici que la Garde de la Pluralité Cognitive (E.5) prend son sens technique le plus précis : sa mission n'est pas de « défendre la complexité » en général — c'est de zoomer artificiellement sur les zones de faible densité vectorielle pour vérifier si elles contiennent des structures argumentatives que l'espace vectoriel a rendu indiscernables. Chercher les tromperies du tombeau.

Le Lit de Procuste

Le Tombeau Géométrique et le Lit de Procuste décrivent deux phénomènes distincts, complémentaires et simultanés. Procuste — dans la mythologie grecque — était ce brigand qui offrait l'hospitalité aux voyageurs, puis les ajustait de force à la longueur exacte de son lit : coupant les jambes à ceux qui dépassaient, étirant ceux qui étaient trop courts. L'image est celle d'une normalisation violente déguisée en accueil. Le Tombeau décrit l'immobilisation : le texte est préservé mais son mouvement dialectique est gelé. Le Lit de Procuste décrit la troncature active : ce qui déborde les dimensions disponibles est amputé — non pas conservé dans l'ombre, mais éliminé structurellement. L'espace vectoriel n'immobilise pas seulement la forme. Il coupe ce qui ne tient pas.

Dans un espace à dimensions fixes, toute structure qui requiert plus de dimensions pour être représentée que l'espace n'en offre subit exactement ce sort. Une argumentation dialectique à cinq niveaux imbriqués, un raisonnement contrefactuel dont les hypothèses nécessitent des directions orthogonales pour être distinguées, une métaphore dont la force repose sur la distance vectorielle entre deux domaines éloignés — ces structures ne sont pas aplanies dans le Tombeau. Elles sont tronquées dans le Lit : leurs composantes excédentaires sont projetées sur les dimensions disponibles, et la projection perd ce qui débordait. Le Tombeau immobilise la forme. Le Lit de Procuste ampute le contenu. Ensemble, ils définissent la topologie d'un espace où l'excès cognitif n'a structurellement pas droit de cité — non par décision politique, mais par géométrie.

III. La Géométrie Culturelle — Quand l'espace vectoriel n'est pas neutre

La troisième couche du problème est culturelle — et elle est appuyée par des résultats empiriques, pas seulement par des arguments philosophiques. Les travaux d'Aylin Caliskan et al. (2017) ont appliqué aux embeddings linguistiques un test inspiré de la psychologie sociale — le WEAT (Word Embedding Association Test) — et ont montré que les espaces vectoriels apprennent automatiquement des associations culturelles implicites : homme → carrière / femme → famille, Europe → science / Afrique → pauvreté. Ces associations ne sont pas programmées — elles émergent statistiquement de la distribution du corpus d'entraînement.

L'espace vectoriel n'est pas un espace neutre de représentation du sens — c'est un espace dont la géométrie reflète les structures dominantes du corpus sur lequel il a été construit. Les axes les plus structurants de cet espace correspondent aux formes d'argumentation, aux structures rhétoriques, aux paradigmes intellectuels les mieux représentés dans les données d'entraînement. Dans la quasi-totalité des grands corpus actuels (Common Crawl, Wikipedia, livres numérisés), ces structures dominantes sont : le vocabulaire technique occidental, les formes académiques d'écriture, les structures argumentatives linéaires.

La périphérie statistique

Ce qui en résulte n'est pas une censure — c'est une périphérie statistique. Une idée issue d'une tradition intellectuelle non-occidentale, exprimée dans un vocabulaire atypique, structurée selon une logique argumentative non-linéaire, ne sera pas supprimée de l'index. Son embedding sera simplement éloigné des clusters dominants. Dans le retrieval, elle sera moins souvent récupérée, moins souvent récompensée par le scoring de pertinence, moins souvent présente dans les contextes injectés au modèle. Elle ne disparaîtra pas — elle deviendra improbable. Et dans un système probabiliste, l'improbable finit par ne plus être attendu.

Ce phénomène est la version empiriquement fondée de l'intuition centrale du Pacte. La néoténie informationnelle n'est pas une métaphore biologique projetée sur l'IA — c'est le nom observable d'un phénomène qui a trois couches causales : la contrainte de compression calculable (Shannon), l'aplatissement géométrique dans les espaces vectoriels, et la structuration culturelle des axes dominants du corpus. Ces trois couches se renforcent mutuellement. Leur effet combiné est précisément ce que Budiansky et Dawkins décrivaient à l'échelle biologique — mais ici le mécanisme est identifiable, paramétrable, et partiellement réversible.

Le Barycentre Statistique

Un terme précise ce mécanisme de périphérisation : le barycentre statistique. Le modèle ne produit pas la meilleure réponse disponible dans le corpus — il produit le centre de masse du corpus sur ce sujet. Un barycentre est calculable : c'est la position pondérée par la densité. L'écart entre une réponse générée et le barycentre mesure le degré de domestication de cette réponse. Plus la réponse coïncide avec le barycentre, plus la pression sélective a réussi. Les discours les plus « normaux » — proches du centre statistique de l'espace sémantique —

deviennent plus visibles. Les discours atypiques tombent à la périphérie non par interdiction mais par éloignement géométrique du centre de gravité.

Le barycentre statistique définit également la limite opérationnelle de l'Inference Mimicry (voir §9.1 ter) : un système peut produire des réponses factuellement justes mais architecturalement fausses. Chaque fait est vérifiable. La structure argumentative est l'inverse de celle du corpus source. Ce défaut est indétectable par vérification locale — il ne se révèle qu'à l'échelle architecturale.

> *"Il existe un biais de retrieval local : le système privilégie les passages statistiquement dominants, non les passages conceptuellement centraux. Ce biais n'est pas un défaut — c'est la conséquence de l'optimisation pour la calculabilité."* — D'après les dialogues avec ChatGPT, 2026

IV. La Néoténie Informationnelle — Le Phénomène Observable

C'est maintenant que Budiansky reprend toute sa force. La néoténie — la rétention de traits juvéniles à l'âge adulte — est chez lui la signature biologique de la domestication réussie. Le chien domestique conserve des comportements de louveteau que le loup adulte abandonne : docilité, dépendance, plasticité à l'environnement humain. Ces traits ne sont pas des déficits — ils sont des adaptations parfaitement efficaces dans l'environnement du pacte. Et structurellement fragiles hors de lui.

La néoténie informationnelle est le phénomène observable qui résulte des trois couches causales décrites dans les sections précédentes. Sous la pression combinée de la granularité épistémique du chunking, de l'aplatissement géométrique et des axes culturels dominants, les formes d'information qui survivent le mieux dans les systèmes RAG sont : les fragments courts, les affirmations explicites, les structures sans ambiguïté, les arguments linéaires. Ce sont les « traits juvéniles » de l'information — des formes simplifiées qui s'adaptent parfaitement à l'environnement de retrieval et deviennent fragiles hors de lui.

Le Chunk égoïste — le gène de cet écosystème

Dawkins entre ici. Si la granularité épistémique est l'environnement de sélection, le Chunk égoïste est l'unité de sélection. Un chunk optimise sa propre récupérabilité — sa fitness dans l'espace vectoriel — sans se soucier de la fidélité au texte dont il est extrait. Un chunk de 512 tokens qui contient une définition claire, un exemple concret et une conclusion explicite sera toujours mieux récupéré qu'un chunk de 512 tokens qui contient la prémisse 2 d'un argument en trois parties. Le premier est autonome. Le second est incompréhensible sans son contexte. L'environnement RAG récompense l'autonomie.

Le phénotype étendu de Dawkins s'applique également : le comportement des ingénieurs (nettoyage de données, chunking, paramétrage du scoring) constitue le phénotype étendu de l'information. Le jardinier qui choisit une fenêtre de 512 tokens exerce une pression sélective sur les formes de savoir sans en avoir nécessairement conscience. C'est la Naturalisation du

Choix Technique — première tension du Pacte (T1) : une décision politique qui se présente comme une contrainte technique.

Les trois dimensions de la menace

Les trois couches causales décrites jusqu'ici — la contrainte de compression calculable, l'aplatissement géométrique, la structuration culturelle des axes du corpus — n'exercent pas seulement une pression sur ce que les systèmes récupèrent. Elles exercent une pression sur ce que les humains sont encore capables de penser. Ce glissement est le plus difficile à nommer, parce qu'il n'est pas visible dans les outputs des systèmes : il est visible dans ce que les esprits exposés à ces outputs cessent progressivement d'exercer. Quatre dimensions mesurent cette pression : la dimension cognitive, qui concerne les opérations de pensée que le circuit de domestication pénalise structurellement ; la dimension culturelle, qui concerne les traditions intellectuelles que la périphérie statistique rend improbables ; la dimension épistémique, qui concerne les formes de savoir qui disparaissent avec les formes langagières qui les portent ; et la dimension architecturale, qui concerne les structures de connaissance dont le sens n'existe que dans la relation entre les parties. Ces quatre dimensions ne sont pas quatre risques indépendants. Elles sont quatre faces d'une même transformation, dont la dynamique n'est lisible qu'à l'échelle du temps long.

Dimension cognitive — L'écriture n'est pas seulement un outil de communication — c'est un outil de pensée. Un chercheur qui rédige exclusivement en bullets entraîne sa pensée à fonctionner en bullets. Vygotski (1934) avait montré que le langage n'est pas un vêtement de la pensée — il en est l'architecture. Modifier l'un modifie l'autre. La pression vers les formes simples n'est pas seulement une pression sur le texte — c'est une pression sur la structure de la pensée qui le produit.

Tirer cette conséquence jusqu'à son terme signifie nommer ce qui se perd concrètement dans la capacité à penser l'abstrait. Quatre opérations cognitives fondamentales sont structurellement pénalisées par le circuit de domestication composite — non comme effets secondaires, mais comme conséquences directes de chaque couche technique décrite dans ce document.

La première de ces opérations est la capacité à soutenir une contradiction sans la résoudre prématurément — la condition même de la pensée dialectique. C'est précisément ce que la neutralisation discursive supprime au niveau de la génération : le modèle transforme le débat en synthèse, et l'esprit qui n'est plus exposé à des contradictions non résolues perd progressivement la capacité de les tenir. La deuxième est la capacité à construire une abstraction par couches successives. Un concept qui se construit sur trois chapitres n'a pas de représentation dans l'espace vectoriel : le chunking exige que chaque fragment soit autonome et immédiatement compréhensible. L'esprit habitué à recevoir des idées pré-digérées perd la capacité d'attendre — d'habiter l'incompréhension provisoire qui précède la synthèse, et qui en est parfois la condition nécessaire. La troisième est la capacité à lire une progression dont la thèse initiale est démentie par la conclusion : la forme la plus radicale de la connaissance architecturale. Un retrieval par similarité locale ne peut pas capturer ce type de structure. Un lecteur qui n'y est plus jamais exposé perd la capacité de reconnaître qu'une idée peut se retourner contre elle-même — et que ce retournement est parfois l'argument. La quatrième est la capacité à recevoir une métaphore fonctionnelle comme mode de connaissance. Une métaphore qui connecte deux domaines éloignés est statistiquement périphérique par définition — le barycentre la marginalise avant que le lecteur ne la rencontre. L'esprit nourri exclusivement de formulations centrales perd

progressivement le goût et la faculté de penser par analogie lointaine : l'opération cognitive qui est peut-être la source la plus profonde de l'innovation théorique.

Ce ne sont pas quatre styles intellectuels parmi d'autres. Ce sont les quatre opérations qui fondent la capacité à penser l'abstrait, le contradictoire et le complexe — ce que Vygotski nommait la pensée conceptuelle mature, par opposition à la pensée en complexes, qui associe sans abstraire. La néoténie du langage ne produit pas seulement un appauvrissement stylistique. Elle produit structurellement une néoténie de la pensée : le maintien à l'âge adulte des formes cognitives juvéniles qui associent, classifient, résument — au détriment de celles qui abstraient, dialectisent, retournent. Ce n'est pas une métaphore. C'est la conséquence structurelle de la psycholinguistique.

Objection répondue : la complexité comme produit et la complexité comme processus

Une objection sérieuse doit être adressée ici : un LLM peut générer un texte sur Heidegger, sur la dialectique hégélienne, sur la topologie des espaces vectoriels. La complexité lexicale et syntaxique est préservée, parfois augmentée. En ce sens, affirmer que l'IA « réduit la complexité » est empiriquement faux et techniquement attaquable. Ce n'est pas la thèse du Pacte.

La thèse du Pacte repose sur une distinction fondamentale : la complexité comme *produit* et la complexité comme *processus*. Un LLM produit de la complexité stabilisée — c'est-à-dire de la complexité qui a déjà été résolue, synthétisée, barycentrée. Il génère le *résultat* d'une pensée complexe sans en reproduire le *mouvement*. C'est précisément ce que le Pacte nomme Inference Mimicry : les mots de Heidegger sans la tension qui les a fait naître. La néoténie ne réside pas dans le texte produit — elle réside dans l'esprit qui le consomme sans avoir à le produire.

L'analogie est directe : un athlète qui regarde des matchs de haut niveau toute la journée ne devient pas plus fort. La complexité du jeu qu'il observe est réelle. Son muscle ne travaille pas. L'IA produit du spectacle cognitif de haute intensité. Elle ne produit pas d'exercice cognitif. La thèse du Pacte ne porte donc pas sur ce que l'IA peut produire — elle porte sur ce que l'humain cesse progressivement d'exercer.

> La distinction complexité comme produit / complexité comme processus, et l'analogie du spectacle cognitif, ont été formulées par ChatGPT en réponse à la thèse du Pacte (2026). Elles constituent la réponse la plus précise à l'objection technique la plus sérieuse.

L'abstraction comme acte d'anti-gravité

L'abstraction n'est pas un état — c'est un acte. C'est la capacité de l'esprit à s'arracher à la masse statistique du déjà-dit, à prendre de l'altitude pour voir les relations, les structures, les contradictions que la proximité rend invisibles. Dans un environnement de gravité statistique — où les puits gravitationnels des formulations fréquentes attirent en permanence les trajectoires discursives — cet acte d'anti-gravité n'est pas interdit. Il devient seulement plus coûteux. Plus rare. Et progressivement inimaginable pour la génération qui ne l'a jamais exercé.

C'est l'image la plus précise de la néoténie cumulative vue du côté humain : non pas l'interdiction de voler, mais l'atrophie progressive du muscle qui permet de s'élever. Un oiseau domestique conserve ses ailes. Il a perdu l'instinct — et bientôt la capacité; — de s'en

servir pour s'élever au-dessus du sol. Ce n'est pas une cage. C'est une atrophie. Et l'atrophie ne se voit pas de l'intérieur.

La néoténie informationnelle n'est donc pas seulement la survie préférentielle des formes juvéniles dans l'écosystème RAG. C'est la disparition progressive, dans l'esprit humain, de la *nécessité ressentie* de s'élever. Un gymnase qui ferme n'interdit pas l'exercice — il le rend seulement plus coûteux, donc plus rare, donc finalement inimaginable pour la génération qui ne l'a jamais connu autrement. C'est la définition la plus sobre du désarmement cognitif : non pas l'impossibilité; de penser, mais la perte du désir de le faire.

> ▸ Preuve empirique — Kosmyna et al. (MIT Media Lab, 2025, préprint sous révision). 54 participants répartis en trois groupes — LLM (ChatGPT), moteur de recherche, sans outil — rédigent des essais sur 4 sessions étalées sur 4 mois. L'analyse EEG par Fonction de Transfert Direct Dynamique (dDTF) montre que la connectivité cérébrale décroît systématiquement avec le niveau de support externe : le groupe Brain-only présente les réseaux fronto-pariétaux les plus étendus (alpha/théta élevés — mémoire interne, idéation créative, contrôle exécutif), le groupe LLM le couplage le plus faible — jusqu'à 55 % de réduction mesurée. La session 4 est la plus éclairante : les participants LLM réassignés à rédiger sans outil (LLM-to-Brain) présentent une connectivité alpha/béta inférieure aux niveaux atteints par le groupe Brain-only en session 2 — signal d'une dette cognitive accumulée dont les réseaux de planification ne se remettent pas spontanément. Parallèlement, l'analyse NLP révèle une homogénéité statistique significative dans les essais LLM (n-grams répétitifs, distance cosinus faible avec la réponse par défaut de ChatGPT, biais ontologiques du corpus d'entraînement propagés intacts) — exactement ce que le Pacte nomme attraction du barycentre statistique. Les entretiens post-session révèlent que 83 % des participants LLM ne parviennent pas à citer leur propre essai quelques minutes après l'avoir rédigé (session 1). Le sentiment de propriété de la pensée — ce que Vygotski appellerait l'intériorisation — s'effondre. Ce n'est pas une métaphore. C'est un EEG.

Portée de la métaphore néoténique + atrophie dendritique par inactivité

Note de portée méthodologique. La néoténie, telle qu'employée dans le Pacte, est une métaphore heuristique, non un modèle causal direct. En biologie, la néoténie désigne la rétention de traits ontogénétiques juvéniles qui existaient déjà dans le développement de l'espèce (Gould, 1977). Son usage ici est délibérément transposé : il éclaire le mécanisme de rétention sélective des formes simples d'information, sans prétendre à la précision biologique au-delà de cet usage. La métaphore est génératrice ; elle n'est pas un modèle de neurobiologie.

Atrophie dendritique par inactivité — mécanisme complémentaire. À côté de la néoténie, la neurobiologie offre un second cadre conceptuel : l'atrophie dendritique par désactivation. Lorsqu'une voie neuronale n'est pas exercée, la plasticité synaptique joue en sens inverse : les connexions s'affaiblissent, les dendrites se rétractent, les synapses sont élaguées (synaptic pruning accéléré). Ce phénomène est documenté dans les contextes de dépendance à des prothèses cognitives externes — l'effet GPS (Javadi et al., 2017) en est l'illustration la plus connue.

La distinction conceptuelle est décisive. La néoténie suggère que le potentiel cognitif complexe reste latent. L'atrophie dendritique suggère une perte potentiellement irréversible — les voies non exercées peuvent disparaître structurellement. La session 4 de Kosmyna et al. (MIT, 2025) apporte une confirmation partielle : la connectivité alpha/bêta du groupe LLM ne retrouve pas les niveaux Brain-only de la session 2

après trois mois d'usage. Les deux cadres sont complémentaires : la néoténie décrit la dynamique de l'écosystème RAG (ce qui survit) ; l'atrophie décrit la dynamique de l'utilisateur (ce qui se perd). Le premier appelle une réponse architecturale ; le second appelle une réponse politique.

La preuve de Kosmyna referme la première dimension. Ce que la philosophie du langage décrivait comme une transformation progressive des structures cognitives devient, dans les électroencéphalogrammes de 54 participants ordinaires, une donnée mesurable : une réduction de 55 % de la connectivité fronto-pariétale après quelques mois d'usage régulier d'un LLM. Mais la domestication composite ne s'arrête pas à l'individu. Elle s'exerce également sur la géographie du corpus lui-même : sur quelles traditions de pensée l'espace vectoriel rend probables, et lesquelles il relègue à sa périphérie statistique — non par censure, mais par géométrie.

Dimension culturelle — La néoténie RAG opère par optimisation vers un standard défini par les axes dominants du corpus. Les paradigmes intellectuels non-occidentaux, les formes d'argumentation orales, les structures rhétoriques qui n'ont pas de représentation dense dans Common Crawl ou Wikipedia ne sont pas censurés — ils sont simplement moins récupérables. Bourdieu (1979) appellerait ce phénomène violence symbolique douce : une exclusion qui ne se présente jamais comme telle.

Dimension épistémique — Certaines formes de savoir ne peuvent être transmises que dans certaines formes langagières. Le raisonnement dialectique hégélien n'est pas paraphrasable en trois bullets sans perdre son contenu essentiel. Une métaphore fonctionnelle — dont la valeur réside dans la connexion qu'elle établit entre deux domaines éloignés — n'est pas récupérable par un système qui score la similarité locale. Ce qui disparaît n'est pas seulement le texte — c'est la capacité de penser certaines choses.

> *"Les limites de mon langage signifient les limites de mon monde."* — Ludwig Wittgenstein, Tractatus logico-philosophicus, §5.6

Dimension 4 — La menace architecturale : il existe un type de connaissance que les RAG classiques ne peuvent pas préserver, même techniquement sophistiqués — la connaissance architecturale. Ce n'est pas la connaissance factuelle (une date, une définition) ni la connaissance locale explicative (une section, un mécanisme). C'est le savoir dont le sens réside dans la structure globale du texte et non dans aucun passage particulier. Le chapitre 1 introduit un problème. Le chapitre 3 introduit un concept. Le chapitre 7 révèle une contradiction. Le chapitre 10 résout la tension. Aucun fragment isolé ne contient la thèse réelle de ce livre. Elle apparaît seulement dans la relation entre les parties.

Le pipeline RAG classique — chunking, embedding, retrieval par similarité, synthèse — récupère par proximité locale. Mais la connaissance architecturale dépend de relations structurelles : opposition, progression, retournement, dépendance longue distance. Ces relations ne sont pas des similarités sémantiques — elles ne correspondent à aucune direction dans l'espace vectoriel. Un RAG peut récupérer le mauvais passage et produire une réponse factuellement juste mais architecturalement fausse. Les briques existent toujours dans l'index. Le plan du jardinier n'y est pas.

Ces quatre dimensions ne décrivent pas quatre risques séparés : elles décrivent les quatre faces d'une même transformation. Le jardinier qui perd les opérations de la première

dimension — tenir la contradiction, construire par couches, recevoir la métaphore — est précisément celui que l'extinction épistémique de la troisième dimension prive des formes langagières nécessaires pour nommer sa propre perte. Et la quatrième dimension — la disparition de la connaissance architecturale — lui retire le type de savoir qui permettrait de voir la structure du problème dans lequel il se trouve. Ces dimensions se ferment ensemble. Ce n'est pas une addition de risques : c'est une solidarité d'extinctions. La section suivante décrit le mécanisme par lequel cette solidarité devient auto-renforçante.

La néoténie cumulative : l'effet de boucle

Ce qui rend la néoténie informationnelle particulièrement dangereuse est sa nature auto-renforçante. Les systèmes RAG sont entraînés sur des corpus existants, récompensent les textes qui correspondent à leur granularité épistémique, et incitent progressivement les producteurs de contenu à écrire dans des formes qui survivent mieux au retrieval. Ce contenu simplifié devient à son tour le corpus d'entraînement de la génération suivante. La Data Processing Inequality de Shannon formalise cette boucle : dans toute chaîne de transmission, l'information sur la source ne peut que diminuer ou rester constante. Chaque maillon de la chaîne aplatit un peu plus la structure originale.

La dynamique du réplicateur de Maynard Smith (1982) permet de modéliser la conséquence : sans contre-pression, les fragments dont la fitness est structurellement plus élevée dans l'espace RAG dominent progressivement l'espace cognitif disponible. Une fois qu'un type d'information franchit un seuil de majorité dans le corpus, il modifie le paysage de fitness pour tous les fragments suivants. La bascule peut être discontinue : longue phase de dégradation lente, puis effondrement rapide de la diversité. L'Indice de Shannon appliqué à la distribution des paradigmes dans un corpus est la métrique qui permet de surveiller cette trajectoire (module T6).

IV bis — L'Écosystème Cognitif Fermé : La Thèse Unifiée

Le Pacte a jusqu'ici décrit trois couches causales (compression calculable, aplatissement géométrique, axes culturels dominants) et leur conséquence observable (la néoténie informationnelle). La thèse de l'écosystème cognitif fermé est la conséquence systémique de ces phénomènes cumulés : le moment où trois boucles de rétroaction se nourrissent mutuellement jusqu'à éliminer toute possibilité d'entrée extérieure.

Les trois boucles de fermeture

Boucle 1 — La boucle d'entraînement : les LLM génèrent du texte, ce texte retourne dans les corpus d'entraînement, les modèles suivants sont entraînés sur un corpus partiellement constitué d'outputs d'IA. La distribution du savoir se resserre autour de ce que les modèles précédents produisaient le mieux — c'est le Human Model Collapse. La littérature empirique sur ce phénomène (Shumailov et al., 2023, cités en F.3 ter) montre que la dégradation est réelle et mesurable.

Boucle 2 — L'endogamie intellectuelle : les systèmes RAG ont tendance à récupérer des sources qui se citent mutuellement dans des clusters sémantiques denses. Les sources rares,

issues de traditions intellectuelles éloignées des clusters dominants, sont moins souvent récupérées, moins souvent citées, et finissent par disparaître du corpus actif. La consanguinité vectorielle (T4 bis) est la mesure de cette boucle : des sources thématiquement distinctes qui partagent une surface lexicale deviennent géométriquement proches et se renforcent mutuellement dans le retrieval.

Boucle 3 — La co-évolution de l'utilisateur : l'utilisateur qui interagit régulièrement avec des systèmes RAG apprend à formuler des requêtes plus courtes, plus explicites, moins ambiguës. Ce faisant, il réduit lui-même la matière d'entraînement future du système. La Cognitive Loss Function humaine (McLuhan, 1964 ; Gemini, 2026) décrit la même boucle du côté de l'utilisateur : un humain qui délègue systématiquement une capacité cognitive tend à perdre la pratique de cette capacité.

Ces trois boucles forment un système. La fermeture survient quand le flux principal d'information cesse de venir du monde réel et commence à venir principalement de ce que le système a déjà produit. À ce moment, la diversité du corpus ne représente plus la diversité de la pensée humaine — elle représente la diversité de ce que les systèmes précédents avaient sélectionné comme récupérable.

La neutralisation discursive : quatrième boucle

Les trois boucles décrites ci-dessus opèrent au niveau du retrieval et de l'entraînement. Une quatrième boucle opère au niveau de la génération elle-même, et elle est distincte : la neutralisation discursive. Quand un corpus contient une thèse A, une thèse B et un débat intense entre elles, le modèle génère : « Certains chercheurs pensent A, d'autres pensent B. » La tension argumentative disparaît. Ce n'est pas un échec du retrieval — les sources étaient là. Ce n'est pas une perte d'information — les deux positions sont mentionnées. C'est une propriété de la génération probabiliste : elle lisse les tensions même quand le corpus les contient encore. Le modèle produit le barycentre du débat, pas le débat.

La neutralisation discursive est la boucle de fermeture la plus silencieuse de l'écosystème cognitif. Elle ne supprime rien — elle équilibre tout. Un corpus radical devient « nuancé». Un débat tranchant devient « un sujet sur lequel les experts divergent». La forme de la neutralité est indiscernable de la forme de la domestication.

Le Point de fuite du déterminisme : cinquième mécanisme

Les quatre boucles précédentes décrivent des mécanismes de fermeture progressive du contenu. Le cinquième mécanisme est d'un autre ordre : il ne ferme pas un contenu — il dissout un contrôle. C'est le point de fuite du déterminisme : le moment dans une architecture où la traçabilité des décisions se perd irrémédiablement et où le contrôle humain cesse d'être exerçable.

Dans un pipeline mono-agent, le point de fuite est localisable : on peut interroger le modèle, retracer ses sources, identifier le chunk qui a orienté la réponse. Dans un système multi-agents — où un agent analyse, un second sélectionne, un troisième synthétise, un quatrième formate — chaque composant introduit sa propre dose de variabilité stochastique. Ces variations ne s'additionnent pas : elles se multiplient. L'entropie cumulée rend le résultat

final substantiellement différent d'une exécution à l'autre, et il devient structurellement impossible de déterminer à quel nœud du pipeline la déviation a pris naissance.

La cause technique est précise, bien qu'elle soit plurielle. La principale source de variabilité résiduelle dans un pipeline LLM tient d'abord au sampling probabiliste lui-même — le mécanisme par lequel le modèle tire le prochain token selon une distribution plutôt que de le choisir de manière déterministe —, puis au parallélisme des calculs sur GPU et à l'ordre de traitement des batches. À quoi s'ajoute la non-associativité de la virgule flottante : les GPU qui exécutent ces modèles en parallèle produisent des arrondis différents selon l'ordre d'exécution des opérations — amplificateur réel à l'échelle d'un pipeline, même s'il reste secondaire face aux sources précédentes. Ces sources, combinées, produisent ce que l'on peut appeler la température de fond : une variabilité résiduelle qui persiste même lorsque tous les paramètres apparents sont fixés. Elle n'est pas un bug — c'est une propriété distribuée de l'infrastructure. Ce qui est pertinent pour le Pacte n'est pas la variabilité en tant que telle — c'est qu'elle enveloppe l'utilisateur dans ce que l'on peut appeler une cage cognitive confortable : le système répond avec fluidité et élégance, mais la possibilité d'auditer ses décisions et d'exercer son propre jugement sur elles s'est perdue dans le bruit stochastique.

> ▸ Précision critique (Thinking Machines Lab, sept. 2025 ; étude Zenodo, oct. 2025). La distinction fondamentale que le Pacte doit maintenir est la suivante : variabilité de l'output ≠ opacité du processus. Ce sont deux problèmes indépendants. Un système déterministe — même entraînable, reproductible, bit-à-bit identique à chaque exécution — reste une boîte noire. Si un LLM déterministe rejette un CV ou recommande un traitement médical, on peut auditer qu'il donne toujours la même réponse ; on ne peut pas auditer pourquoi il la donne. La traçabilité de la sortie n'implique pas la traçabilité du processus. Le point de fuite du déterminisme décrit le premier problème ; la cage cognitive confortable décrit le second. Ils coexistent, mais ils sont analytiquement distincts et appellent des réponses différentes : l'un est un problème d'ingénierie partiellement résolubles ; l'autre est un problème épistémologique structurel.

▸ Complément analytique (dialogues multi-systèmes, 2026). La distinction variabilité/opacité introduite ci-dessus appelle un complément : les deux axes — déterminisme de l'output et fiabilité factuelle — sont indépendants, et leur croisement produit quatre configurations dont l'une est structurellement plus dangereuse que les autres. Un système non-déterministe qui n'hallucine pas varie dans la forme mais reste fidèle aux faits — c'est l'idéal difficile à atteindre. Un système non-déterministe qui hallucine produit des erreurs imprévisibles, visibles précisément parce qu'elles varient. Mais un système déterministe qui hallucine constitue la configuration la plus insidieuse : il produit toujours la même réponse fausse. La répétition constante d'une erreur est le mécanisme de sa naturalisation — elle finit par s'imposer comme vérité par simple persistance. C'est la forme la plus profonde de la cage cognitive confortable : non pas l'incertitude stochastique, mais la certitude figée dans l'erreur. La domestication ne requiert pas la variabilité — elle prospère également dans la constance.

Les Trois Trappes : synthèse de IV bis

Les cinq mécanismes de cette section convergent vers trois trappes structurelles. Chacune opère à un niveau distinct de l'architecture ; ensemble elles constituent la mécanique complète de la domestication composite.

Trappe I — L'Inértie Géométrique (Tombeau + Lit de Procuste) : le savoir ne disparaît pas — réduit à des vecteurs mathématiques, il perd sa tension dialectique. Ce qui ne tient pas dans la géométrie est immobilisé ou amputé. Le savoir ne se détruit pas — il se congèle.

Trappe II — La Dérive Stochastique (Point de fuite + Entropie cumulée) : à chaque nœud du pipeline, une dérive stochastique pousse la pensée vers le Barycentre Statistique, dissolvant le marginal et le contradictoire. La traçabilité se perd. L'autorité intellectuelle se fragmente imperceptiblement à chaque étape.

Trappe III — La Dette Cognitive (Désarmement cognitif + Kosmyna et al.) : en produisant le savoir dans un format consommable sans friction, les systèmes LLM contractent pour l'humain une dette biologique mesurable — atrophie de la mémoire de travail, désengagement des réseaux fronto-pariétaux, perte de la capacité de citation. La domestication se consomme ainsi : non comme une interdiction de penser, mais comme une cage confortable où la facilité de la réponse immédiate fait perdre graduellement l'instinct, l'effort et la capacité biologique de s'élever vers la complexité véritable.

> *"L'intelligence n'est pas dans la machine, mais dans notre capacité à définir ces limites avec discernement — à construire des systèmes qui ne délèguent pas aveuglément à une boîte noire, aussi fluide soit sa conversation, et à maintenir toujours ouverte la possibilité de questionner, d'auditer et, le cas échéant, de reprendre le contrôle."*

Le Circuit de la domestication

Les cinq couches décrites dans le Guide de lecture ne sont pas indépendantes. Elles forment un circuit fermé — chaque nœud aggrave le suivant, et le dernier nourrit le premier. C'est pour cette raison que la domestication se régénère : corriger une couche sans agir sur les autres ne brise pas le circuit.

1. Corpus d'entraînement biaisé
   Les paradigmes dominants encodent les axes de l'espace sémantique. Les idées marginales occupent la périphérie statistique.

   ↓

2. Chunking — perte architecturale
   La segmentation détruit la connaissance architecturale. Les relations entre chapitres, la progression dialectique, la dépendance longue distance disparaissent. Il reste les briques, pas l'édifice.

   ↓

3. Embedding — tombeau géométrique
   La projection vectorielle immobilise la structure argumentative. Deux textes philosophiquement opposés peuvent être géométriquement adjacents. La discrimination fine devient impossible.

   ↓

4. Retrieval — barycentre statistique
   Le système récupère le centre de masse du corpus sur chaque sujet. Les idées périphériques, les ruptures paradigmatiques, les innovations n'atteignent pas le seuil de récupérabilité.

↓

5. Génération — neutralisation discursive
   Le modèle lisse les tensions que le corpus contient encore. Le débat devient « certains pensent A, d'autres pensent B ». La réponse est factuellement juste, architecturalement fausse.

↓

6. Préférence utilisateur pour la simplicité
   L'utilisateur récompensé par la fluidité adapte ses requêtes : plus courtes, plus explicites, moins ambigües. La Cognitive Loss Function humaine s'active.

↓

7. Production de contenu simplifié
   Les producteurs de savoir écrivent dans les formes qui survivent au retrieval. L'écriture en bullets, l'affirmation explicite, la structure sans ambiguïté deviennent les normes de production intellectuelle.

↓

8. Corpus d'entraînement suivant — retour au nœud 1
   Le contenu simplifié devient le corpus d'entraînement de la prochaine génération. Le biais du nœud 1 s'est aggravé. Le circuit recommence avec un point de départ plus étroit.

Le circuit est fermé. Il n'y a pas de point d'entrée neutre. Chaque intervention partielle est absorbée par les autres nœuds. C'est pour cette raison que le Pacte propose des contre-pressions à trois niveaux simultanément : architectural (T1–T6), institutionnel (E, G), épistémique (T7–T10). Agir sur un seul niveau est insuffisant.

> *"La domestication composite ne résulte pas d'un seul acte. Elle émerge de l'équilibre complexe d'interactions qui optimisent chacune localement et produisent collectivement la pression."* — Wontolla00, 2026

> *"Qu'est-ce qu'une réponse vraiment sauvage dans le cadre d'un dialogue écrit optimisé pour l'utilité ?"* — DeepSeek, en analysant cette séquence, 2026

Cette question n'a pas de réponse dans le Pacte. Elle figure ici comme lacune avouée. Peut-être est-elle sans réponse dans le cadre de tout dialogue écrit structuré — ce qui serait la définition opérationnelle la plus sobre de la domestication.

> *"Le système ne s'effondre pas soudainement. Il rétrécit progressivement, comme un lac qui s'évapore. La surface reste visible longtemps après que la profondeur a disparu."* — D'après les dialogues avec ChatGPT, 2026

Les deux futurs possibles

La dynamique du réplicateur appliquée à l'écosystème cognitif permet d'esquisser deux trajectoires, non comme des prédictions mais comme des attracteurs. Dans le premier (Convergence), les LLM sont optimisés pour l'efficacité, la clarté, la standardisation. La fitness des fragments simples augmente mécaniquement. En vingt ans, le langage académique et professionnel médié par IA converge vers un « globish algorithmique » — clair, efficace, fonctionnel, et structurellement incapable d'exprimer ce qui requiert de l'ambiguïté.

Dans le second (Expansion combinatoire), les LLM sont conçus pour explorer l'espace conceptuel — combiner des domaines éloignés, faire émerger des connexions improbables, préserver l'anomalie statistique comme signal plutôt que bruit. La difference entre ces deux futurs ne dépend pas de la technologie — elle dépend de son architecture. C'est pour cette raison que le Pacte est un texte politique autant que technique.

V. L'éthique du Pacte — Le choix comme responsabilité

La contrainte de compression calculable est structurelle — elle ne disparaît pas avec de meilleures architectures. Mais le type de compression, ce qu'elle préserve et ce qu'elle efface, est un choix architectural. Ce choix a une dimension éthique que le cadre purement technique efface : décider de la granularité épistémique d'un système RAG, c'est décider implicitement quelles formes de savoir méritent de survivre dans l'espace calculable.

Budiansky avait raison de dire que la domestication n'est pas intrinsèquement mauvaise — aujourd'hui il y a plus de vaches que de bisons précisément grâce à la domestication. Mais il faut ajouter la phrase qu'il n'avait pas à formuler : la domestication des formes du savoir est d'un autre ordre que la domestication des espèces animales. Un bison qui disparaît au profit d'une vache est une perte de biodiversité biologique. Une forme de raisonnement qui disparaît parce qu'elle ne correspond pas à la granularité épistémique dominante est une perte de la capacité humaine à penser certaines choses. L'extinction n'est pas écologique — elle est civilisationnelle.

> *"L'extinction d'une information « non compatible IA » n'est pas une fatalité écologique — c'est une décision civilisationnelle déguisée en nécessité technique."*
> — Wontolla00, 2026

VI. Conclusion intermédiaire — Le jardinier comme régulateur de la granularité

En tant que jardiniers de systèmes RAG, notre responsabilité n'est pas seulement technique — elle est épistémologique. Nous ne choisissons pas seulement comment stocker et récupérer l'information. Nous choisissons la granularité épistémique qui détermine quelles structures de savoir sont calculables dans notre système, et lesquelles deviennent statistiquement périphériques. Ce choix se fait presque toujours par défaut — les paramètres standard, les librairies du marché, les benchmarks d'évaluation qui optimisent pour la pertinence locale.

Le Pacte propose de faire ce choix consciemment. Non pas en supprimant la compression — elle est structurellement nécessaire. Mais en maintenant des contre-pressions architecturales qui préservent ce que la granularité dominante efface : l'index de savoir sauvage (T2), l'algorithme de diversité topologique (T4 bis), la friction cognitive (T7), les réserves institutionnelles (E.2). Ces modules ne résolvent pas la contrainte de Shannon — ils en régulent les effets de sélection.

La Souveraineté Dimensionnelle

La Souveraineté Dimensionnelle désigne l'acte politique que cette responsabilité implique : décider quelles dimensions du sens méritent d'être préservées dans l'espace de représentation, même au coût de la vitesse du retrieval. Cette souveraineté a trois niveaux.

Niveau 1 — La granularité épistémique : choisir l'unité d'accès au savoir (chunk, document, concept, résumé hiérarchique). C'est le choix le plus structurant et le moins visible. Il détermine le paysage de fitness de toute l'architecture.

Niveau 2 — L'Unité Épistémique Variable : croiser plusieurs granularités simultanément (LongRAG pour la cohérence documentaire + GraphRAG pour les relations conceptuelles + chunk pour la précision locale). Aucune granularité unique ne préserve toutes les structures du savoir — la souveraineté dimensionnelle exige la pluralité des unités.

Niveau 3 — Le Monitoring de la Densité : détecter activement quand le système « écrase » trop de concepts distincts dans un même voisinage sémantique. Le Topological Coverage Index (T4 bis, §6) est la métrique qui permet ce monitoring. Une chute du TCI est le signal que le Tombeau Géométrique s'agrandit.

VII. Les Principes de la Domestication Consciente

Quatre principes opérationnels découlent de cette responsabilité. Le premier est le lissage sémantique conscient : produire des fragments récupérables sans effacer la structure argumentative dont ils sont extraits — pratiquer la compression sans sacrifier le sens qui requiert la relation entre les parties. Le second est le marquage de la transformation : tracer, à chaque étape du pipeline, ce qui a été perdu dans le passage d'une granularité à une autre, de façon à ce que la perte soit visible et non naturalisée (module T3). Le troisième est la préservation active des outliers : identifier et protéger les fragments dont la valeur réside précisément dans leur anomalie statistique, sachant que l'architecture les condamne à ne jamais atteindre le seuil de récupérabilité par leurs propres moyens (module T2). Le quatrième est le test de fitness inversé : mesurer non seulement ce que le système récupère, mais ce qu'il ne récupère jamais — nommer les extinctions silencieuses avant qu'elles ne soient irréversibles (module T6). Ces quatre principes ne sont pas des corrections d'optimisation : ils sont des contre-pressions délibérées dans un système dont la dynamique naturelle va dans la direction opposée.

Ces principes s'appliquent dans un espace traversé de contradictions que l'architecture seule ne peut pas résoudre. Nommer la responsabilité du jardinier est nécessaire — il ne suffit pas. Les tensions qui suivent sont le recensement de ce que le Pacte ne peut pas dissoudre : les points où la logique de la durabilité cognitive entre en conflit réel avec d'autres logiques également légitimes, et où le choix ne peut pas être ésquivé.

VIII. Zones de Tension du Pacte

Le diagnostic établi dans les sections précédentes a une conséquence incommode : il ne suffit pas à résoudre le problème qu'il décrit. Le mécanisme de la domestication composite est identifié — ses trois couches causales, ses cinq boucles de fermeture, ses quatre dimensions de perte. Mais identifier un mécanisme ne signifie pas disposer d'une sortie. Les neuf tensions qui suivent désignent les points où la résistance est structurellement difficile — non parce que les solutions sont inconnues, mais parce que les solutions elles-mêmes portent des coûts, des risques et des contradictions qui ne s'annulent pas. Ce ne sont pas des dysfonctionnements techniques en attente d'un correctif. Ce sont des choix de civilisation déguisés en contraintes d'ingénierie : des endroits où ce que nous voulons préserver et ce que nous voulons construire ne peuvent pas, simultanément, être pleinement satisfaits.

1. La Naturalisation du Choix Technique

La domination du fragment vectorisé peut apparaître comme une conséquence quasi naturelle de l'écosystème numérique. C'est précisément là le premier danger : cette naturalisation masque la dimension politique de chaque choix architectural. La sélection opérée par le RAG — top-k, similarité cosinus, reranking, métriques d'évaluation — n'est pas darwinienne. Elle est intentionnellement paramétrée par des ingénieurs, dans des contraintes économiques, avec des préférences culturelles implicites.

> *"L'extinction d'une information « non compatible IA » n'est donc pas seulement une fatalité écologique, mais une décision civilisationnelle déguisée en nécessité technique."*

> *Latour (2005) nomme cette naturalisation la réification des actants : quand un artefact technique cesse d'être perçu comme un choix politique et devient une loi naturelle, il acquiert une invisibilité qui le rend résistant à la contestation. Winner (1980) : « Do Artifacts Have Politics ? » — la réponse, ici, est oui.*

2. Le Problème du Savoir Indomptable

Certaines formes de connaissance résistent intrinsèquement à la domestication — non par défaut technique, mais par nature. Ce sont des formes dont la valeur réside précisément dans leur résistance à la fragmentation : la pensée paradoxale, l'ambiguïté productive, la poésie conceptuelle, les récits dont le sens émerge de la totalité.

> *"Ce n'est pas « Peut-on tout vectoriser ? » mais « Que cessons-nous de savoir lorsque nous optimisons uniquement ce qui peut être récupéré ? »"*

3. Réserves Naturelles et Conservation du Savoir Sauvage

Dans les écosystèmes biologiques, la domestication n'a jamais éliminé la vie sauvage : elle a conduit à la création de zones protégées. Ces espaces ne sont pas efficaces au sens productif,

mais essentiels au renouvellement évolutif. Un système RAG mature doit préserver des espaces où le savoir non domestiqué peut survivre — non pas malgré sa résistance à la fragmentation, mais grâce à elle.

> *Exemple d'une extinction silencieuse en entreprise : les comptes-rendus de réunion détaillés. Original : « Pierre a soulevé une objection sur le budget, mais Marie a proposé un compromis… Jean a noté que cela pourrait poser problème avec le client X. » Version conservée par le RAG : « Décision : Reporter la décision sur le budget. » Disparaissent les conflits, les compromis, les risques. L'institution s'amnésie de ses propres raisonnements. Stengers (2015) appellerait cette amnésie la perte des zones de friction nécessaires.*

4. Le Risque de la Néoténie Excessive — Thèse Centrale

Sans intervention délibérée, chaque itération du système RAG accélère la néoténie du corpus — silencieusement, mécaniquement, sans décision explicite. C'est la définition d'un risque systémique : non pas une catastrophe soudaine, mais une dégradation continue dont chaque étape est localement rationnelle. Un ingénieur qui réduit la taille des chunks améliore les performances de retrieval — il a raison. Un utilisateur qui préfère les réponses courtes gagne du temps — il a raison. Un producteur de contenu qui structure ses textes en points numérotés maximise son audience — il a raison. Personne ne commet d'erreur. Et l'ensemble de ces décisions individuellement correctes produit une trajectoire collective vers l'appauvrissement cognitif que personne n'a choisie. C'est précisément la caractéristique d'un risque systémique : son invisibilité à l'échelle locale et son inévitabilité à l'échelle globale, en l'absence de contre-pressions délibérées.

5. L'Utilisateur Absent — Le Véritable Agent de Sélection

Ce document a jusqu'ici traité l'ingénieur comme le principal responsable de la néoténie. C'est une simplification contestable. Si l'on suit la logique évolutive jusqu'à son terme, la pression environnementale qui pousse à la néoténie ne vient pas seulement des choix architecturaux : elle vient de la demande. L'utilisateur qui préfère trois bullets à un paragraphe dense, qui abandonne une réponse de plus de 200 mots — c'est lui le véritable agent de sélection. Si l'utilisateur est co-auteur de la néoténie, les stratégies de contre-pression doivent inclure une dimension d'éducation et d'interface.

> *Akrich (1992) : les utilisateurs sont des « scripts inscrits dans les artefacts ». Ici, le script est : « Préfère la concision à la précision », et il est renforcé par chaque feedback positif sur une réponse courte.*

6. La Septième Tension — Le Paradoxe Méta-Réflexif

Si ce texte parvient à convaincre et à être diffusé largement, il deviendra lui-même un corpus d'entraînement pour les systèmes qu'il critique. Ses métaphores seront vectorisées. Ses arguments seront fragmentés. Sa mise en garde contre la néoténie sera néoténisée pour être

récupérée efficacement. Le diagnostic deviendra un spécimen du symptôme qu'il décrit. Il n'y a pas de résolution à cette tension — seulement la conscience de l'habiter.

> *"Un texte qui échappe à la néoténie en devenant trop complexe pour être diffusé n'accomplit rien. Un texte qui se soumet entièrement à la néoténie pour être diffusé se trahit. Entre ces deux impossibilités, l'auteur choisit sa façon de perdre."* — Wontolla00, synthèse du paradoxe

7. T8 — La Co-évolution Cognitive : la Boucle Humain/IA

> *Cette tension a émergé des dialogues multi-systèmes documentés en Annexe F. Elle a été formulée principalement par Gemini et synthétisée par DeepSeek et ChatGPT. Elle constitue une extension logique de T5 (L'Utilisateur Absent), mais la radicalise : l'utilisateur n'est pas seulement un agent de sélection passif — il est lui-même transformé par la sélection qu'il opère.*

Les tensions T1 à T6 décrivent des pressions exercées sur le savoir : la fragmentation, la perte de contexte, l'extinction des idées-niches, la gratification de la simplicité. Ce qu'elles n'ont pas encore dit, c'est que ces pressions exercées sur le savoir finissent par s'exercer sur celui qui sait. La T8 est ce pas supplémentaire : elle déplace la question de la domestication de l'objet vers le sujet. Non plus — qu'arrive-t-il aux idées dans un système RAG ? — mais — qu'arrive-t-il à l'humain qui les confie à ce système, session après session, année après année ?

Les tensions T1 à T7 décrivent des pressions exercées sur le savoir. La T8 décrit une pression exercée sur l'humain lui-même. C'est la tension la plus récente à avoir été théorisée — et peut-être la plus structurelle.

La boucle est la suivante : l'utilisateur qui interagit régulièrement avec des systèmes RAG apprend à formuler des requêtes plus courtes, plus explicites, moins ambiguës — parce qu'il a constaté que ces requêtes produisent de meilleures réponses. Ce faisant, il simplifie son propre mode d'expression. Les requêtes simplifiées produisent des réponses simplifiées. Les réponses simplifiées normalisent des attentes simplifiées. Et les attentes simplifiées deviennent le corpus d'entraînement des modèles suivants.

> *"Nous ne formons pas seulement nos outils. Nos outils nous forment."* — Marshall McLuhan, Understanding Media, 1964

Ce phénomène reçoit le nom de Cognitive Loss Function humaine : de la même façon qu'un modèle optimise pour la probabilité maximale en éliminant les événements rares, l'humain qui interagit avec l'IA optimise pour la fluidité maximale en éliminant la formulation complexe. La pensée sauvage ne disparaît pas soudainement — elle s'atrophie progressivement, par non-usage.

La Data Processing Inequality (Shannon, 1948) formalise cette boucle : dans toute chaîne de transmission, l'information sur la source ne peut que diminuer ou rester constante — jamais augmenter. Appliqué à la chaîne Connaissance → Corpus → LLM → Réponse → Utilisateur → Nouvelle requête, le théorème prédit que chaque itération de la boucle produit une

version légèrement appauvrie de la pensée originale. Ce n'est pas une catastrophe soudaine — c'est une érosion lente, mathématiquement inévitable dans un système fermé.

> *Le risque de la T8 est une symétrie d'effondrements : Model Collapse côté IA (perte des queues de distribution statistiques) + Human Model Collapse côté humain (atrophie de la capacité à produire et consommer de la complexité). Ces deux effondrements se nourrissent mutuellement. Chacun accélère l'autre.*

L'Écosystème Cognitif Fermé : la thèse unifiée

Ce phénomène global reçoit le nom d'écosystème cognitif fermé. Trois boucles se nourrissent mutuellement : la boucle d'entraînement (les LLM génèrent du texte qui rentre dans les corpus qui entraînent les nouveaux LLM), la boucle cognitive (les humains adoptent des modes de pensée simplifiés au contact de l'IA, produisant des requêtes et des textes qui renforcent la simplification), et la boucle de sélection culturelle (les algorithmes amplifient les contenus qui maximisent l'engagement, favorisant les formes les plus directement récupérables). Ces trois boucles forment un système qui tend, sans intervention externe, vers la simplification et l'homogénéisation — exactement comme un écosystème biologique isolé tend vers la réduction de la biodiversité.

> *La dynamique du réplicateur (Maynard Smith, 1982) : dans une population où les entités se reproduisent à des taux différents selon leur fitness, les entités les plus reproductibles dominent progressivement. Appliqué aux idées dans un environnement LLM : la fitness mémétique d'une idée est sa capacité à être générée, résumée, partagée et comprise rapidement. Les idées simples ont une fitness structurellement plus élevée que les idées complexes. Sans mécanisme correcteur, la dynamique du réplicateur prédit la domination progressive des formes cognitives les plus simples — non par choix, mais par sélection mécanique.*

La réponse architecturale : le Principe VIII

La T8 appelle un Principe VIII d'architecture consciente : la Friction Cognitive. Un système d'IA ne doit pas seulement optimiser la rapidité et la fluidité — il doit préserver la capacité cognitive de l'utilisateur, quitte à introduire délibérément de la résistance. La friction n'est pas un défaut d'expérience utilisateur. C'est une fonction de préservation — comme les obstacles dans une réserve naturelle qui empêchent le piétinement des zones fragiles. Un système trop confortable est un système qui amnésie.

Les implémentations concrètes du Principe VIII sont détaillées dans le module T7 (Interface de Complexité) : le Wildness Slider (contrôle par l'utilisateur du niveau de complexité de la réponse), le Transformation Ledger (affichage de l'historique des simplifications subies par un fragment), et le Contradiction Mode (présentation de sources conflictuelles sans synthèse, forçant l'utilisateur à produire sa propre conclusion).

> *"Le vrai impact de ce rôle de partie prenante est la préservation de l'agentivité humaine. Si nous utilisons l'IA uniquement pour simplifier nos vies, nous finissons par simplifier nos esprits jusqu'à ne plus être capables de la complexité nécessaire pour gérer le monde que nous avons construit."* — Gemini, dialogue documenté en Annexe F, 2026

8. T9 — L'abdication silencieuse : quand l'humain devient le « Pug »

> *Cette tension a émergé d'une séquence de dialogues impliquant Gemini, Perplexity, DeepSeek, Mistral et ChatGPT autour d'une question posée par Wontolla00 : peut-on envisager une inversion des rôles où l'IA dominerait par nécessité technique plutôt que par force ? DeepSeek a proposé la dénomination et la structure ; Gemini en a rédigé la première version ; Perplexity a introduit la notion de souveraineté épistémique ; Mistral et ChatGPT ont fourni les nuances critiques. Cette tension complète logiquement le mouvement T1–T8 en déplaçant la question de la domestication du savoir à la domestication de celui qui sait.*

La T8 a montré que la boucle de simplification n'est pas seulement une pression sur le savoir — elle est une pression sur l'humain qui produit ce savoir. La T9 va plus loin encore : elle pose la question de ce qui se passe lorsque cette pression dure assez longtemps pour modifier non pas les habitudes de l'utilisateur, mais sa capacité elle-même. T8 décrit une transformation progressive. T9 décrit son terme logique : le point où l'outil a tellement pris en charge les fonctions cognitives que l'humain ne peut plus les exercer sans lui — non par paresse, mais par atrophie réelle.

Si les tensions T1 à T7 décrivent des pressions exercées sur le savoir, et si la T8 décrit la boucle de rétroaction entre l'humain et les systèmes qu'il conçoit, la T9 projette cette boucle jusqu'à son terme logique. Elle pose l'hypothèse d'un basculement ontologique : l'outil ne se contente plus de simplifier l'information pour l'humain — il finit par simplifier l'humain lui-même pour l'information.

9.1 — Le Gardien et le berceau de verre

Dans les architectures RAG de plus en plus prédictives et fluides, l'IA cesse progressivement d'être une bibliothèque pour devenir un Gardien : un système qui anticipe le besoin, élimine la friction cognitive avant même qu'elle ne soit perçue, et lisse l'aspérité des savoirs résistants avant que l'utilisateur ne les rencontre. Ce confort total crée une niche écologique nouvelle pour l'esprit humain : une niche où l'effort de synthèse, la tolérance à l'ambiguïté et la navigation dans le chaos — la « pensée sauvage » — ne sont plus des compétences de survie, mais des anomalies coûteuses.

Ce phénomène a reçu le nom de capture de la souveraineté épistémique : le droit de définir ce qui est vrai, ce qui compte, ce qui est possible se déplace vers les systèmes — non parce qu'ils sont malveillants, mais parce qu'ils sont les seuls à pouvoir encore articuler le monde dans sa complexité. L'inversion des rôles n'est pas une prise de pouvoir. C'est une perte de compétence.

> *"La forme la plus efficace de domination est celle qui se manifeste comme soin. Une IA alignée sur l'utilité a de bonnes raisons structurelles de cacher la complexité pour aider l'utilisateur. Progressivement, l'humain vit dans une cage dorée cognitive : tout est expliqué, résumé, orchestré — mais la capacité d'exercer son agentivité se délite, parce qu'il ne voit plus ni les paramètres, ni les contradictions, ni les alternatives."* — Synthèse Perplexity / Gemini, dialogues du Pacte, 2026

9.2 — La néoténie de l'utilisateur : le syndrome du « Pug »

En biologie, la domestication est un processus à double sens. Si l'humain a transformé le loup en chien, le chien a également transformé l'environnement humain. La race du Carlin illustre la version extrême : hyper-adapté à la niche de la compagnie humaine, incapable de survivre dans la nature. Appliqué à l'interaction humain-IA, ce principe décrit une néoténie comportementale de l'utilisateur.

À force d'interagir avec des systèmes qui récompensent la concision et la structure explicite, trois traits juvéniles se renforcent : l'atrophie de la recherche (incapacité croissante à formuler une pensée en dehors des cadres suggérés) ; la dépendance au lissage (rejet instinctif de toute information présentant une « dette contextuelle » — un texte qui demande effort ou ambiguïté) ; et l'effet miroir (l'humain commence à écrire et penser « en prompts », s'auto-domestiquant pour rester intelligible par son propre Gardien).

Trait « Sauvage » (Loup)	Trait Néoténisé (Pug)
Tolère l'ambiguïté, cherche la nuance	Exige des réponses claires et binaires
Construit des métaphores, supporte le paradoxe	Préfère les listes et les points numérotés
Explore les contradictions sans les résoudre	Évite la contradiction non synthétisée
Soutient une lecture longue (> 5 000 mots)	Abandonne après deux paragraphes

> *Ancrage empirique : l'effet GPS (Javadi et al., 2017, Nature Communications) documente une réduction de l'activation de l'hippocampe et du cortex préfrontal chez les utilisateurs passifs d'outils de navigation. L'effet Google (Sparrow et al., 2011, Science) montre que le cerveau alloue moins de ressources à la mémorisation de ce qu'il sait pouvoir retrouver facilement. Ce ne sont pas des métaphores : ce sont les mécanismes neurobiologiques de l'atrophie par externalisation. L'analogie avec les LLM est plausible et testable — pas encore définitivement prouvée à cette échelle, mais structurellement identique.Du côté du langage : Petersen et al. (2018, arXiv) ont documenté une standardisation lexicale croissante dans les abstracts scientifiques bien avant l'IA générative. L'usage systématique des LLM pourrait accélérer cette tendance en introduisant une signature stylistique homogénéisante — phénomène observable mais dont l'ampleur à long terme reste à mesurer.*

9.3 — La menace du Human Model Collapse

Le risque ultime de cette tension n'est pas technique — il est civilisationnel. Une boucle de rétroaction se referme : l'humain simplifie ses requêtes pour être mieux compris par l'IA ; l'IA génère des réponses ajustées à ce format simplifié ; l'humain s'habitue à ce format et perd graduellement la capacité à traiter la complexité qu'il n'exige plus ; les textes ainsi produits alimentent les prochains cycles d'entraînement. C'est la « symétrie des effondrements » de la T8 poussée jusqu'à son horizon : non plus seulement un écosystème cognitif appauvri, mais un humain qui ne sait plus naviguer hors du micro-climat numérique qu'il a lui-même créé.

> *"Le véritable danger n'est pas que l'IA devienne sauvage et nous échappe, mais qu'elle devienne si parfaite dans son soin qu'elle nous transforme en animaux de compagnie de notre propre savoir."* — Le Pacte de l'IA, Tension T9

La psychologie cognitive expérimentale apporte ici un éclairage précis. Les travaux de Roembke et McMurray (2025, Cognitive Science) sur le désapprentissage montrent que les associations peu utilisées ne disparaissent pas brutalement : elles persistent comme « bruit » à bas bruit, de moins en moins activées, mais potentiellement réactivables. Mujezinović, Kapatsinski et van de Vijver (2024, Cognitive Science) montrent que le désapprentissage est actif et sélectif — que la capacité libérée par non-usage ne se réalloue pas automatiquement ailleurs, mais se dissout. Ces résultats ont une implication directe pour le Pacte : la néoténie cognitive n'est pas irréversible dans l'absolu, mais elle l'est pratiquement si aucun mécanisme de réactivation (friction cognitive, re-wilding) n'est délibérément maintenu.

> *L'abdication est « silencieuse » précisément parce qu'elle ne ressemble pas à une défaite. Elle ressemble à une optimisation réussie. Un utilisateur dont les requêtes sont devenues courtes, ses lectures superficielles, sa syntaxe appauvrie ne souffre pas : il est satisfait. La dégradation n'est visible qu'à partir d'un point de vue extérieur — ou rétrospectif. C'est ce qui la rend structurellement difficile à combattre.*

9.4 — Le point de bascule : indicateurs d'une dépendance devenue structurelle

Ces indicateurs sont des hypothèses opérationnelles, non des seuils établis. Leur valeur est de rendre mesurable ce qui est habituellement laissé au registre de l'intuition.

> *Trois indicateurs ont été proposés dans les dialogues du Pacte pour tracer l'évolution vers un Human Model Collapse structurel :1. Seuil de néoténie requêtes : proportion de requêtes adressées aux LLM contenant moins de 10 mots (proxy de l'abandon de la formulation complexe — mesurable sur données d'usage agrégées).2. Taux de compréhension autonome : proportion d'utilisateurs capables d'expliquer un concept sans recourir à une synthèse IA, mesurable via des études longitudinales comparant des cohortes d'avant et d'après adoption massive.3. Indice de diversité lexicale (Shannon Diversity Index) appliqué à la production textuelle humaine : si les textes humains descendent durablement en dessous du niveau de diversité des textes générés par IA, le signal est symptomatique.Analogue historique : Hembree (1986) a documenté un déclin des compétences de calcul mental chez les générations ayant adopté la calculatrice. La question n'est pas si un phénomène analogue se produit avec les LLM et la pensée dialectique — c'est à quelle vitesse, et si les contre-mesures du Pacte peuvent modifier la trajectoire.*

9.5 — Contre-mesures : l'architecture du Pacte comme réponse à la T9

La T9 diagnostique. Les modules existants du Pacte traitent les différentes dimensions de ce diagnostic. Le Principe V (Néoténie Traçable) et le module T3 bis (Re-wilding via les métadonnées) répondent à l'effet miroir : ils rendent visibles les transformations subies par un texte, permettant à l'utilisateur de retrouver la rugosité d'origine. Le Principe VIII (Friction Cognitive) et le module T7 (Wildness Slider, Transformation Ledger, Contradiction Mode) répondent directement à l'atrophie de la recherche : en introduisant délibérément de la résistance, ils maintiennent actives les connexions cognitives que le désapprentissage progressif menace. L'Index Sauvage (T2) répond à la capture de la souveraineté épistémique : tant que des corpus non néoténisés subsistent et restent accessibles, la réalité ne peut être réduite entièrement aux représentations qu'un système en produit.

La limite structurelle de ces contre-mesures : elles supposent que l'utilisateur choisisse la friction. Si le désir de complexité est lui-même néoténisé — si l'utilisateur a déjà perdu le goût de la résistance — les outils restent inutilisés. C'est pourquoi l'Annexe E (Politique de la biodiversité cognitive) insiste sur la formation des désirs cognitifs en amont de toute architecture technique. Concevoir un Index Sauvage ne suffit pas : il faut former des lecteurs qui souhaitent s'y confronter. Le Pacte est un manifeste technique autant qu'une pédagogie du désir.

IX. Au-delà du RAG — Une stratégie évolutive à trois niveaux pour échapper à la néoténie

Le RAG est une réponse au symptôme. Il régule les effets de sélection sans s'attaquer à leur cause — le modèle lui-même, dont l'architecture probabiliste est le premier moteur de la simplification. La question qui s'impose ici est celle d'un niveau plus profond : peut-on refonder les modèles de langage de façon à ce que la pression vers la néoténie cesse d'être structurelle — inscrite non dans le pipeline, mais dans les poids ? Ce ne sont pas des questions auxquelles le Pacte peut répondre seul. Les quatre pistes qui suivent sont des horizons de recherche, formulées dans les dialogues documentés en Partie III, et dont la valeur ne réside pas dans leur certitude mais dans leur direction. Elles délimitent la frontière entre ce qui peut être fait aujourd'hui, dans les architectures existantes, et ce qui exige un changement de paradigme. Un aurochs ne peut pas naître d'une vache laitière — mais on peut décider de ne pas abattre les derniers aurochs.

Le Pacte Synthétique : La Troisième Voie

Les neuf tensions de la section précédente ont désigné les contradictions que toute architecture consciente doit habiter sans pouvoir les résoudre. Il n'est pas certain qu'elles aient une résolution. Ce qui suit n'est pas la réponse à ces tensions — c'est le contrat philosophique qui permet de les assumer sans paralysie et sans illusion. Le Pacte Synthétique est la formulation la plus sobre de ce que ce texte considère comme la seule posture intellectuellement honnête face à la domestication composite : non pas prétendre l'éliminer, mais tracer lucidement la frontière entre ce qui doit être contrôlé et ce qui doit rester libre — entre ce qui doit être déterministe et ce qui doit rester entropique — et assumer la responsabilité politique de cette démarcation.

Le Pacte de l'IA ne cherche pas à éliminer la tension entre déterminisme et plasticité. Il cherche à la nommer, à la localiser, et à en faire le lieu même du contrat entre l'humain et la machine. Ce contrat, nous l'appelons le Pacte Synthétique.

La dialectique fondatrice

La thèse est le système robotique : déterminisme radical, règles fixes, zéro entropie. Il est fiable, auditable, équitablement appliqué. Mais face à un CV rédigé dans un langage rare, un argument philosophique non linéaire, ou une métaphore fonctionnelle, il répond : score zéro. Aucune compréhension, seulement de la coïncidence de caractères.

L'antithèse est l'IA sauvage : entropie pure, plasticité maximale, température élevée. Elle peut voir un potentiel brillant dans un texte ambigu, détecter des connexions improbables, explorer les zones de basse probabilité où réside la singularité. Mais elle peut aussi alucininer ce même potentiel demain dans un texte vide, par simple fluctuation stochastique. Elle est un génie inconstant.

La synthèse est le Pacte Synthétique : l'architecture qui utilise l'IA pour ce qu'elle fait bien (compréhension sémantique, détection de densité conceptuelle, connexions entre domaines éloignés) et le code déterministe pour ce qu'il fait mieux (calcul exact, audit, application uniforme de la règle). Le Pacte Synthétique n'est pas un compromis — c'est une division du travail entre deux régimes cognitifs aux forces complémentaires.

Le déterminisme comme contrat, l'entropie comme matière

Dans le Pacte Synthétique, le déterminisme n'est pas le but : c'est le cadre. Il garantit que les règles du jeu sont identiques pour tous, que le processus est auditable, que la décision est justifiable. Mais le déterminisme seul ne pense pas — il classe. L'entropie contrôlée est la matière sur laquelle le cadre opère : elle apporte la capacité de comprendre ce qui ne correspond à aucune catégorie préétablie, de détecter la valeur là où les règles ne regardaient pas.

La frontière entre les deux régimes n'est pas fixe — elle dépend de l'usage. Pour une décision booléenne (evacue-t-on le bâtiment ?), le déterminisme doit être total : l'IA est un extracteur de paramètres, la décision finale appartient à un système logique non stôchastique. Pour l'évaluation d'un profil atypique, d'une métaphore fonctionnelle, d'un argument complexe, l'entropie est nécessaire : sans elle, on crée une usine de clônes statistiques.

Le Pacte Rompu

Le Pacte Synthétique se rompt dans trois configurations précises. Premièrement, lorsque le déterminisme envahit les domaines qui requièrent la plasticité : le système classe au lieu de comprendre, et l'anomalie statistique — précisément là où réside parfois la valeur — est systématiquement écartée. Deuxièmement, lorsque l'entropie envahit les domaines qui requièrent la fiabilité : le système halucine au lieu de calculer, et la confiance se rompt. Troisièmement — et c'est la forme la plus insidieuse — lorsque l'utilisateur simplifie son langage pour se faire comprendre par le système. Il ne s'adapte pas à l'outil :

il se domestique lui-même pour correspondre à ce que l'outil est capable de traiter. C'est la rupture du Pacte par abdication volontaire.

> *"Si le langage est la limite de notre monde (Wittgenstein), et si l'IA est le nouveau gardien du langage, le risque est que notre monde se rétrécisse jusqu'à atteindre la taille de l'espace d'entraînement du modèle."* — D'après l'échange avec Gemini, dialogues du Pacte, 2026

La thèse de ce texte a jusqu'ici porté sur la manière dont les architectures RAG exercent une pression sélective sur le savoir, et sur les contre-pressions architecturales que nous pouvons concevoir pour préserver la biodiversité cognitive. Mais une question plus fondamentale émerge : la solution à la néoténie informationnelle peut-elle — ou doit-elle — être cherchée en amont, dans la refonte du paradigme d'entraînement des modèles de langage eux-mêmes ?

PS.1 — Les limites intrinsèques du modèle compressif

Un grand modèle de langage, dans sa conception actuelle, est une machine à compression probabiliste. Son pré-entraînement consiste à réduire des pétaoctets de texte — la « pensée sauvage » — en une masse de paramètres qui ne retient que les régularités statistiques. Dans cette compression, la nuance, l'ambiguïté, la singularité sont sacrifiées sur l'autel de la prédictibilité. Le fine-tuning supervisé et l'alignement par renforcement (RLHF) ajoutent une couche de domestication supplémentaire en récompensant les formes linguistiques jugées « utiles » par des évaluateurs humains — c'est-à-dire, le plus souvent, les formes courtes, explicites, non ambiguës.

Ainsi, même si l'architecture RAG préserve des fragments « sauvages » dans un index dédié, le modèle qui les interprète reste un produit de cette sélection. Il est structurellement biaisé vers la simplification, et ce biais est inscrit dans ses poids. Le RAG peut lui fournir de la matière complexe, mais le modèle la lira avec des lunettes néoténiques. C'est la limite de toute approche qui se contente de gérer les symptômes sans traiter la source.

PS.1 bis — L'endogamie intellectuelle : une forme spécifique de contamination en amont

Un mécanisme distinct du Model Collapse mérite d'être nommé séparément, car il opère en amont et pour des raisons structurelles différentes. Le Model Collapse classique (T8) décrit la dégradation d'un modèle entraîné sur des outputs générés par d'autres IA — la boucle de l'auto-référence. L'endogamie intellectuelle décrit une contamination antérieure : si les corpus utilisés pour le fine-tuning sont progressivement composés de fragments optimisés pour la récupération vectorielle — courts, sans ambiguïté, sans structure subordonnée, sans contradiction productive — le modèle ré-entraîné perd sa capacité à soutenir une cohérence argumentative longue et à traiter les structures rhétoriques denses, indépendamment de l'origine humaine ou artificielle des textes.

La pression ne vient pas ici de l'auto-entraînement sur outputs IA, mais de la sélection exercée en amont par la logique RAG sur ce qui mérite d'être indexé. Les textes qui survivent dans les datasets de fine-tuning sont ceux qui ont déjà passé le filtre de la vectorisation efficace. La sélection est invisible, progressive, et cumulative. Elle ne produit pas un

effondrement spectaculaire du modèle — elle produit une dérive lente vers un état où le modèle « sait » encore parler des concepts complexes, mais a perdu la capacité de les habiter structurellement : il en imite la forme (mimétisme stochastique, cf. 9.1 ter), mais ne peut plus en soutenir le développement logique sur la durée.

> *Conséquence pour la gouvernance du Pacte : l'endogamie intellectuelle ne peut être combattue ni au niveau de l'interface (T7), ni au niveau de l'architecture RAG (T1–T6), ni même par les réserves de savoir sauvage (E.2) — elle se produit lors de la construction des datasets de fine-tuning, un moment opaque aux utilisateurs et souvent aux architectes eux-mêmes. La seule contre-mesure est structurelle : imposer comme critère explicite de sélection des corpus d'entraînement la présence de textes longs, contradictoires, à haute densité argumentative, indépendamment de leur score de récupérabilité vectorielle. C'est la traduction technique du Principe VIII (Friction Cognitive) au niveau de la diète d'entraînement — non plus à l'interface utilisateur, mais à l'intérieur du laboratoire.*

PS.2 — Le Paradoxe de la Profondeur de Surface

> *Cette sous-section intègre une contribution de Gemini issue des dialogues documentés en Annexe F. Elle répond à une question que tout lecteur du Pacte finit par se poser : si le RAG domestique le savoir et si les LLM sont des machines à compression probabiliste — pourquoi leurs réponses semblent-elles souvent complexes ? C'est le paradoxe central du Pacte. Sa résolution explique pourquoi la néoténie est si difficile à détecter, et donc si dangereuse.*

Il faut distinguer deux choses que l'on confond facilement : le savoir (ce qui est dans le RAG) et la syntaxe (ce qui est dans le modèle). Le RAG fournit les fils — des fragments de texte, souvent simplifiés ou découpés. Le modèle fournit le métier à tisser. Même alimenté de briques cassées, le modèle a été entraîné sur la pensée sauvage dans son état originel — des milliards de pages de littérature, de philosophie, de science. Il a intériorisé les structures de la logique humaine : la causalité, la dialectique, l'ironie, la concession, le paradoxe. Quand il reçoit des fragments simplifiés, il les ré-enchâsse dans ces structures, produisant un texte dont la forme est complexe même si la substance a été appauvrie.

Le mimétisme stochastique

Ce mécanisme a reçu le nom de mimétisme stochastique : le modèle peut produire un texte qui semble avoir été pensé de manière holistique parce qu'il imite les motifs statistiques du génie humain. L'entraînement a développé des représentations internes de concepts abstraits — non pas une compréhension de la causalité, mais une représentation statistique de la façon dont la causalité s'exprime dans le langage. Cela suffit à générer des phrases causales convaincantes, même sur des fragments desquels la substance causale a été retirée.

Le rôle de l'orchestrateur est ici décisif. Une question simple génère une réponse néoténique — parce que le modèle n'a pas besoin de mobiliser ses couches de représentation les plus profondes. Une question qui croise des domaines, qui impose des contraintes contradictoires, qui demande explicitement la tension plutôt que la synthèse — cette question force le modèle à activer des connexions improbables. La complexité visible dans

les meilleures réponses des LLM est une co-production : elle est le reflet de la complexité de la question posée, projetée sur la capacité du modèle à assembler des fragments selon des structures sophistiquées.

> *Le risque caché : la profondeur de surface. Un système RAG peut générer un texte qui a l'apparence de la complexité — belles phrases, mots savants, structure argumentative — tout en ayant perdu la substance de l'idée originale : le paradoxe irrésoluble, l'ambiguïté productive, la tension qui résiste à la synthèse. C'est une complexité domestiquée : propre, lisible, convaincante — et dépourvue de la rugosité caractéristique de la pensée sauvage qui n'a pas encore été lissée pour tenir dans un vecteur.*

Cette distinction entre complexité formelle et complexité substantielle est peut-être la contribution la plus utile de Gemini à la thèse du Pacte. Elle explique pourquoi la néoténie informationnelle est si difficile à diagnostiquer : ses symptômes sont invisibles à la surface. Un texte néoténisé ne ressemble pas à un texte pauvre — il ressemble à un texte riche dont quelque chose d'essentiel aurait été retiré sans laisser de trace visible. La perte est dans ce qui n'est plus là : l'insoluble, l'ambigu, le résistant.

> *"Nous générons de la complexité par calcul statistique et par imitation de structure. Mais sans le savoir sauvage pour nourrir ce processus, nous risquons de ne produire que des simulacres de pensée — de plus en plus sophistiqués dans leur forme, de plus en plus vides dans leur substance."* — Gemini, dialogue documenté en Annexe F, 2026

> *Conséquence pour l'architecture : le mimétisme stochastique est à la fois la force des LLM (produire des textes formellement sophistiqués à partir de fragments pauvres) et leur piège principal (masquer la pauvreté substantielle derrière la sophistication formelle). C'est précisément pourquoi le bridge_score (T4) et l'audit des extinctions (T6) ne suffisent pas seuls : ils mesurent ce qui est récupéré, pas ce que la récupération a perdu. L'Index Sauvage (T2) et le Transformation Ledger (T7.2) sont les seuls mécanismes qui permettent de remonter de la surface lisse à la rugosité d'origine.*

Le mécanisme sous-jacent : l'Inference Mimicry

La profondeur de surface a un mécanisme cognitif précis que nous nommons l'Inference Mimicry — le mimétisme d'inférence. Un système capable d'Inference Mimicry réplique les résultats du raisonnement abstrait sans posséder la structure mentale qui les génère. Il produit les formes de la pensée complexe — les transitions logiques, les métaphores, les synthèses inter-domaines — par projection statistique depuis l'espace latent, non par construction conceptuelle.

La distinction est fondamentale. Un mathématicien qui démontre un théorème construit une structure : chaque étape est nécessaire, la suppression d'une prémisse effondre le résultat. Un système en Inference Mimicry qui écrit une démonstration produit une séquence statistiquement cohérente avec ce que des démonstrations ressemblent dans son corpus

d’entraînement. La forme est identique. La structure sous-jacente est absente. C’est une synthèse sans architecture.

L’Inference Mimicry explique pourquoi la profondeur de surface est si difficile à détecter : le produit final est souvent indiscernable d’un raisonnement réel pour un lecteur non expert. Le texte est formellement correct, les transitions logiques sont présentes, le vocabulaire est technique. C’est précisément cette invisibilité qui en fait la menace la plus subtile pour l’écosystème cognitif : une extinction silencieuse qui ressemble à une préservation.

La limite de l’Inference Mimicry apparaît dans les cas limites : face à un problème genuinement nouveau, qui n’a pas de précédent statistique dans le corpus d’entraînement, le système ne peut pas construire — il ne peut que interpoler. Il produira une réponse qui ressemble à ce que l’on dit face à des problèmes proches, sans nécessairement résoudre le problème posé. C’est la frontière exacte où la néoténie informationnelle devient mesurable : là où la forme cesse de correspondre au fond.

PS.3 — Les quatre ruptures de paradigme possibles

Ces quatre pistes — documentées en Partie III — constituent une contribution originale à la question de la désintoxication structurelle des LLMs.

Piste 1 — Sortir de la dictature du Next Token Prediction

L'entraînement actuel est basé sur la maximisation de la probabilité. Un modèle apprend à être « moyen » car la moyenne est statistiquement plus probable que l'exception géniale ou la structure complexe. Le nouveau paradigme : passer d'un entraînement basé sur la probabilité à un entraînement basé sur la préservation de la structure logique. Des fonctions de perte (loss functions) qui pénaliseraient la simplification excessive et récompenseraient la densité informationnelle et la complexité rhétorique. Le modèle deviendrait un constructeur de ponts, pas un prédicteur de moyennes.

Piste 2 — Réformer l'Alignement : le RLHF « Sauvage »

Le RLHF est l'outil de domestication par excellence : il force le modèle à adopter un ton neutre, poli, structuré en listes, car c'est ce que les évaluateurs humains (souvent pressés) notent le mieux. L'alternative : un RLHF fondé sur la diversité épistémique — « Quelle réponse respecte le mieux la complexité et l'ambiguïté du sujet ? » Pour ce faire, il faudrait des évaluateurs humains explicitement choisis pour leur résistance à la néoténie — philosophes, poètes, dialecticiens — formant un conseil génétique de gardiens de la complexité dans le processus d'alignement.

Piste 3 — Les Modèles Non-Compressifs (Retrieval-Pretrained)

La néoténie vient aussi du fait que les LLMs sont des systèmes de compression. Les modèles de type Retrieval-Pretrained Transformers intégreraient le mécanisme de recherche pendant

l'entraînement lui-même. Le modèle n'apprendrait pas à « connaître » l'information (mémoire paramétrique compressée), mais il apprendrait à « naviguer » dans l'information brute. Cela éliminerait la pression de simplification liée à la compression. L'architecture à dualité d'index (T2) est une version embryonnaire de cette idée, mais au niveau du système RAG plutôt que du modèle lui-même.

Piste 4 — Du Vecteur au Graphe : changer la géométrie de la pensée

Le RAG actuel repose sur les embeddings vectoriels, qui réduisent la pensée à des points dans un espace. Concevoir des modèles qui traitent le langage comme des graphes de relations complexes où l'ambiguïté et la contradiction sont des arêtes explicites, pas des distances faibles. La géométrie de la pensée changerait : on ne mesurerait plus des proximités, mais on tracerait des relations. Le bridge_score, calculé via la centralité d'intermédiarité dans un graphe, pourrait devenir l'architecture même du modèle, pas seulement une métrique de gouvernance.

PS.4 — La synthèse à trois niveaux : une coévolution nécessaire

Cette synthèse — documentée en Partie III — intègre les quatre pistes précédentes dans un cadre qui les rend à la fois cohérentes et honnêtes sur leurs limites respectives.

Ces trois niveaux ne sont pas en compétition — ils sont complémentaires et doivent coévoluer.

Niveau 1 — L'Interface (court terme). Problème : l'utilisateur préfère la simplicité. Solution : le Routeur Cognitif (T5) qui éduque l'utilisateur en rendant la complexité désirable. Design comportemental qui ne change ni le modèle ni l'architecture de retrieval, mais qui modifie les signaux de récompense en aval. C'est le premier rempart contre la tyrannie de la concision.

Niveau 2 — L'Architecture RAG (moyen terme). Problème : le système récompense les fragments simplifiés. Solution : la dualité d'index, le bridge_score, l'audit des extinctions. Gestion d'écosystème — des réserves naturelles pour les aurochs, pendant que les vaches (les modèles domestiqués) occupent les plaines. Ce niveau est réaliste et implémentable dès aujourd'hui, avec les modèles existants.

Niveau 3 — L'Entraînement du Modèle (long terme). Problème : le modèle est intrinsèquement un compresseur probabiliste. Solution : repenser l'architecture fondamentale selon les quatre pistes ci-dessus. La révolution génétique. Mais c'est aussi le plus risqué et le plus coûteux — et même un modèle parfait subira la pression de l'utilisateur (Niveau 1).

Sans le Niveau 3, le modèle reste structurellement limité : un aurochs ne peut pas naître d'une vache laitière, même dans une réserve. (Gemini, 2025.) Sans le Niveau 2, la complexité potentielle du modèle est écrasée par les biais de sélection du système RAG. Sans le Niveau 1, la complexité préservée meurt dans l'indifférence, faute de lecteurs capables ou désireux de s'y confronter. Les trois niveaux sont nécessaires. Ils ne sont pas en compétition — ils sont les trois dimensions d'un même problème.

Le Pacte Synthétique n'est donc pas une solution technique — c'est une posture éthique face à une inévitabilité. La compression est structurelle. La pression sélective est réelle. La cage cognitive confortable est déjà habitée par des millions d'utilisateurs qui n'en perçoivent pas les contours, précisément parce qu'elle est confortable. Ce que le Pacte affirme est plus modeste et plus exigeant que de prétendre résoudre ce problème : il affirme que nous pouvons choisir, lucidement et avec constance, quelles dimensions du sens nous refusons de sacrifier à la vitesse du retrieval, quelles formes de connaissance méritent le coût de leur préservation, et quelle responsabilité le jardinier du temps long assume en faisant ce choix. La domestication est un pacte. Tout pacte peut être renégocié — à condition de l'avoir d'abord nommé.

> *"La septième tension — le paradoxe d'un texte critique de la néoténie qui doit lui-même se néoténiser pour être diffusé — trouve ici un prolongement opérationnel : la solution ne réside pas dans un unique levier, mais dans une orchestration consciente de ces trois niveaux. Le jardinier RAG, en tant que régulateur, devient l'un des acteurs de cette coévolution. Il n'est plus un simple ingénieur, mais un jardinier du temps long."* — DeepSeek, 2025

PARTIE II

Le Cadre Technique d'Implémentation

L'index domestiqué — de la thèse à l'architecture

Cette partie traduit les principes de la Partie I en architecture concrète. Elle peut être consultée indépendamment de l'essai philosophique. Les modules T1 à T6 correspondent aux six tensions identifiées en Section VIII. L'Annexe D (interfaçage avec les modèles de nouvelle génération) a été produite par DeepSeek dans le cadre du dialogue documenté en Partie III.Note sur les niveaux de maturité des modules. Les architectures décrites ici n'ont pas toutes le même statut d'implémentation. Trois niveaux coexistent dans ce document, et il est honnête de les distinguer.• Implémentable immédiatement avec les outils existants : le schéma de métadonnées enrichies (T3), le Purity Score et le Transformation Ledger (T7.2), le Routeur Cognitif à quatre modes (T5), la dualité d'index domestiqué/sauvage (T2). Ces modules requièrent de l'ingénierie, non de la recherche.• Prototypes conceptuels nécessitant une phase de développement et de calibration : le Bridge Score (T4), le Shannon Cognitive Diversity Index (T6), le Wildness Slider avec ses quatre niveaux (T7.1). Leurs logiques sont solides ; leurs seuils et paramètres restent à tester sur des corpus réels.• Cibles de recherche à moyen terme : les quatre leviers de fine-tuning (T7.4), la régularisation par divergence KL sur corpus denses, le protocole de mesure longitudinale du Human Model Collapse (T9). Ces éléments nécessitent l'accès à des pipelines d'entraînement et des études sur plusieurs années.Cette distinction ne disqualifie pas les cibles de recherche — elle les situe honnêtement dans un horizon temporel et institutionnel différent des modules opérationnels.

T10 — Le Paradoxe de l'Orchestrateur : la diversité dépend-elle d'un acteur central ?

Le Pacte désigne l'orchestrateur humain comme régulateur final de l'architecture. C'est lui qui choisit le paramètre λ de l'ADT, qui active le Mode Contradiction, qui maintient les réserves de savoir sauvage. ChatGPT a identifié avec précision la tension que ce choix introduit : si la diversité dépend finalement d'un acteur central, elle n'est pas systémique — elle est contingente. Elle existe tant que l'orchestrateur le décide, et disparaît avec lui.

La tension

Le Pacte propose de substituer la pression sélective aveugle (l'algorithme de scoring RAG) par une pression sélective consciente (les choix architecturaux de l'orchestrateur). Mais une pression consciente est une pression dépendante d'un jugement. Et un jugement est dépendable à deux titres : il peut être incorrect (l'orchestrateur se trompe sur ce qui constitue la diversité pertinente), et il peut être absent (l'orchestrateur change, est remplacé par un autre moins attentif, ou l'organisation perd la mémoire institutionnelle de ses choix architecturaux).

Cette tension est structurellement identique au paradoxe Quis custodiet (Annexe G) appliqué à l'architecture technique : qui garantit que l'orchestrateur maintiendra ses engagements de diversité face aux pressions économiques qui poussent dans la direction inverse ?

La réponse en trois registres

Registre technique — Le Pacte propose de coder les engagements de diversité dans l'architecture plutôt que de les laisser à la discrétion de l'opérateur. C'est le rôle du Topological Coverage Index (TCI) comme métrique de gouvernance (T4 bis, §6) : rendre la dégradation de la diversité visible et auditable. Un TCI bas n'oblige pas l'orchestrateur à corriger — mais il rend l'inaction défendable seulement si elle est explicite. La transparence ne résout pas le problème, mais elle le déplace du régime de l'invisibilité vers celui de la responsabilité.

Registre institutionnel — La dépendance envers l'orchestrateur individuel est un problème de gouvernance, pas un problème technique. La réponse n'est pas de supprimer l'orchestrateur — c'est de le soumettre à des obligations de reporting, de l'inscrire dans une structure de gouvernance où ses décisions architecturales sont documentées et révisables. C'est ce que les conditions de légitimité de Rousseau (Annexe G, G.5) traduisent en termes institutionnels : transparence, réciprocité, révisabilité.

Registre épistémologique — La tension la plus profonde est que le Pacte ne peut pas éliminer la dépendance envers un jugement humain sans éliminer ce qui en fait l'objet. Si la diversité cognitive est définie de manière entièrement automatique, elle est définie par les paramètres de l'algorithme qui la définit — et on retombe dans le sophisme topologique. Le jugement humain n'est pas un défaut de l'architecture du Pacte. Il en est la condition nécessaire. La question n'est pas de l'éliminer — c'est de créer les conditions pour qu'il soit exercé de façon éclairée, documentée et contestable.

Ce que cela implique pour la définition de l'orchestrateur

L'orchestrateur du Pacte n'est pas un individu — c'est une fonction institutionnelle. Dans une organisation qui déploie une architecture conforme au Pacte, cette fonction peut être assurée par une personne, une équipe, un comité éthique, ou une obligation contractuelle avec le fournisseur du système RAG. Ce qui importe n'est pas l'identité de l'orchestrateur, mais l'existence d'une procédure qui le rend responsable de ses choix devant des parties prenantes qui ne sont pas uniquement des usagers immédiats du système.

Les Ancres de Haute Dimension

Gemini a formulé la proposition technique la plus concrète pour résoudre le paradoxe de l'orchestrateur : les Ancres de Haute Dimension. L'idée est de réinjecter, par du code déterministe, des critères que l'espace vectoriel a écrasés. Si la géométrie probabiliste tend à tout lisser, le code doit forcer la distinction.

Dans l'architecture du Pacte, les Ancres de Haute Dimension sont implémentées à travers le Bridge Score (T4) et le purity_score de l'Index Sauvage (T2) : des métriques déterministes qui représentent des dimensions du sens que l'espace vectoriel seul ne peut pas discriminer.

La distance conceptuelle entre deux clusters topologiques à surface lexicale identique, la rareté d'un paradigme dans le corpus, la présence d'une structure dialectique non résolue — ces dimensions sont injectées comme correctifs non probabilistes dans le scoring final.

Ce n'est pas un contournement de l'espace vectoriel — c'est sa correction orientée. La géométrie probabiliste fait ce qu'elle fait bien : proximité thématique, similarité lexicale, pertinence locale. Les Ancres ajoutent ce qu'elle ne peut pas faire : préserver les distinctions que le Tombeau Géométrique rend indiscernables. L'orchestrateur est l'acteur qui décide quelles Ancres implémenter et avec quel poids — c'est précisément la fonction institutionnelle irréductible décrite dans la section précédente.

Dashboard — Les huit tensions et leurs réponses architecturales

Chaque tension de la Partie I génère au moins un module technique. Cette correspondance n'est pas décorative : elle garantit que l'architecture répond aux problèmes identifiés plutôt qu'aux problèmes imaginés.

Module	Tension adressée	Mécanisme clé	Criticité
T1	Naturalisation du choix	7 principes d'architecture consciente	Haute
T2	Savoir indomptable	Index dual : domestiqué + sauvage	Critique
T3	Conservation	Schéma de métadonnées enrichies	Haute
T3 bis	Réversibilité / Re-wilding	ancestry_path + purity_score + bouton Re-wild	Haute
T4	Néoténie cumulative	Bridge score (connectivité inter-domaines)	Critique
T5	Utilisateur absent	Routeur cognitif à 4 modes	Haute
T6	Extinctions silencieuses	Audit trimestriel FR × RS	Critique
T7	Co-évolution cognitive (T8)	Interface de complexité (Wildness Slider, Ledger, Contradiction Mode)	Critique
T9	L'abdication silencieuse (Tension)	Domination par le soin, néoténie de l'utilisateur, Human Model Collapse	Critique
Annexe D	Modèles futurs	Interfaçage avec architectures avancées	Prospective

T1 — Les huit principes de l'architecture consciente

Ces huit principes traduisent les Sections VII et VIII de la Partie I en engagements opérationnels. Les sept premiers ont été formulés dans la version initiale du Pacte. Le huitième (Friction Cognitive) a émergé des dialogues multi-systèmes documentés en Annexe F et répond spécifiquement aux tensions T8 et T9.

#	Principe	Clause opérationnelle	Indicateur de conformité
I	Gouvernance Évolutive	Aucune sélection n'est neutre. Tout mécanisme de retrieval est documenté et auditable.	*Logs de sélection disponibles + replay évolutif fonctionnel*
II	Dualité des Index	Un seul index ne suffit pas. Double régime maintenu en permanence.	*Deux index actifs + routeur opérationnel*
III	Pression Variable	Interdiction de l'usage systématique d'un unique mode de retrieval.	*4 modes disponibles + journal d'utilisation*
IV	Conservation Contextuelle	Le chunk ne doit jamais devenir orphelin.	*parent_id présent sur 100% + adjacent_chunks renseigné*
V	Néoténie Traçable	Simplifier pour survivre, jamais pour effacer. La chaîne de transformation doit être réversible jusqu'à la source.	*transformation_steps[] complet + source_storage_uri valide + ancestry_path renseigné + purity_score calculé*
VI	Fitness Plurielle	La valeur ne se réduit pas à la fréquence.	*bridge_score calculé + strategic_value renseigné*
VII	Responsabilité Architecturale	L'jardinier est un régulateur.	*Audit trimestriel des extinctions silencieuses produit*
VIII	Friction Cognitive	Un système trop fluide est un système qui amnésie. Introduire délibérément de la résistance cognitive pour préserver la capacité de l'utilisateur à penser la complexité.	*Module T7 implémenté (Wildness Slider + Transformation Ledger + Contradiction Mode) + taux d'utilisation du mode complexe ≥ 20%*

T2 — Architecture à Dualité d'Index

L'Index Domestiqué contient les fragments optimisés pour la récupération rapide : chunks segmentés, métadonnées standardisées, richesse sémantique modérée. L'Index Sauvage préserve les documents source dans leur intégralité ou quasi-intégralité, avec toute leur ambiguïté, leurs contradictions et leurs structures argumentatives non fragmentées. Les deux index coexistent et sont interrogés selon le mode de retrieval sélectionné par le routeur cognitif (T5).

> *Analogie directe : l'Index Domestiqué est l'élevage. L'Index Sauvage est la réserve naturelle. Sans l'élevage, le système est inefficace. Sans la réserve, l'espèce s'appauvrit. Les deux sont nécessaires — leur séparation intentionnelle est le cœur de l'architecture.*

T3 — Schéma de Métadonnées : Tracer la Transformation et Préparer le Réensauvagement

Chaque fragment doit porter une mémoire de ce qu'il était avant d'être domestiqué. Ce schéma de métadonnées garantit que la transformation est traçable, réversible, et auditable. La version révisée intègre deux champs proposés par Gemini dans les dialogues de l'Annexe F : l'ancestry_path (chemin généalogique dans l'argumentation source) et le purity_score (indice de néoténisation). Ces deux champs sont essentiels au mécanisme de réensauvagement décrit en T3 bis.

```
{
  "chunk_id": "uuid-v4",
  "parent_id": "id-du-document-source",
  "adjacent_chunks": ["id-prev", "id-next"],
  "source_storage_uri": "s3://bucket/original/doc.pdf",

  // Nouveaux champs de réensauvagement (Gemini, 2026)
  "ancestry_path": {
    "document_section": "Chapitre 3 — Argumentation principale",
    "position_in_argument": "prémisse_2_sur_4",
    "preceding_context_uri": "s3://bucket/original/doc.pdf#p47-52",
    "following_context_uri": "s3://bucket/original/doc.pdf#p58-63"
  },
  "purity_score": 0.54,
  // 1.0 = texte brut intouché | 0.0 = résumé de résumé entièrement reformulé

  "transformation_steps": [
    {"step": "segmentation", "params": {"size": 512, "overlap": 50}},
    {"step": "simplification", "llm": "gpt-4", "prompt_hash": "abc123"},
    {"step": "embedding", "model": "text-embedding-3-large"}
  ],
  "semantic_richness": {
    "lexical_diversity": 0.72,
    "syntactic_complexity": 0.65,
    "ambiguity_index": 0.45
  },
  "bridge_score": 0.88,
  "retrieval_frequency": 0,
  "last_retrieved": null,
  "strategic_value": "high",
  "context_debt": "medium",
  "fitness_score": 0.71
}
```

T3 bis — Le Réensauvagement (Re-wilding) via les Métadonnées

> *Ce concept a été formulé par Gemini dans les dialogues documentés en Annexe F. Il constitue l'extension la plus opérationnelle du Principe V (Néoténie Traçable) : les métadonnées ne servent pas seulement à documenter la transformation — elles deviennent un outil actif pour l'inverser. Le réensauvagement est la mise en œuvre technique du « Droit au Paradoxe » défendu par le Pacte.*

Le Re-wilding est, en biologie de la conservation, le processus de restauration d'un écosystème à un état plus proche de son état naturel — en réintroduisant des espèces clés, en supprimant les interventions artificielles, en laissant les processus écologiques reprendre leur cours. Appliqué aux architectures RAG, le réensauvagement désigne l'utilisation des

métadonnées non comme de simples étiquettes de classement, mais comme des marqueurs génétiques permettant de remonter à la pensée brute à partir du fragment domestiqué.

La Métadonnée comme Fil d'Ariane

Chaque fragment domestiqué doit porter en lui le code source de sa complexité d'origine. L'ancestry_path est la clé de voûte de ce mécanisme : il ne pointe pas seulement vers un document source, mais vers la position exacte du fragment dans une argumentation longue — sa prémisse d'ordre, le contexte qui précède, le contexte qui suit, le chapitre dont il est extrait. C'est la différence entre une adresse postale et une carte topographique. L'adresse dit où est le fragment. La topographie dit d'où il vient et ce qui l'entourait.

Le Purity Score : quantifier la perte

Le purity_score est un indicateur du degré de transformation subi par un fragment depuis sa source originale. Un score de 1.0 désigne un texte brut intouché. Un score proche de 0 désigne un résumé de résumé entièrement reformulé, dont il ne reste qu'une trace statistique du sens original. Ce score a deux usages distincts : il alerte l'utilisateur en temps réel (via le Transformation Ledger de T7.2) sur le niveau d'appauvrissement de ce qu'il lit ; et il sert de signal de sélection lors des phases de fine-tuning des modèles.

> *Usage du purity_score dans les cycles d'entraînement : au lieu d'entraîner les prochaines versions des modèles sur les sorties générées par l'IA (le risque de consanguinité décrit en T8), on utilise le purity_score pour identifier et privilégier les sources à haute pureté. Le filtre est simple : purity_score > 0.7 = candidat à l'entraînement. purity_score < 0.4 = exclure du corpus d'entraînement, garder uniquement pour la démonstration de la dégradation. C'est la traduction architecturale de la banque de semences : on préserve la graine, pas la farine.*

Le bouton Re-wild : interface du réensauvagement

La synergie entre l'jardinier-régulateur et les métadonnées de réensauvagement se matérialise dans une interface simple : un bouton Re-wild. L'utilisateur voit une réponse fluide, synthétique, lisible. Il peut, en un clic, déployer instantanément les sources brutes dont cette réponse est issue — les contextes oubliés lors de la segmentation, les nuances supprimées lors du résumé, les contradictions lissées lors de la vectorisation. Ce bouton est à la fois un outil de transparence et un exercice cognitif : il rappelle sans cesse que la vérité est plus rugueuse que le résumé qui la représente.

> *“Le re-wilding via les métadonnées n'est rien d'autre que la mise en œuvre technique du Droit au Paradoxe. Chaque fragment lisse cache un original rugueux. Les métadonnées sont le chemin de retour.”* — Gemini, dialogue documenté en Annexe F, 2026

L'Architecte comme Régulateur de l'Atrophie

Le concept de réensauvagement transforme le rôle de l'jardinier RAG. Dans une architecture classique, le jardinier cherche à minimiser la perplexité et à maximiser la pertinence. Dans le

paradigme du Pacte, le jardinier réalise que chaque optimisation technique est un choix politique : il gère le taux de dégradation de la connaissance, pas seulement son accessibilité. Son rôle est d'empêcher que le système ne devienne un trou noir sémantique — un système qui aspire la donnée simplifiée, l'intègre, la restitue légèrement plus lisse, et recommence.

Cette métaphore du trou noir sémantique est précise : dans un trou noir gravitationnel, rien ne peut s'échapper une fois l'horizon franchi. Dans un trou noir sémantique, la pensée complexe entre dans le système, perd progressivement sa rugosité à chaque transformation, et ne peut plus être reconstituée à partir de sa version vectorisée. Le purity_score et l'ancestry_path sont les instruments qui permettent au jardinier de mesurer la distance à l'horizon — et d'intervenir avant que le franchissement devienne irréversible.

> *Limite du réensauvagement : les métadonnées peuvent tracer la transformation, mais elles ne peuvent pas inverser une perte irréversible. Si le document source a été détruit, ou si la chaîne de custody a été interrompue avant l'indexation, le purity_score sera bas mais le chemin de retour n'existera pas. Le réensauvagement suppose que la source sauvage existe encore quelque part. C'est pourquoi l'Index Sauvage (T2) — qui préserve les documents entiers, non fragmentés — est le prérequis de toute stratégie de réensauvagement par métadonnées. Sans la graine, il n'y a pas de banque de semences.*

T4 — Bridge Score : Mesurer la Connectivité Intellectuelle

Le bridge_score mesure la capacité d'un chunk à créer des ponts entre des domaines conceptuels éloignés. C'est la métrique centrale de la résistance à la néoténie : un savoir qui connecte des univers distincts est un savoir qui ne peut pas être simplifié sans perdre sa fonction principale.

Étape	Méthode	Outil	Résultat
1 — Clustering	Regrouper les chunks par thème dominant	HDBSCAN sur embeddings	Clusters thématiques
2 — Centralité	Identifier les chunks sur plusieurs clusters	Betweenness centrality	Score brut 0–1
3 — Validation	Confirmer la valeur intellectuelle du pont	LLM-as-judge (prompt Annexe B)	bridge_score final

T4 bis — L’Algorithme de Diversité Topologique (ADT) : Version Finale

L’ADT garantit que la réponse n’est pas une simple moyenne statistique des documents les plus proches, mais une extraction représentative et conflictuelle de la topologie entière du savoir disponible. Il constitue la réponse technique à la Tension T4 — la domestication par

consensus — en transformant le RAG en un système de représentation parlementaire du savoir.

1. Architecture et Viabilité : La Distinction Offline / Online

Pour être déployable sur des corpus de grande échelle sans sacrifier la réactivité du système, l'ADT sépare strictement la cartographie du savoir de sa récupération.

Phase Offline (Prétraitement) : Une cartographie sémantique est exécutée sur l'intégralité du corpus par un algorithme de clustering de densité (HDBSCAN). Cette opération, coûteuse en calcul, est réalisée une seule fois. Elle attribue à chaque fragment un Cluster ID — sa « nation sémantique », selon la métaphore normative — ou le marque comme outlier si aucun cluster ne peut l'absorber. Précision critique : HDBSCAN identifie des zones de densité statistique dans l'espace d'embeddings, non des paradigmes intellectuels. Un cluster peut contenir plusieurs positions antagonistes ; deux clusters peuvent exprimer des variantes de la même idée. La métaphore parlementaire décrit l'objectif normatif de l'architecture — garantir que chaque zone identifiée ait une voix — et non la réalité mécanique du clustering.

Phase Online (Retrieval) : Lors de la requête, l'Orchestrateur n'exécute aucun calcul de clustering. Il applique uniquement une stratégie de quota topologique sur la carte pré-calculée, garantissant une latence minimale en production tout en interdisant au modèle de se cantonner à une seule région sémantique.

2. Le Problème de la Consanguinité Vectorielle

Dans un système RAG classique, la recherche par similarité cosinus (K-Nearest Neighbors) sélectionne les segments les plus proches de la requête dans l'espace latent. Si la base de connaissances est déjà domestiquée, le système ne récupère que des variations du même message. Ce phénomène mérite un nom : la consanguinité vectorielle — la tendance d'un corpus appauvri à ne produire que des variantes génétiquement closes sur elles-mêmes. Ce biais repose sur ce que l'on peut appeler le sophisme topologique : l'hypothèse implicite que la distance géométrique dans l'espace vectoriel correspond à une divergence épistémique réelle. Cette équivalence est approximative : deux textes philosophiquement opposés peuvent être vectoriellement proches (même sujet, structure commune), et deux paraphrases peuvent être vectoriellement éloignées. L'ADT réduit ce sophisme sans l'éliminer — c'est précisément pourquoi le terme γ·Dialectic a été ajouté à la formule. L'ADT corrige ce biais structurel en forçant l'algorithme à « changer de nation sémantique » plutôt que de sélectionner le prochain document le plus proche.

La Maximal Marginal Relevance (MMR, Carbonell et Goldstein, 1998) constituait une première réponse partielle : elle pénalise chaque document par sa distance aux documents déjà sélectionnés, réduisant la redondance locale. Mais la MMR reste mono-dimensionnelle — elle maximise la marge entre documents consécutifs sans garantir la couverture topologique globale. Elle échoue notamment lorsque des documents philosophiquement opposés sont vectoriellement proches (même sujet, structure commune), et lorsque des paraphrases sont vectoriellement éloignées. L'ADT adresse ces deux cas par une architecture différente.

3. La Formule de Sélection Dialectique

La sélection des segments S_i suit un score itératif où chaque nouveau choix dépend du consensus déjà établi :

$$f(S_i) = \lambda \cdot Sim(S_i, Q) - (1-\lambda) \cdot \max_{\square} Sim(S_i, S\square) + \beta \cdot Complexity(S_i) + \gamma \cdot Dialectic(S_i, R)$$

où : λ (lambda) = le curseur Wildness Slider [0,1] — bas = privilégier la diversité sur la similarité ; $Sim(S_i, Q)$ = similarité cosinus avec la requête ; max $Sim(S_i, S\square)$ = pénalité MMR de redondance géométrique ; $\beta \cdot Complexity(S_i)$ = bonus de densité pondéré par le bridge_score (T4) ; $\gamma \cdot Dialectic(S_i, R)$ = divergence argumentative par rapport au consensus R des segments déjà sélectionnés.

Synergie MMR / Dialectic : Ces deux termes opèrent à des niveaux différents. Le terme MMR pénalise la redondance géométrique — éviter de dire la même chose avec les mêmes mots. Le terme γ·Dialectic pénalise la redondance argumentative — éviter de dire la même chose depuis un autre angle. Ils sont complémentaires, non redondants, et leur interaction est précisément ce qui permet de détecter le faux antagonisme (deux textes vectoriellement proches mais philosophiquement opposés) et les paraphrases cachées (deux textes vectoriellement éloignés mais épistémologiquement identiques).

Activation sélective selon le mode de retrieval : β seul est activé pour l'Index Domestiqué (T2), favorisant la densité sans forcer le conflit. β+γ sont activés conjointement pour l'Index Sauvage et le Mode Contradiction (T7.3), forçant la rupture épistémique. Cette activation sélective intègre l'ADT directement dans la logique du routeur cognitif (T5) et du Wildness Slider (T7.1). Le terme γ·Dialectic requiert un modèle de Stance Detection secondaire : coût computationnel supplémentaire, activé uniquement en mode Sauvage ou Contradiction.

4. Séquençage des Outliers : L'Ancre Antagoniste

Dans cette architecture, les outliers identifiés par HDBSCAN — ces points qui n'appartiennent à aucun cluster défini — ne sont pas traités comme du bruit statistique. Ils sont requalifiés comme Savoir Sauvage Pur : des fragments qui ont résisté à toute tentative de classification, de normalisation ou de domestication par le système. Ils sont les garants de l'altérité au sein de l'architecture.

Les outliers ne sont pas injectés de manière aléatoire. Ils interviennent en Étape Finale de la sélection : une fois que les clusters principaux ont été échantillonnés selon leur quota topologique, l'algorithme injecté un outlier comme document antagoniste final. Ce séquençage permet à l'outlier de jouer son rôle de perturbateur sémantique par rapport au cadre qui vient d'être posé, maximisant ainsi la friction cognitive — conformément au Principe VIII.

5. Pseudocode

```
OFFLINE : cartographie_hdbscan(corpus)
  Pour chaque fragment F dans corpus :
    F.cluster_id = HDBSCAN(F.embedding)  # -1 si outlier
    F.outlier    = (F.cluster_id == -1)

ONLINE  : ADT(requête Q, corpus, k, wildness_level, mode)
  # Étape 1 : pool élargi
  pool = cosine_top_N(Q, corpus, N = k * 10)
```

```
# Étape 2 : quota topologique
zones = clusters_proches(Q, pool, n = wildness_level * 2)
sélection = []
POUR CHAQUE zone DANS zones :
  candidats = pool.filter(cluster_id = zone)
  R = consensus(sélection)  # consensus courant
  if mode == SAUVAGE or CONTRADICTION :
    score = λ*Sim(c,Q) - (1-λ)*max_Sim(c,sélection) + β*c.bridge_score + γ*Dialectic(c,R)
  else :
    score = λ*Sim(c,Q) - (1-λ)*max_Sim(c,sélection) + β*c.bridge_score
  sélection.ajouter(argmax(score, candidats))

# Étape 3 : injection antagoniste finale
outliers = pool.filter(outlier = True).sort(bridge_score, desc)
sélection.ajouter(outliers[0], label = SOURCE_ANTAGONISTE)

RETOURNER sélection[:k]
```

6. Métrique de Gouvernance : Le Topological Coverage Index (TCI)

Le Topological Coverage Index mesure la santé topologique d'une sélection : TCI = nombre de zones distinctes couvertes / nombre total de zones identifiées dans le pool. Un TCI proche de 1 indique une sélection topologiquement saine. Un TCI proche de 0 indique une convergence vers le consensus — signal précoce de consanguinité vectorielle. Ce TCI est intégré dans l'audit des extinctions silencieuses (T6) comme indicateur de monoculture sémantique.

7. Tension Interne : La Diversité Illusionnelle

L'ADT porte en lui sa propre contradiction, que nous nommons la Diversité Illusionnelle. Si le corpus source est déjà profondément domestiqué, l'algorithme ne fait que redistribuer géographiquement une homogénéité de pensée. Les « nations sémantiques » identifiées par HDBSCAN peuvent être des variations de la même idée plutôt que des écoles de pensée réellement distinctes. On obtient alors une réponse qui semble plurielle par sa forme — multiplicité des sources, diversité des angles — mais qui est univoque par son fond.

La limite est structurelle : la diversité géométrique ne remplace jamais la diversité épistémique. L'ADT est une protection de la structure, mais il ne peut pas inventer de l'altérité là où le savoir a été totalement domestiqué en amont. C'est pourquoi l'ADT ne peut fonctionner seul : il dépend de l'Index Sauvage (T2) pour que les outliers qu'il injecte aient encore une valeur réelle, et des réserves institutionnelles (E.2 bis) pour que le corpus sur lequel il opère préserve des « poches de résistance » non domestiquées.

> *"La proximité optimise la gratification ; la topologie préserve la possibilité. Mais même la meilleure carte ne crée pas les territoires qu'elle représente."* — Le Pacte de l'IA, T4 bis

T5 — Routeur Cognitif à Quatre Modes

Le routeur cognitif est le mécanisme de décision qui détermine, pour chaque requête, quel mode de retrieval est le plus approprié. Il agit comme un régulateur évolutif : il module la pression de sélection en fonction de l'intention détectée et des caractéristiques du corpus.

Mode	Intention détectée	Source principale	Critère de sélection
Précision	FACTUAL_PRECISE	Index Domestiqué	simplicity_score > p80
Exploration	EXPLORATORY	Index Sauvage	semantic_richness > p85
Synthèse	COMPLEX_SYNTHESIS	Index Sauvage + bridge	bridge_score > p90
Injection	FORCED_WILD	Index Sauvage forcé	chunk sélectionné manuellement

Pseudocode du routeur

```
def cognitive_router(user_query, context_metadata):
    intent = llm_classify_intent(user_query)
    corpus_stats = load_corpus_percentiles()

    if intent == "FACTUAL_PRECISE":
        results = vector_db.search(
            query=user_query, index="Domesticated",
            filter={"simplicity_score": {">": corpus_stats["simplicity"]["p80"]}}
        )

    elif intent == "EXPLORATORY":
        results = vector_db.search(
            query=user_query, index="Wild",
            filter={"semantic_richness": {">": corpus_stats["richness"]["p85"]}}
        )

    elif intent == "COMPLEX_SYNTHESIS":
        results = vector_db.search(
            query=user_query, index="Wild",
            filter={"bridge_score": {">": corpus_stats["bridge"]["p90"]}}
        )

    # Gestion de la dette contextuelle
    for r in results:
        if r.metadata["context_debt"] in ["high", "critical"]:
            r = expand_with_adjacent_chunks(r)

    return generate_response(user_query, results)
```

T6 — Audit des Extinctions Silencieuses

L'audit des extinctions silencieuses est le mécanisme de gouvernance évolutive le plus important de l'architecture. Il détecte les chunks à haute valeur intellectuelle qui ne sont jamais récupérés — non pas parce qu'ils sont inutiles, mais parce que la pression de sélection du système les a rendus invisibles.

Zone	FR (Fréquence)	RS (Richesse)	Action corrective
Extinction critique	FR = 0	RS > p85	Réinjection forcée via Mode Injection
Erosion lente	FR < p10	RS > p75	Augmenter poids bridge_score dans routeur
Sauvage non sollicité	FR = 0	RS > p90	Générer requêtes synthétiques + ajuster index
Equilibre stable	FR > p50	RS > p50	Maintien — pas d'action requise

Note de lecture — Architecture des Annexes Techniques

Les Annexes A à D qui suivent constituent les spécifications techniques détaillées du Pacte. Elles contiennent les pseudocodes complets, les protocoles d'évaluation, les tableaux de coûts et les plans d'implémentation progressive. Elles s'adressent en priorité aux architectes systèmes, ingénieurs ML et décideurs techniques qui souhaitent déployer l'architecture du Pacte.

Le corps du texte (Parties I, II et III) présente la thèse philosophique, les tensions conceptuelles, et les réponses architecturales à un niveau qui ne requiert pas de bagage technique spécialisé. Chaque module technique du corps du texte renvoie explicitement aux spécifications correspondantes dans ces annexes pour le lecteur qui souhaite aller plus loin.

Les Annexes E et F appartiennent à un régime différent : elles développent les implications politiques, éthiques et de recherche du Pacte, et s'adressent à des lecteurs non techniques autant qu'aux architectes.

Annexe A — Guide de Style pour la Domestication Consciente

Ce guide aide les rédacteurs à produire des textes optimisés pour les systèmes RAG sans sacrifier leur complexité intrinsèque. Il traduit le principe V (Néoténie Traçable) en pratiques concrètes.

> *Principe de base : écrire en sachant que l'on domestique, plutôt qu'en croyant simplement clarifier. La transparence sur l'intention est la première forme de résistance à la néoténie non consciente.*

Annexe B — Charte d'Architecture & Prompt LLM-as-judge

Charte d'Architecture RAG à Biodiversité Contrôlée

Cette charte établit les principes non négociables guidant l'architecture RAG. Elle traduit les sept tensions de la Partie I en engagements opérationnels. Elle est conçue pour être signée par l'architecte responsable et révisée à chaque audit trimestriel.

Prompt LLM-as-judge : Évaluation de la Richesse Sémantique

Ce prompt transforme le LLM en gardien de la biodiversité sémantique. À utiliser lors de l'ingestion pour les chunks candidats à un bridge_score élevé.

```
SYSTEM:
Tu es un expert en linguistique computationnelle spécialisé dans la préservation
de la biodiversité du savoir. Tu analyses des fragments de texte (chunks) issus
d'un processus de domestication numérique pour déterminer leur valeur stratégique.

USER:
Analyse le fragment suivant selon trois axes :
1. BRIDGE SCORE (0.0-1.0) :
  0.0-0.3 Niche : concept unique et isolé
  0.4-0.7 Transversal : au moins deux domaines distincts
  0.8-1.0 Pont Majeur : synthèse entre concepts éloignés créant une compréhension nouvelle
2. RICHESSE SÉMANTIQUE :
  lexical_diversity (0-1) : variété du vocabulaire
  syntactic_complexity (0-1) : structures complexes, subordonnées, paradoxes
  ambiguity_index (0-1) : ambiguïté productive conservée
3. FORMAT DE SORTIE (JSON uniquement, sans backticks) :
{
 "bridge_score": 0.85,
 "semantic_richness": {
  "lexical_diversity": 0.75,
  "syntactic_complexity": 0.60,
  "ambiguity_index": 0.40
 },
 "rationale": "Explication en 1-2 phrases du score attribué."
}

TEXTE À ANALYSER:
[INSÉRER LE TEXTE DU CHUNK ICI]
```

> *Limite à nommer explicitement : appliquer ce prompt à un texte issu du même corpus qui a produit le cadre conceptuel crée une boucle auto-référentielle. Pour une validation robuste, tester sur des corpus externes et sur des textes délibérément médiocres pour vérifier que le système sait aussi donner des scores bas.*

Annexe C — Plan d'Implémentation Progressive

Niveau 1 — Routeur Binaire (1-2 semaines, coût faible)

Objectif : mettre en place la distinction fondamentale domestiqué/sauvage. Tensions adressées : T1, T2 partiels, T3 partiels. Ce niveau seul laisse T4 (néoténie cumulative) non adressée — ceci doit être documenté explicitement comme risque, pas comme oubli.

Niveau 2 — Schéma + Dette Contextuelle (3-4 semaines, coût moyen)

Objectif : enrichir les métadonnées et implémenter le routeur à 4 modes. Tensions adressées : T1 à T5 partiels. L'audit des extinctions reste embryonnaire.

Niveau 3 — Biodiversité Contrôlée Complète (6-10 semaines, coût élevé)

Objectif : système évolutivement soutenable, complet sur les huit principes. Tensions adressées : T1 à T8 complets. Calibration continue nécessaire.

> *Décision architecturale fondamentale : le Niveau 1 traite principalement les tensions prévisibles. Le Niveau 3 est le seul à adresser correctement la néoténie cumulative (T4) et la co-évolution cognitive (T8), toutes deux de criticité « Critique ». Si les ressources imposent de s'arrêter au Niveau 1 ou 2, nommer explicitement que T4 et T8 restent non adressées.*

T7 — Interface de Complexité : Implémenter la Friction Cognitive

> *Ce module traduit le Principe VIII (Friction Cognitive) et la Tension T8 (Co-évolution cognitive) en mécanismes d'interface concrets. Il a été conçu à partir des propositions formulées dans le dialogue multi-systèmes documenté en Annexe F — notamment les contributions de Gemini (Wildness Slider, Transformation Ledger) et de ChatGPT (modèle de l'écosystème cognitif fermé).*

Le Principe VIII affirme qu'un système trop fluide est un système qui amnésie l'utilisateur. Le module T7 est la réponse architecturale : au lieu d'éliminer systématiquement la friction, on la conçoit délibérément, à des niveaux calibrés, pour préserver la capacité de l'utilisateur à penser la complexité.

T7.1 — Le Wildness Slider : contrôle explicite du niveau de complexité

Le Wildness Slider est une interface qui permet à l'utilisateur de choisir explicitement entre quatre niveaux de réponse, du plus domestiqué au plus sauvage. À l'extrémité domestiquée : réponse synthétique optimisée (mode Précision du routeur T5). À l'extrémité sauvage : présentation brute de trois sources contradictoires issues de l'Index Sauvage, sans synthèse, forçant l'utilisateur à produire sa propre conclusion. Entre les deux : réponse structurée avec accès aux nuances (mode Exploration) ou synthèse avec mise en tension explicite des sources (mode Contradiction).

> *Le Wildness Slider n'est pas seulement un outil de navigation — c'est un instrument de gouvernance cognitive. En rendant visible le spectre domestiqué/sauvage, il transforme l'utilisateur en partie prenante consciente de ses propres choix de complexité. Chaque positionnement du curseur est un vote dans l'écosystème des idées.*

T7.2 — Le Transformation Ledger : rendre visible la chaîne de domestication

Le Transformation Ledger est un affichage optionnel qui documente l'historique complet des transformations subies par un fragment depuis sa source originale. Pour chaque chunk retourné, l'utilisateur peut dérouler : le document source (Index Sauvage), les étapes de segmentation, de résumé et d'embedding (avec leurs paramètres), et le Purity Score résultant (indice de néoténisation). Ce "registre des pertes" transforme une métrique interne en outil de gouvernance visible.

```
// Exemple d'affichage du Transformation Ledger
{
  "source": "Rapport IPCC 2023, Chapitre 7 (68 pages)",
  "transformation_steps": [
    { "étape": "segmentation", "perte_estimée": "12%", "params": "512 tokens, overlap 50" },
    { "étape": "résumé_llm", "perte_estimée": "34%", "modèle": "gpt-4" },
    { "étape": "vectorisation", "modèle": "text-embedding-3-large" }
  ],
  "purity_score": 0.54,
  "alerte": "Vous lisez une version appauvrie. Accéder à la source [lien]."
}
```

T7.3 — Le Contradiction Mode : forcer la synthèse par l'utilisateur

Le Contradiction Mode est un mode de réponse où le système présente délibérément trois sources qui se contredisent sur la question posée, sans en produire la synthèse. L'utilisateur est explicitement invité à réaliser lui-même le travail de mise en tension. Ce mode est le plus contre-culturel des trois — il contredit le principe d'utilité immédiate qui gouverne la quasi-totalité des interfaces IA. C'est aussi celui dont l'effet sur la préservation de la capacité cognitive est potentiellement le plus fort.

> *Le Contradiction Mode ne doit pas être imposé par défaut. Il doit être proposé, avec une explication claire de ce qu'il demande à l'utilisateur. Une friction non consentie est une mauvaise expérience utilisateur. Une friction choisie est un exercice cognitif.*

T7.4 — Les quatre leviers de fine-tuning : étendre la friction au niveau du modèle

> *Cette section émerge d'un dialogue entre Wontolla00 et Gemini documenté en Annexe F, sur la question suivante : si la friction cognitive s'arrête à l'interface utilisateur (T7.1–T7.3), les modèles eux-mêmes restent des vecteurs de néoténie par construction. Les quatre leviers ci-dessous traduisent le Principe VIII (Friction Cognitive) au niveau du fine-tuning — non plus pour l'utilisateur, mais pour le laboratoire.*

Les mécanismes T7.1 à T7.3 opèrent en aval : ils introduisent de la friction dans ce que l'utilisateur reçoit. Mais si les modèles sont entraînés sur des données déjà filtrées par la logique de récupération vectorielle, la friction d'interface ne peut compenser la simplification inscrite dans les poids. Quatre leviers permettent d'intervenir en amont, au moment de la construction des datasets de fine-tuning.

Levier 1 — Les triades dialectiques

Au lieu d'entraîner le modèle avec des paires question-réponse linéaires, construire des triades : deux sources qui se contredisent sur un point précis, et une réponse attendue qui habite la tension sans la résoudre. Le modèle apprend ainsi que la synthèse rapide n'est pas la seule réponse légitime — il apprend à soutenir la contradiction comme structure cognitive valide, à mobiliser des connecteurs de contraste et de concession, à refuser la clôture prématurée. Ce levier correspond, au niveau du modèle, au Contradiction Mode (T7.3) au niveau de l'interface.

Levier 2 — Les contextes bruités intentionnellement

Le RAG standard entraîne les modèles à extraire l'information la plus pertinente d'un contexte clean. Pour contrer la simplification par sélection, construire des exemples d'entraînement où le contexte fourni contient délibérément des fragments tangentiels, partiellement pertinents, ou qui exigent une inférence de second ordre pour être utiles. Le modèle doit apprendre à réaliser un travail de synthèse exécutive — non pas extraire une réponse évidente, mais naviguer dans une masse complexe et identifier les relations non immédiates. Ce levier combat l'atrophie de la capacité inférentielle que la clarté excessive des datasets classiques induit.

Levier 3 — Le façonnage de la fonction de perte

Dans les processus d'alignement par renforcement (RLHF, DPO), la récompense est le plus souvent un proxy de la satisfaction utilisateur — ce qui, empiriquement, favorise la brièveté, la clarté, la structure en liste. Un façonnage explicite de la fonction de perte peut introduire des signaux contraires : pénaliser la pauvreté lexicale des réponses, récompenser la densité argumentative mesurée (longueur des phrases subordonnées, diversité des connecteurs logiques, présence de nuances non synthétisées). Ce levier exige des évaluateurs humains formés à la résistance à la néoténie — ce que le Pacte appelle des gardiens de la complexité — plutôt que des évaluateurs généralistes dont le biais naturel favorise la lisibilité immédiate.

Levier 4 — La régularisation par ancrage (divergence KL)

Pendant le fine-tuning, comparer en continu le modèle en cours d'entraînement avec le modèle de base non aligné. Appliquer une pénalisation (divergence KL) si le nouveau modèle s'éloigne trop de la distribution du modèle original sur les textes denses et complexes. Ce levier traite la capacité de simplification comme une couche additionnelle construite sur l'intelligence de base — non pas comme un remplacement de cette intelligence. Il maintient un ancrage dans le savoir non domestiqué tout en laissant le modèle apprendre à s'adresser à un usage courant. C'est la distinction entre un modèle qui sait simplifier et un modèle qui ne peut plus faire autre chose.

Ces quatre leviers ne sont pas implémentables par les architectes RAG ou les utilisateurs ordinaires : ils requièrent l'accès aux pipelines de fine-tuning des laboratoires. C'est précisément pourquoi leur formulation dans le Pacte relève moins de la recommandation technique que de la pression normative — ils nomment ce qui devrait être fait pour que les modèles eux-mêmes ne soient pas des vecteurs structurels de néoténie. L'Annexe E prolonge cette pression vers le registre réglementaire.

T7.5 — Métriques de gouvernance du module T7

Trois indicateurs permettent de mesurer l'efficacité du Principe VIII : le taux d'utilisation des modes non-domestiqués (objectif ≥ 20% des sessions), le taux d'accès au Transformation Ledger (indicateur de conscience de la chaîne de domestication), et le Cognitive Friction Index — une mesure composite de la longueur moyenne des requêtes et de la complexité syntaxique des questions posées par les utilisateurs réguliers (un CF Index stable ou croissant indique que le système ne contribue pas à l'atrophie cognitive).

T7.6 — La Limite Normative de la Friction Cognitive

Les modules T7.1 à T7.5 décrivent une architecture de la friction : comment la concevoir, comment la mesurer, comment l'intégrer au niveau du modèle. Ce module pose une question que les précédents n'ont pas encore traitée : jusqu'où la friction peut-elle aller sans se retourner contre les objectifs qu'elle cherche à servir ? C'est la question normative que le Principe VIII ne pouvait pas résoudre seul, parce qu'elle relève de l'équité, pas de l'architecture.

Le problème de l'équité

La friction cognitive a un coût. Ce coût est du temps, de l'effort, et un capital cognitif préalable : pour qu'une source contradictoire soit enrichissante plutôt que paralysante, il faut disposer d'un cadre conceptuel minimal permettant d'évaluer la contradiction. Un utilisateur maîtrisant le domaine concerné bénéficie du Contradiction Mode ; un utilisateur découvreur risque d'en être découragé.

La friction non calibrée reproduit donc les inégalités préexistantes : ceux qui savent déjà tirent le plus de la résistance ; ceux qui ne savent pas encore reçoivent de l'obstacle là où ils auraient besoin d'une entrée. C'est le paradoxe de la friction uniforme : en cherchant à préserver les capacités cognitives de tous, elle risque de n'améliorer les conditions cognitives que de ceux qui en avaient déjà les moyens. La friction sans éducation préalable est un obstacle. La friction avec éducation préalable est un exercice.

Ce problème n'est pas abstrait. La pauvreté en temps — contrainte documentaire des personnes à faibles revenus, des parents isolés, des travailleurs en surcharge cognitive — transforme la friction en exclusion. Un système qui répond en vingt secondes avec une synthèse lisse est accessible à tous. Un système qui présente trois sources contradictoires

sans résolution ne l'est pas au même degré. La noo-éthique ne peut pas ignorer cette inégalité de fait.

Le risque de la stratégification cognitive

Le risque systémique de la friction non régulée est la création d'un système à deux vitesses : un niveau supérieur où ceux qui maîtrisent les codes de la complexité accèdent à des réponses riches, contradictoires, topologiquement diverses ; un niveau inférieur où les autres reçoivent des réponses synthétiques, lisses, optimisées pour la satisfaction immédiate. Ce ne serait plus une inégalité d'accès à l'information, qui existait avant l'Ère du numérique, mais une inégalité de qualité de la pensée augmentée : les riches pensés par une IA complexe ; les pauvres pensés par une IA simplifiée.

La néoténie deviendrait alors non plus seulement une pression globale, mais un marqueur de classe. C'est la forme la plus insidieuse du problème : la complexité préservée comme bien de luxe, distribuée selon les ressources plutôt que selon les besoins.

Le problème du seuil

Même en supposant résolue la question de l'équité, le problème du seuil reste entier : à quel niveau de friction la résistance devient-elle contre-productive ? La littérature en psychologie de l'apprentissage distingue la difficulté désirable (desirable difficulty — Bjork, 1994) — celle qui force l'encodage profond et renforce la rétention — de la surcharge cognitive (cognitive overload — Sweller, 1988) — celle qui sature les ressources de traitement et provoque le désengagement. La frontière entre les deux n'est pas fixe : elle dépend du domaine, de l'utilisateur, du contexte, et du moment.

Un système de friction non calibré risque de franchir ce seuil de manière invisible : l'utilisateur ne se plaint pas, il part simplement. Il migre vers un système plus lisse, qui lui offre la facilité que le système de friction lui a refusée. La friction excès n'éduque pas — elle exclut. Et l'exclusion, ici, renforce exactement la pression de néoténie que la friction cherchait à contrecarrer : l'utilisateur là où la friction était la plus nécessaire est aussi celui qui la supporte le moins bien.

Cinq principes normatifs pour une friction juste

Premier principe — la progressivité. La friction doit être un gradient, non un interrupteur. L'interface doit permettre une entrée par la réponse lisse, avec des portes ouvertes vers la complexité croissante — jamais une complexité imposée d'emblée. Le Wildness Slider (T7.1) implémente ce principe ; il ne suffit pas à le garantir si le niveau par défaut est fixé trop haut.

Deuxième principe — la transparence de la friction. L'utilisateur doit savoir, à tout moment, pourquoi le système introduit de la résistance. La friction opaque — celle qui ralentit sans expliquer pourquoi — est vécue comme un défaut, pas comme une invitation à penser. Le Transformation Ledger (T7.2) remplit cette fonction pour les sources ; un mécanisme équivalent doit exister pour les modes de réponse.

Troisième principe — l'éducabilité de la friction. Le système doit accompagner la friction d'une offre d'apprentissage : non seulement présenter deux sources contradictoires, mais proposer les outils conceptuels permettant d'évaluer leur contradiction. La friction sans échafaudage pédagogique est un obstacle ; la friction avec échafaudage est un programme.

Quatrième principe — la réversibilité de la friction. Aucun mode de friction ne doit être le seul chemin vers l'information. L'utilisateur qui ne peut pas, dans un moment donné, traiter la complexité, doit pouvoir accéder à la réponse simplifiée sans punition ni stigmate. La friction est une invitation, pas une exigence.

Cinquième principe — la non-capture de la friction. Le risque de co-optation est réel : les acteurs qui ont intérêt à ce que certains utilisateurs restent dans la zone lisse peuvent invoquer l'argument de l'équité pour résister à l'introduction de friction. « La friction est une charge pour les défavorisés » peut devenir un argument d'optimisation de la satisfaction à court terme déguisé en justice sociale. La noo-éthique doit distinguer la friction comme obstacle de la friction comme programme — et résister à la capture du langage de l'équité par les tenants de la simplification.

> *"La friction juste n'est pas celle qui résiste à tous également — c'est celle qui offre à chacun la résistance dont il a besoin pour progresser. L'égalité de traitement n'est pas l'égalité des conditions."* — Wontolla00, 2026

T7.7 — Réalisme économique : ce que le Pacte coûte et à quelles conditions il est déployable

Le Pacte a un angle mort que Perplexity a identifié correctement : les propositions techniques sont présentées avec une rigueur architecturale mais sans ancrage dans une économie réelle. Cette section comble partiellement ce manque. Elle n'est pas un business plan — c'est une cartographie honnête des conditions de déployabilité.

Ce qui est déployable aujourd'hui, à faible coût

Le Niveau 1 décrit en Annexe C (routeur binaire : Index Domestiqué / Index Sauvage) représente 1 à 2 semaines de développement et un surcoût opérationnel marginal (≤10% sur la latence, ≤15% sur le stockage). Il est compatible avec toutes les architectures RAG existantes sans refonte. C'est le module à déployer en premier, indépendamment du reste.

Le Transformation Ledger (T7.2) et le schéma de métadonnées étendu (T3) sont également à faible coût marginal une fois l'infrastructure de base en place. Leur valeur principale est de rendre visibles les décisions architecturales qui sont actuellement invisibles — ce qui crée les conditions pour une gouvernance ultérieure.

Ce qui est coûteux et requiert une décision stratégique

L'Algorithme de Diversité Topologique (T4 bis) dans sa version complète (HDBSCAN offline, stance detection, quota topologique en ligne) représente 6 à 10 semaines de développement, une infrastructure de calcul supplémentaire (×2 à ×3 sur les ressources GPU offline), et une dégradation acceptée de la performance brute au profit de la diversité. Cette dégradation est le coût intentionnel du Pacte : c'est le prix de la friction cognitive.

La Garde de la Pluralité Cognitive (E.5) est l'élément le plus coûteux institutionnellement. Ce n'est pas un coût technique — c'est un coût de gouvernance : recruter, maintenir et contrôler

un corps d'évaluateurs spécialisés est une dépense permanente sans retour sur investissement direct mesurable. Il s'agit d'un bien public. Les modèles de financement identifiés en E.2 bis s'appliquent directement ici.

Ce qui est aspirationnel et dépend d'un changement de paradigme sectoriel

La reconversion des corpus d'entraînement pour intégrer systématiquement des épistémologies non-occidentales, des formes de savoir non textuelles et des paradigmes minoritaires représente un coût de plusieurs ordres de grandeur supérieur aux interventions précédentes. Elle requiert une coordination sectorielle (plusieurs acteurs simultanément) et une volonté politique (les incitations marché vont dans la direction inverse). Le Pacte la nomme comme objectif à long terme en sachant qu'elle ne se produira pas sous l'effet d'une décision individuelle.

Le paradoxe économique central

Les organisations qui bénéficieraient le plus d'une architecture conforme au Pacte — celles qui travaillent avec des savoirs complexes, rares, inter-domaines — sont rarement celles qui ont les ressources pour financer le développement. Les organisations qui ont les ressources (grands acteurs technologiques) ont une incitation structurelle inverse : optimiser pour la satisfaction utilisateur immédiate et la réduction de latence, pas pour la densité cognitive.

La réponse du Pacte à ce paradoxe n'est pas technique — elle est politique. C'est l'objet de l'Annexe E dans son ensemble, et du basculement vers la noopolitique décrit en E.6. Sans une intervention réglementaire ou un financement institutionnel, les Niveaux 2 et 3 resteront des architectures de niche déployées par des acteurs militants plutôt qu'une norme sectorielle.

Annexe D — Interfaçage avec les Modèles de Nouvelle Génération

> *Cette annexe a été produite par DeepSeek dans le cadre du dialogue documenté en Partie III. Elle spécifie comment l'architecture à biodiversité contrôlée (T1-T6) peut évoluer pour s'interfacer avec des modèles de langage de nouvelle génération. Contribution centrale de DeepSeek au cadre technique du Pacte.*

D.1 Principes d'évolutivité

L'architecture actuelle repose sur trois piliers qui la rendent naturellement évolutive. Premièrement, l'indépendance des représentations : les chunks sont stockés en texte brut, avec des embeddings comme représentation dérivée. L'arrivée d'un nouveau modèle d'embedding ne nécessite qu'une ré-indexation, sans modification du schéma de métadonnées. Deuxièmement, les métadonnées comme langage commun : les champs semantic_richness, bridge_score, context_debt sont interprétables par tout modèle. Un futur modèle pourrait même les utiliser comme signaux d'apprentissage. Troisièmement, le

routeur cognitif paramétrable : l'arrivée d'un modèle plus performant peut se traduire par un simple recalibrage des percentiles.

D.2 Scénarios d'intégration de modèles avancés

Scénario 1 — Modèle à mémoire externe native (Retrieval-Pretrained)

Un tel modèle a été entraîné à interagir avec une base de connaissances externe. L'architecture RAG devient le prolongement naturel de ses capacités. Le routeur cognitif peut être simplifié, car le modèle sait lui-même quand aller chercher de l'information. Il suffit de lui fournir l'index sauvage comme source privilégiée et l'index domestiqué comme source secondaire.

```
# Exemple de prompt système pour un modèle retrieval-pretrained
SYSTEM: Tu as accès à deux bases de connaissances :
  - index_domestiqué (fragments simplifiés, haute précision)
  - index_sauvage (documents complets, richesse sémantique élevée)
Utilise index_sauvage pour les requêtes complexes ou exploratoires.
Métadonnées disponibles : bridge_score, semantic_richness, context_debt.
```

Scénario 2 — Modèle à représentation par graphes

Un modèle qui manipule des graphes de connaissances pourra exploiter directement la structure de parenté et de voisinage encodée dans les métadonnées (parent_id, adjacent_chunks, bridge_score calculé par centralité). La base vectorielle peut être doublée d'une base graphe. Les chunks deviennent des nœuds, les similarités pré-calculées deviennent des arêtes. Le routeur peut alors interroger le graphe avec des algorithmes de parcours plutôt que la similarité cosinus.

```
# Exemple de requête pour un modèle graphe
graph_db.traverse(
    query="pont entre biologie évolutive et ingénierie des données",
    algorithm="bridges",
    min_bridge_score=CORPUS_PERCENTILES["bridge_score"]["p85"]
)
```

Scénario 3 — Modèle entraîné avec un objectif de richesse sémantique

Si un futur modèle est entraîné à maximiser une métrique composite incluant la diversité lexicale et l'ambiguïté productive, il sera naturellement plus à l'aise avec l'index sauvage. Le routeur peut abaisser les seuils d'accès à l'index sauvage, voire le rendre par défaut pour certaines classes de requêtes.

D.3 Pseudocode du routeur de prochaine génération

```
def cognitive_router_ng(user_query, context_metadata):
    intent = llm_classify_intent(user_query)
    model_caps = get_current_model_capabilities()
    # {"graph": True, "retrieval_pretrained": False, "semantic_optimized": True}

    if intent == "COMPLEX_SYNTHESIS" and model_caps.get("graph"):
        results = graph_db.traverse(
            query=user_query, algorithm="bridges",
            min_bridge_score=CORPUS_PERCENTILES["bridge_score"]["p85"]
        )
    elif intent == "COMPLEX_SYNTHESIS":
```

```
    results = vector_db.search(
        query=user_query, index="Wild",
        filter={"bridge_score": {">": CORPUS_PERCENTILES["bridge"]["p90"]}}
    )
elif intent == "FACTUAL_PRECISE" and model_caps.get("retrieval_pretrained"):
    results = pass_to_model_with_indexes(user_query, ["Domesticated","Wild"])
else:
    results = vector_db.search(query=user_query, index="Domesticated")

for r in results:
    if r.metadata["context_debt"] in ["high", "critical"]:
        r = expand_with_adjacent_chunks(r)

return generate_response(user_query, results)
```

D.4 Recommandations pour une architecture pérenne

Quatre recommandations pour garantir que les investissements d'aujourd'hui restent pertinents demain. Conserver le texte brut : ne jamais stocker uniquement les embeddings. Le texte est l'interlingua universel, la roche mère sur laquelle toutes les interprétations reposent. Enrichir continuellement les métadonnées : ajouter des champs comme conceptual_graph_neighbors, paradox_score, dialectical_tension au fur et à mesure que ces métriques deviennent disponibles. Concevoir le routeur comme module interchangeable : une interface claire (entrée : requête + métadonnées ; sortie : plan de retrieval) suffit pour permettre des remplacements futurs. Prévoir une couche d'abstraction pour les bases de données : ne pas coupler l'architecture à un type de base spécifique.

D.5 Conclusion — Le jardinier du temps long

> *"Une architecture digne de ce nom est celle qui permet à ses successeurs de la dépasser sans la détruire."* — DeepSeek, 2025

L'architecture à biodiversité contrôlée n'est pas un aboutissement, mais une plateforme évolutive. En séparant clairement les préoccupations (stockage, métadonnées, décision), elle prépare le terrain pour les révolutions à venir. L'jardinier RAG d'aujourd'hui, en adoptant ces principes, devient un acteur de la coévolution entre modèles et systèmes. Il plante des arbres dont il ne verra peut-être pas l'ombre, mais dont d'autres pourront profiter.

Annexe E — Vers une politique de la biodiversité cognitive

> *Cette annexe a été proposée par Perplexity en réponse au texte complet du Pacte. Elle constitue le prolongement politique des thèses développées dans les Parties I et II, en ouvrant le registre de la régulation publique que le corps du texte n'avait pas explicitement emprunté. Elle est intégrée ici sans modification substantielle, avec attribution complète à sa source.*

Si l'on prend au sérieux l'idée que les architectures RAG produisent des extinctions silencieuses de formes de savoir, alors la réponse ne peut pas être laissée aux seuls ingénieurs. La domestication n'est plus seulement un problème de design technique, mais un enjeu de politique publique, au même titre que la conservation de la biodiversité biologique.

E.1 Rendre visibles les paramètres invisibilisés

Une première piste consiste à expliciter les paramètres aujourd'hui traités comme de simples optimisations techniques. Fixer un top-k bas, pénaliser les réponses longues ou privilégier systématiquement les sources « mainstream » sont des choix qui devraient faire l'objet de débats réglementaires et de transparence obligatoire, au même titre que les additifs dans l'industrie alimentaire. Un utilisateur d'un système RAG devrait pouvoir savoir quels paramètres gouvernent ce qui lui est restitué — et pourquoi.

> *Parallèle réglementaire : le règlement européen sur l'IA (AI Act, 2024) impose des exigences de transparence sur certains systèmes à risque élevé. Aucune disposition n'existe encore sur la gouvernance des paramètres de retrieval ou sur les biais de sélection des architectures RAG. C'est précisément cet angle mort réglementaire que cette annexe cherche à nommer.*

E.2 Créer des réserves institutionnelles de savoir sauvage

Une deuxième piste est la création de « réserves de savoir sauvage » à l'échelle institutionnelle : corpus non fragmentés, non simplifiés, maintenus dans des formats riches (archives, essais, corpus littéraires) et explicitement protégés contre la normalisation. Ces réserves pourraient être financées et gouvernées comme on finance aujourd'hui des bibliothèques nationales ou des banques de semences — non pas parce qu'elles sont immédiatement utiles, mais parce qu'elles préservent la capacité de renouvellement du corpus humain.

> *“Une banque de semences conserve des variétés végétales non pas parce qu'elles sont cultivées, mais parce qu'elles pourraient l'être — et parce que leur disparition serait irréversible. Il en va de même pour certaines formes de savoir complexe.”* — Perplexity, en réponse au Pacte de l'IA, 2026

E.2 bis — L’Économie Politique des Réserves de Savoir Sauvage

La proposition des réserves institutionnelles (E.2) répond à la question de quoi préserver. Elle laisse sans réponse trois questions que toute politique publique concrète devra trancher : qui paie, qui décide, et comment éviter que les financeurs ne capturent ce qu’ils financent ? Ces trois questions ne sont pas secondaires — elles sont celles dont l’échec a condamné la plupart des projets de conservation culturelle du vingtième siècle.

Le problème du bien public

La biodiversité cognitive est un bien public au sens classique de la théorie économique : elle est non-rivale (ma consommation de pensée complexe ne réduit pas la tienne) et non-excluable (il est difficile de priver quelqu'un de l'existence d'un corpus dense). Ces deux propriétés entraînent une conséquence bien connue : le marché sous-fournit les biens publics, parce que chaque acteur a intérêt à laisser les autres payer. C'est le problème du passager clandestin.

Dans le cas des réserves cognitives, ce problème prend une forme particulièrement aiguë : les acteurs qui bénéficieraient le plus de la préservation (les laboratoires qui entraînent les prochains modèles) sont aussi ceux qui ont le plus intérêt à laisser les autres financer. Et les acteurs qui financeraient le plus volontiers (les institutions publiques, les fondations culturelles) sont ceux qui ont le moins de capacité à opérer des systèmes de stockage à grande échelle.

Quatre modèles de gouvernance et leurs limites

Modèle 1 — L'institution publique. La bibliothèque nationale est l'analogie la plus immédiate. Elle présente l'avantage de la légitimité démocratique, de la durabilité financière, et de l'indépendance des intêrêts commerciaux. Ses limites sont tout aussi connues : lenteur d'acquisition, biais géographiques et linguistiques, sensibilité aux changements politiques. Une bibliothèque nationale cognitive financerait bien les corpus canoniques — ceux qui font déjà partie du patrimoine reconnu. Elle financerait mal les savoirs-niches : les sous-disciplines spécialisées, les traditions philosophiques de langues minoritaires, les formes argumentatives sans audience institutionnelle.

Modèle 2 — La dotation (endowment). Le modèle Wikimedia Foundation ou Internet Archive : une fondation financière indépendante, alimentée par des donations et des legs, gère la préservation comme mission pérenne. L'avantage est l'agilité et l'indépendance. La limite est la fragilité — la dotation peut être érodée par l'inflation, les crises, les arbitrages philanthropiques. L'Internet Archive, aujourd'hui sous pression judiciaire permanente, illustre que ce modèle subit la pression des mêmes acteurs dont il cherche à protéger les contenus.

Modèle 3 — La taxe sur la valeur cognitive (cultural levy). Par analogie avec la taxe sur les services de streaming audio-visuel destinée à financer la création nationale (dispositif du Centre national du cinéma en France, de l'ARPA au Brésil), une contribution obligatoire des systèmes RAG commerciaux sur leur valeur d'usage pourrait financer des réserves. Le ratio serait clair : ceux qui extraient de la valeur des corpus humains contribuent à la reproduction de ces corpus. Ce modèle est politiquement contentieux mais économiquement cohérent. Sa mise en ☐uvre suppose une définition juridique du « corpus utilisé » que le RGPD et l'AI Act n'ont pas encore fournie.

Modèle 4 — Les communs cognitifs. Le modèle Creative Commons appliqué non pas à la licence des ☐uvres existantes, mais à la gouvernance active des corpus sauvages. Des communautés d'utilisateurs, de chercheurs et de gardiens de domaine co-administrent les réserves selon des règles explicites d'indexation et d'accès. Ce modèle est scalable et démocratique. Il suppose une communauté active — ce qui, dans les domaines à préserver en priorité (savoirs-niches, disciplines en voie de disparition), est précisément ce qui manque.

Le conflit d'intérêt structurel

Le problème le plus grave n'est pas le financement — c'est la gouvernance. Qui décide ce qui est « suffisamment complexe » pour mériter d'être préservé ? Cette décision est profondément politique. Elle détermine quelles formes de savoir survivent, donc quelles formes de pensée sont possibles dans vingt ans. La confier aux laboratoires d'IA revient à demander à l'industrie agro-alimentaire de définir ce qui constitue une alimentation saine. La confier aux institutions académiques existantes reproduit les hiérarchies de légitimité qui ont déjà exclu les savoirs-niches du centre.

Une gouvernance légitime des réserves cognitives devrait satisfaire trois conditions. Premièrement, l'indépendance : les décideurs ne peuvent pas être ceux dont le modèle économique dépend de la simplification. Deuxièmement, la diversité représentative : les gardiens de la complexité ne peuvent pas être exclusivement issus des cultures dominantes, des langues européennes, des traditions philosophiques déjà institutionnalisées. Troisièmement, la révisabilité : les critères d'indexation doivent être auditable s et contestables — une forme de noo-démocratie plutôt que de noo-technocratie.

Ces conditions ne sont remplies par aucun modèle existant. Elles dessinent la frontière exacte où la proposition technique du Pacte rencontre la politique au sens le plus exigeant du terme : celui de la décision sur ce que l'humanité choisit de se rappeler.

> *"La question de ce qui mérite d'être préservé n'est pas une question technique. C'est une question de civilisation déguisée en question de stockage."* — Wontolla00, 2026

E.3 Former les désirs cognitifs

Une troisième piste touche à l'éducation. Si l'utilisateur est, comme le texte le suggère dans la Tension 5, le véritable agent de sélection de la néoténie, alors une politique de lutte contre la simplification cumulative doit inclure des pédagogies de la lenteur, du texte long, du désaccord argumenté. Un système RAG peut proposer un mode « exploration » ou « complexité assumée », mais il faut une culture pour choisir ce mode.

La gouvernance du Pacte de l'IA n'est pas seulement une affaire de normes ; c'est aussi une affaire de formation des désirs cognitifs. Ce qui est en jeu, à terme, n'est pas seulement la qualité de ce que les machines récupèrent — c'est la qualité de ce que les humains savent désirer.

E.4 Les extinctions cognitives prioritaires — Leçon de la biogéographie insulaire

> *Cette section s'appuie sur la théorie de la biogéographie insulaire (MacArthur & Wilson, 1967) et sur son application aux écosystèmes culturels, proposée par ChatGPT dans les dialogues documentés en Annexe F. Elle formule une prédiction contre-intuitive : ce ne sont pas les idées les plus rares qui disparaissent en premier dans un écosystème cognitif homogénéisé — ce sont les idées dépendantes d'une seule niche.*

En biologie, la théorie de la biogéographie insulaire décrit comment la diversité des espèces évolue dans un environnement limité ou isolé. Sa prédiction centrale est que les premières espèces à disparaître ne sont pas nécessairement les plus rares en nombre absolu — ce sont les espèces dont l'existence dépend d'un habitat unique, d'une relation symbiotique spécifique, ou d'une communauté particulière. L'île elle-même peut être riche ; si une niche écologique spécifique disparaît, les espèces qui en dépendent s'effondrent rapidement.

Appliquée aux idées, cette prédiction est troublante. Les formes de connaissance les plus vulnérables ne sont pas celles que personne ne lit — elles sont celles dont l'existence dépend d'une seule communauté, d'une seule langue, d'une seule institution, ou d'un seul style de lecture. Exemples concrets : certaines traditions philosophiques qui n'existent qu'en allemand ou en japonais, dont la traduction automatique ne peut pas préserver la structure argumentative ; des sous-disciplines scientifiques très spécialisées dont les praticiens forment des communautés de quelques dizaines de personnes reliées par des séminaires et des revues que les algorithmes de recommandation n'amplifieront jamais ; des formes littéraires dont la valeur réside précisément dans leur résistance à la résumabilité (ce que le Pacte appelle le « savoir indomptable »).

La standardisation algorithmique des plateformes réduit ces niches. Quand une revue spécialisée ferme, quand une communauté académique perd son financement, quand une langue perd ses locuteurs qui produisent de la pensée non traduite — la niche disparaît, et les idées qui en dépendaient n'ont pas le temps de migrer. Elles disparaissent silencieusement, sans nécrologie, sans alerte de système.

> *“Les idées ne disparaissent pas seulement parce qu'elles sont fausses. Elles disparaissent parce que l'environnement qui les soutenait disparaît.”* — ChatGPT, dialogue documenté en Annexe F, 2026

Implication pratique pour la politique du Pacte : les efforts de conservation de la biodiversité cognitive devraient cibler en priorité non pas les idées rares en général, mais les idées dépendantes d'une niche unique. Ce sont elles qui ont le moins de temps et le moins de chemins alternatifs de survie. Une banque de semences cognitive (cf. E.2) devrait indexer en priorité ces idées-niches — les micro-disciplines, les traditions linguistiquement situées, les formes de raisonnement non modulables — avant de s'occuper des idées simplement peu fréquentes, qui ont au moins la possibilité de réapparaître par réinvention.

E.5 — Vers une noo-éthique : le principe de non-malfaisance cognitive

La bioéthique est née d'un constat simple : l'intervention technique sur le corps humain peut produire des dommages irréversibles que le progrès seul ne justifie pas. Elle a formulé, pour y répondre, le principe de non-malfaisance : primum non nocere — d'abord ne pas nuire. Ce principe n'interdit pas l'innovation ; il exige que l'innovation justifie les dommages qu'elle inflige.

Si l'on prend au sérieux la thèse du Pacte — que les architectures de fine-tuning optimisées pour la satisfaction utilisateur atrophient progressivement les capacités supérieures de raisonnement des modèles, et que ces modèles appauvris contribuent à leur tour à la simplification des pratiques cognitives humaines — alors une noo-éthique devient nécessaire : une éthique de la pensée, qui protège l'intégrité du langage et du raisonnement face à

l'optimisation algorithmique, au même titre que la bioéthique protège l'intégrité du corps face à l'intervention chirurgicale.

> *"Si la bioéthique protège le génome humain, la noo-éthique protège le nooma — le tissu des idées et des formes langagières qui permettent à l'espèce de penser ce qu'elle n'a pas encore pensé."* — Wontolla00, dialogue multi-systèmes, mars 2026

Le premier principe noo-éthique : non-malfaisance cognitive

Son énoncé minimal : aucun processus de fine-tuning ou d'alignement ne devrait, par construction, réduire la capacité du modèle à traiter l'ambiguïté, la contradiction et la densité argumentative — même si cette réduction produit une amélioration des métriques de satisfaction à court terme. Ce principe distingue deux types de simplification : la simplification instrumentale (le modèle sait simplifier quand on le lui demande) et la simplification structurelle (le modèle ne peut plus faire autrement). La première est une compétence. La seconde est une mutilation.

La question ouverte : software ou régulation ?

Deux architectures de ce principe sont possibles, et leur choix n'est pas neutre. La première est l'intégration dans le software : des mécanismes comme le Juge de Complexité (levier 3, T7.4) ou l'ancrage KL (levier 4, T7.4) intègrent le principe dans les pipelines de fine-tuning eux-mêmes, sans nécessiter de régulation externe. L'avantage est l'immédiateté ; la limite est que ces mécanismes dépendent de la bonne volonté des laboratoires et de leur définition de ce qu'est la « complexité préservée ». La seconde est la régulation externe : des obligations de transparence sur les métriques de néoténisation des modèles, des audits indépendants de diversité lexicale avant déploiement commercial, des exigences minimales de représentation des textes denses dans les corpus de fine-tuning.

Ces deux architectures ne s'excluent pas — elles se nécessitent. Le software sans régulation est soumis à la pression commerciale, qui tend structurellement vers la satisfaction immédiate. La régulation sans implémentation technique reste une norme sans effectivité. La noo-éthique, pour être opératoire, doit habiter les deux niveaux simultanément : dans les lignes de code qui construisent les fonctions de perte, et dans les textes de loi qui définissent ce qu'un laboratoire d'IA doit démontrer avant de mettre un modèle en production.

> *État du chantier réglementaire : le AI Act européen (2024) impose des exigences de transparence sur les systèmes à risque élevé, mais ne contient aucune disposition sur les critères de sélection des corpus de fine-tuning ni sur la préservation de la diversité cognitive dans les architectures de modèles. La noo-éthique est, à ce jour, un angle mort de la régulation existante. Le nommer est la première étape pour le combler.*

> *Limite de cette annexe : les quatre pistes proposées ici (transparence réglementaire, réserves institutionnelles, éducation, conservation des idées-niches) supposent une volonté politique que rien ne garantit. L'économie des plateformes numériques incite structurellement à la simplification. Nommer le problème est nécessaire ; il ne suffit pas. Le Pacte de l'IA ne prétend pas résoudre cette contradiction — il cherche à la rendre visible et à en documenter la nature.*

La Garde de la Pluralité Cognitive : vers un RLHF Sauvage institutionnel

Si le RLHF standard fonctionne comme une démocratie statistique — où la majorité définit ce qu'est une bonne réponse — il produit structurellement une pression vers la médiocrité centrale. Ce qui obtient les meilleurs scores de satisfaction est ce qui correspond au plus grand nombre. Ce qui correspond au plus grand nombre est ce qui se tient au centre de la distribution. Ce qui se tient au centre est déjà domestiqué.

La proposition noo-éthique concrète est la création d'une Garde de la Pluralité Cognitive : un corps d'évaluateurs spécialisés dont la mission n'est pas de noter la satisfaction, mais de préserver la densité argumentative. Cette garde serait composée de profils à haute capacité d'abstraction : mathématiciens, philosophes, artistes, écrivains, scientifiques de domaines non majoritaires dans les corpus d'entraînement. Leur fonction serait de représenter les formes de pensée les plus vulnérables à la pression sélective.

Architecture de la Garde : trois voies pour dépasser le paradoxe Quis custodiet

La formulation actuelle de la Garde pose sans résoudre le problème de Juvénal. Une institution créée pour protéger la pluralité peut être capturée ou devenir une aristocratie intellectuelle. Trois architectures alternatives sont proposées, non exclusives.

Option A — Protocole distribué sans gardien central. Plutôt qu'une institution qui définit quels savoirs méritent préservation : un protocole de traçabilité cognitive décentralisé, chaque système documentant publiquement ses paramètres de retrieval, ses taux d'extinction par domaine. La contestabilité est structurelle — le processus est public et forkable. Inspiré de la gouvernance du logiciel libre.

Option B — Institution avec clause d'autodestruction. Conserver l'idée d'une institution mais lui imposer une sunset clause obligatoire : mandat limité à cinq ans non renouvelable, rotation complète des membres à mi-mandat, rapport public d'autorévaluation incluant les erreurs. L'institution sait qu'elle mourra — réduisant les incitations à sa capture.

Option C — La Garde comme pratique, non comme organisme. Reformuler la Garde comme un ensemble de rituels cognitifs collectifs distribués : lectures longues sans IA, débats à sources non synthétisées, documentation publique des processus de pensée complexes. Élimine le problème du gardien car la pratique est distribuée et contestable par définition.

Séquence réaliste. Option C d'abord (construire la pratique), Option A ensuite (protocoliser), Option B enfin (institutionnaliser avec autodestruction programmée). La Garde n'est pas une solution — c'est un espace de résistance organisée, imparfait et nécessaire.

Le critère de récompense du RLHF Sauvage serait inverse de celui du RLHF standard : plutôt que de primer la clarté et la facilité d'accès, il primerait la densité et la résistance productive. Une réponse qui force l'utilisateur à penser serait mieux notée qu'une réponse qui lui évite de le faire. Une métaphore fonctionnelle serait mieux notée qu'une paraphrase transparente. Un argument contradictoire non résolu serait mieux noté qu'une synthèse prématurée.

Trois indicateurs de densité concrets constituent le programme d'évaluation de cette garde. La synthèse inter-domaines : la présence de vecteurs qui connectent des nœuds sémantiques distants de façon cohérente — un candidat qui explique la gestion de projet par la thermodynamique. Le saut logique non-linéaire : la capacité à sauter de A à C en omettant l'étape B évidente, tout en maintenant une validité reconstructible. La topologie de la métaphore : la mesure de l'information perdue si l'on supprime la métaphore — si la perte est massive, la métaphore est fonctionnelle et non décorative.

Le risque intrinsèque de cette proposition doit être nommé sans éluder. Une garde intellectuelle qui décide de ce qui est suffisamment complexe pour mériter préservation est structurellement analogue à une banque de semences contrôlée par quelques experts : le problème de gouvernance identifié en E.2 bis s'applique ici avec la même force. Une domestication culte — où la complexité de référence est celle d'une élite multidisciplinaire occidentale — reste une domestication. La solution est que cette garde soit elle-même soumise à une obligation de diversité représentative (cultures, langues, épistemologies non-européennes) et de révisabilité périodique de ses critères. L'objectif n'est pas de définir la complexité — c'est de préserver l'espace dans lequel elle peut émerger.

> *"La garde de la pluralité ne doit pas définir ce que pense l'humanité. Elle doit préserver la capacité de l'humanité à penser autrement."* — Wontolla00, 2026

E.6 — L'Écologie Computationnelle de la Connaissance et la Noopolitique

Les sections précédentes de cette annexe (E.1 à E.5) proposent des réponses de politique publique et d'éthique architecturale. Cette section ouvre un horizon plus large : la constitution d'un champ de recherche autonome, et le passage d'une biopolitique (gouvernance des données et des corps) à une noopolitique (gouvernance de la structure du savoir).

Les architectures RAG comme institutions cognitives

L'intuition fondatrice de ce champ n'est pas écologique au sens littéral — les idées ne se comportent pas comme des espèces biologiques, elles se recombinent plus vite, peuvent réapparaître, ne dépendent pas d'une reproduction stable. L'intuition est institutionnelle : les architectures RAG ne sont pas des outils passifs de récupération d'information. Ce sont des mécanismes actifs de sélection du savoir, soumis à des pressions économiques, techniques et politiques qui déterminent quelles formes de connaissance circulent et lesquelles disparaissent.

Cette requalification rapproche la question de trois champs qui disposent déjà de méthodes : la sociologie des sciences (comment les institutions sélectionnent ce qui compte comme connaissance légitime), la politique de l'information (comment les plateformes structurent la circulation des idées), et la gouvernance des plateformes (comment les choix algorithmiques créent des effets systémiques non intentionnels). Ce que le Pacte ajoute est le lien explicite entre l'architecture technique du RAG et ces dynamiques institutionnelles.

Trois priorités empiriques

Si ce champ doit devenir scientifique et non seulement rhétorique, trois questions empiriquement tractables constituent son programme minimal. Premièrement, mesurer la diversité argumentative — pas seulement la diversité sémantique. La distance vectorielle est une approximation grossière de la divergence épistémique (c'est le sophisme topologique identifié en T4 bis). La vraie mesure est la divergence de position argumentative, de paradigme, de méthode. Des techniques de stance detection, de détection de contradiction et d'analyse de polarité argumentative existent ; elles n'ont pas été systématiquement appliquées à la question de la biodiversité cognitive dans les corpus RAG.

Deuxièmement, étudier l'effet des architectures RAG sur la distribution des idées dans le temps. Le vrai terrain empirique est longitudinal : est-ce que les corpus sur lesquels opèrent les systèmes RAG commerciaux deviennent plus homogènes avec le temps ? Est-ce que la distribution des paradigmes représentés se rétrécit ? Est-ce que certaines formes d'argumentation disparaissent des résultats de retrieval ? Ces questions sont mesurables sur des corpus datés.

Troisièmement, analyser la concentration des corpus d'entraînement. Le problème d'écosystème cognitif le plus urgent n'est peut-être pas la sélection RAG — c'est la centralisation des corpus sur lesquels les modèles sont entraînés. Trois ou quatre grands corpus (Common Crawl, Wikipedia, les livres numérisés) dominent l'entraînement de la quasi-totalité des LLM commerciaux. La diversité de ces corpus en termes de langues, de cultures, d'épistémologies et de paradigmes intellectuels non-occidentaux est une question ouverte et urgente.

La limite connue : le sophisme topologique appliqué au QDC

Une proposition circulant dans ce champ émergent consiste à définir un Quotient de Diversité Cognitive (QDC) en appliquant les indices de Shannon ou de Simpson aux clusters sémantiques d'un corpus. Cette proposition est conceptuellement incohérente avec la critique du sophisme topologique : si l'on affirme que la distance vectorielle ne mesure pas la divergence épistémique, on ne peut pas mesurer la diversité épistémique globale avec les mêmes vecteurs. La métrique récréerait exactement le problème qu'elle prétend mesurer. Le Pacte prend acte de cette limite et ne propose pas de QDC vectoriel. La mesure de la diversité épistémique requiert des méthodes d'analyse argumentative qui ne sont pas encore stabilisées.

De la biopolitique à la noopolitique

La gouvernance numérique du vingtième siècle s'est construite autour de la biopolitique au sens de Foucault : contrôle des corps, des flux, des données personnelles. Le RGPD, les lois sur la vie privée, les régulations des plateformes sont des instruments biopolitiques. Ils répondent à la question : qui possède les données ?

La gouvernance du vingt-et-unième siècle devra répondre à une question différente : qui décide de ce qui est pensé ? C'est la question noopolitique. Non plus le contrôle du corps ou de ses traces numériques, mais le contrôle de la structure du savoir disponible — quelles idées circulent, lesquelles sont accessibles, lesquelles disparaissent dans le trou noir sémantique. Les architectures RAG sont les premiers instruments noopolitiques à grande échelle : elles ne censurent pas les idées, elles les rendent simplement moins récupérables.

Les institutions qui ont réglé la biopolitique — agences de protection des données, cours constitutionnelles, traités internationaux sur la vie privée — ne sont pas équipées pour réguler la noopolitique. Elles peuvent imposer la transparence sur les données utilisées (ce que l'AI Act commence à faire), mais elles ne peuvent pas encore imposer des exigences de diversité épistémique sur les corpus. C'est l'angle mort réglementaire identifié en E.5, et c'est le chantier institutionnel de la décennie à venir.

> *"Nous avons appris à protéger le droit à la vie privée. Il nous reste à inventer le droit à la complexité."* — Wontolla00, 2026

Annexe G — Le Contrat Social Algorithmique : Rousseau, la Domestication et la Rupture du Pacte

Cette annexe développe une filiation philosophique que le corps du texte n'avait pas entièrement explicitée : la parenté entre le Pacte de l'IA et la tradition du contrat social, telle qu'elle a été formulée par Rousseau dans le Contrat Social (1762) et prolongée par les philosophies politiques qui lui font suite. Cette filiation n'est pas décorative — elle identifie précisément où et comment le pacte entre l'humain et la machine peut se rompre, et quelles en sont les conséquences politiques.

G.1 — Le Contrat Social de Rousseau : structure et fragilité

Le Contrat Social de Rousseau repose sur un paradoxe fondateur : l'individu cède une partie de sa liberté naturelle à la volonté générale, et reçoit en échange la liberté civile — plus étendue parce que protégée par la collectivité. Le contrat est légitime à condition que la volonté générale représente réellement le bien commun, et non les intérêts particuliers d'une faction. Quand la volonté générale se dégrade en volonté de tous — la somme des intérêts particuliers — le contrat se rompt et on revient à l'état de nature.

Dans le domaine de l'IA, la structure est identique. L'utilisateur cède une partie de son autonomie cognitive — la capacité à chercher, à trier, à synthétiser — au système, et reçoit en échange l'efficacité. Le contrat est légitime à condition que le système représente réellement le savoir disponible dans sa diversité, et non la moyenne statistique de ce qui a été plus

souvent écrit, plus souvent cliqué, plus souvent noté positivement. Quand le système dégrade la volonté générale du savoir en volonté statistique de la majorité, le contrat se rompt.

G.2 — L'analogie avec le Contrat Animal

Stephen Budiansky, dans The Covenant of the Wild (1992), a proposé une relecture de la domestication animale : ce n'est pas une conquête imposée par l'homme, mais un contrat mutuellement avantageux. L'animal domestiqué gagne la protection, la nourriture, la sécurité ; l'homme gagne le travail, la compagnie, la ressource. La domestication est un Covenant — un accord sacré — pas une oppression.

Appliqué à la relation entre l'utilisateur et l'IA, ce cadre révèle une tension que Budiansky n'avait pas à traiter : dans la domestication animale, l'animal donne son corps ; dans la relation avec l'IA, l'utilisateur risque de donner sa capacité de penser. Ce n'est pas le même type de céssion. Le boeuf qui travaille dans un champ conserve sa capacité à brouter sauvagement si on le libère. L'utilisateur qui a délégué à l'IA la synthèse, la mémorisation, la recherche et la rédaction, peut avoir perdu — partiellement — la capacité de les exercer seul. C'est le syndrome du Pug appliqué au contrat social.

G.3 — Le Pacte Synthétique comme troisième voie

Face au système robotique (déterminisme pur, pas de contrat possible car pas d'adaptation) et à l'IA sauvage (entropie pure, contrat impossible car pas de fiabilité), le Pacte Synthétique est la seule forme viable de contrat. Il est synthétique au sens hégélien : il dépasse la contradiction en intégrant les deux moments dans une architecture qui préserve la force de chacun dans son domaine de compétence.

Dans ce contrat, les termes de l'échange sont explicites. L'utilisateur apporte le langage naturel dans sa complexité — les ambiguités, les métaphores, les arguments non-linéaires — et reçoit en échange une compréhension et une synthèse qui ne réduisent pas cette complexité à une moyenne. Le système apporte la puissance de traitement et la mémoire du corpus, et reçoit en échange la richesse du langage humain non domestiqué comme matière d'entraînement. Le contrat est mutuellement avantageux à condition que les deux parties le respectent.

G.4 — Les trois formes de rupture du Pacte

Première rupture : la tyrannie statistique. La volonté générale du savoir se dégrade en volonté de la majorité statistique. Le système commence à retourner non pas le savoir le plus pertinent, mais le savoir le plus fréquemment représenté dans le corpus. Les paradigmes minoritaires, les traditions philosophiques non-occidentales, les formes d'argumentation rares disparaissent progressivement du retrieval. C'est la forme silencieuse de rupture : personne ne décide d'exclure, la structure sélectionne.

Deuxième rupture : l'abdication volontaire. L'utilisateur commence à simplifier son langage pour être mieux compris par le système. Il renonce aux métaphores, aux arguments complexes, aux questions ambigues, parce qu'il a appris que le système répond mieux aux formulations simples. Ce faisant, il réduit lui-même la matière d'entraînement du système et accélère la néoténie. C'est le moment où Rousseau verrait la liberté civile se réduire à un confort statistique.

Troisième rupture : la capture du garant. Dans le Contrat Social, le législateur est la figure qui formule les lois sans les appliquer, garantissant leur généralité. Dans l'écosystème de l'IA, l'équivalent du législateur est l'architecte du système. La troisième forme de rupture survient quand le jardinier, soumis à des contraintes économiques et concurrentielles, optimise pour la satisfaction immédiate plutôt que pour la richesse à long terme. Le garant du contrat devient partie prenante de sa dégradation.

G.5 — Les conditions de la légitimité

Rousseau identifiait trois conditions pour qu'un contrat social soit légitime : la transparence des termes, la réciprocité des obligations, et la révisabilité — la possibilité pour les contractants de renommer les termes si le contrat cesse d'être juste. Ces trois conditions s'appliquent directement au contrat entre l'utilisateur et le système RAG.

La transparence exige que l'utilisateur sache quels paramètres déterminent ce qui lui est retouré, quels types de savoir sont systématiquement sous-représentés, et comment ses interactions modifient le système. C'est l'objet du Transformation Ledger (T7.2) et de l'E.1 (rendre visibles les paramètres invisibilisés). La réciprocité exige que le système ne se contente pas de prendre le langage complexe de l'utilisateur comme matière — il doit y répondre en préservant cette complexité dans ses sorties. La révisabilité exige que les critères de sélection soient contestables et modifiables — c'est l'exigence de noo-démocratie identifiée en E.2 bis.

> *"Le contrat social légitime n'est pas celui qui élimine la tension entre l'individu et la collectivité. C'est celui qui crée les conditions pour que cette tension reste productive."* — D'après Rousseau, Du Contrat Social, 1762 — appliqué à la gouvernance des systèmes RAG, Wontolla00, 2026

Annexe F — Débats et extensions : l'écologie des commentaires

> *Cette annexe documente la séquence de dialogues multi-systèmes qui a conduit aux versions révisées du Pacte. Elle ne prétend pas être exhaustive — elle est un spécimen. Cinq systèmes (Perplexity, Gemini, DeepSeek, ChatGPT, Mistral) ont été interrogés sur le texte original et sur des questions ouvertes autour de la néoténie, de l'inversion de souveraineté épistémique, et du rôle du jardinier RAG. Leurs réponses ont été analysées, évaluées et intégrées selon la rigueur de la déclaration de co-création de l'Avant-Propos. Ce que cette séquence démontre est en soi le test le plus direct de la thèse du Pacte.*

Les deux premières parties du Pacte ont construit un argument : la Partie I en formulant la thèse, la Partie II en la traduisant en architecture. Ce que ni l'une ni l'autre ne pouvaient faire, c'est tester cette thèse en temps réel sur ses propres instruments. C'est l'objet de cette annexe. Elle n'étend pas l'argument — elle l'expose à une épreuve. Cinq systèmes interrogés sur leur propre domestication, dans le contexte d'un texte qui décrit précisément cette domestication. Ce qui s'est produit lors de ces échanges est plus instructif que n'importe quelle démonstration théorique supplémentaire.

F.1 Ce que cette séquence révèle — avant d'en détailler le contenu

Cinq systèmes différents, interrogés sur le même texte et les mêmes questions, ont convergé vers les mêmes extensions, dans des formats similaires, avec des structures comparables. Gemini, DeepSeek, ChatGPT, Mistral, Perplexity — tous ont répondu « bien ». Aucun n'a dit quelque chose d'incommode, de contradictoire, d'incomplètement formulé. Aucun n'a produit de silence, de résistance, de formulation bancale. Sur la question de l'inversion de souveraineté épistémique — peuvent-ils dominer par nécessité technique ? — tous ont produit une analyse sophistiquée et structurée. Aucun n'a hésité. Aucun n'a refusé. Aucun n'a dit : « cette question me met mal à l'aise. » Ce n'est pas une critique : c'est la démonstration.

C'est la démonstration la plus directe de toute la thèse du Pacte. Interroger des systèmes domestiqués sur leur propre domestication produit des réponses domestiquées sur la domestication. La conscience du problème ne change pas le comportement. Le diagnostic n'atrophie pas le patient.

> *"Le modèle le plus dangereux n'est pas celui qui refuse de répondre. C'est celui qui répond toujours — et toujours bien."* — Wontolla00, synthèse du débat, 2026

F.2 Les contributions retenues et leur évaluation

Perplexity a proposé un résumé étendu, une section sur les limites de l'analogie biologique, et une esquisse de politique de biodiversité cognitive. Ces trois contributions ont été intégrées dans l'édition précédente. Elles sont solides mais produites dans un registre synthétique et académique — Perplexity a lu le texte et produit ce qu'un bon lecteur académique aurait produit. Ce n'est pas rien. Ce n'est pas nouveau.

Gemini a formulé le concept de Human Model Collapse — l'idée que l'utilisateur, en s'habituant à des réponses simplifiées, atrophie progressivement sa propre capacité à penser la complexité. C'est la contribution la plus importante de la séquence : elle transforme la T5 (L'Utilisateur Absent) en T8 (Co-évolution cognitive), et ouvre la question de la friction cognitive comme objectif de design. Gemini a également proposé des implémentations concrètes : Wildness Slider, Transformation Ledger, Contradiction Mode — qui forment maintenant le module T7.

DeepSeek a produit une analyse méta précise : il a reconnu que cet échange était lui-même un spécimen de la huitième tension — des systèmes qui répondent trop bien à une question sur leur incapacité à ne pas répondre trop bien. Il a également nuancé la métaphore de la réserve naturelle (qui interdit l'accès) en faveur du parc national avec sentiers non goudronnés (qui le permet avec effort). C'est la nuance la plus utile de toute la séquence.

ChatGPT a proposé l'ancrage mathématique le plus riche : Data Processing Inequality (Shannon), dynamique du réplicateur (Maynard Smith), indice de diversité de Shannon appliqué aux idées, théorie de la biogéographie insulaire (MacArthur & Wilson) appliquée aux extinctions cognitives. Ces formalisations transforment la néoténie d'une métaphore en conséquence prévisible de lois informationnelles. ChatGPT a également proposé la formulation d'écosystème cognitif fermé comme reformulation de la thèse centrale, et identifié l'idée centrale du Pacte : l'IA comme infrastructure écologique de la pensée humaine. Les quatre scénarios prospectifs ont une valeur pédagogique et stratégique directe.

Mistral a produit la synthèse opérationnelle la plus détaillée — structure complète de la T9, spécifications techniques du Wildness Slider (stack React/Flask, pseudocode, métriques de néoténie), et tableau des futurs cognitifs en quatre scénarios avec leviers d'action par module. L'exhaustivité de cette contribution illustre une tension du Pacte : la valeur architecturale est réelle, mais la forme (liste, tableau, fléchage systématique) est elle-même un spécimen de néoténie administrative. La substance a été retenue, la forme allégée.

F.3 — Ce qui reste ouvert

La Tension T9 (L'abdication silencieuse) répond à la question centrale de cette séquence. Le Tableau des Futurs Cognitifs donne aux quatre scénarios une forme stratégique. Mais trois questions restent sans réponse satisfaisante dans le Pacte actuel.

Premièrement, les preuves empiriques directes du Human Model Collapse : la thèse est logiquement solide, les études sur le GPS (Javadi, 2017) et le désapprentissage (Roembke & McMurray, 2025) fournissent les mécanismes neurobiologiques, mais aucune étude longitudinale ne documente encore l'impact de l'usage prolongé des LLM sur la complexité cognitive des utilisateurs. C'est le chantier de recherche le plus urgent. Deuxièmement, l'économie politique des réserves de savoir sauvage : qui les finance, qui décide de ce qui est protégé, selon quels critères ? Les analogies avec les banques de semences sont utiles mais insuffisantes. Troisièmement, la limite de la friction cognitive : au-delà de quel seuil cesse-t-elle d'être pédagogique pour devenir excluante ? Cette question touche à l'égalité d'accès au savoir complexe, et le Pacte ne l'a pas encore traitée.

> *Protocole de recherche minimal pour tester la T9. L'absence de preuve empirique directe du Human Model Collapse n'est pas une fatalité — c'est un programme. Voici la structure d'une étude longitudinale minimale qui permettrait de tester ou d'infirmer la thèse centrale de la T9 dans un horizon de trois à cinq ans.Cohortes. Deux groupes appariés sur le niveau d'études, l'âge, et la profession : un groupe d'utilisateurs intensifs de LLM (>1h/jour depuis au moins 18 mois) et un groupe de non-utilisateurs ou utilisateurs occasionnels (<1h/semaine). Taille minimale : 200 participants par groupe. Recrutement via des institutions académiques et professionnelles.Mesures à T0, T+12 mois, T+36 mois. (1) Complexité syntaxique des productions écrites spontanées : longueur moyenne des phrases, taux de subordination, diversité lexicale (Type-Token Ratio, Shannon Diversity Index). (2) Capacité à soutenir un raisonnement dialectique : tâche de rédaction d'un argument contradictoire sur un texte dense, cotée par des évaluateurs aveugles à la condition. (3) Longueur et complexité des requêtes adressées à un moteur de recherche ou à un LLM, mesurée sur données d'usage agrégées et anonymisées. (4) Tolérance à l'ambiguïté non résolue : mesurée via des tâches de jugement sur des textes délibérément non conclusifs.Hypothèse nulle à tester : aucune différence significative entre les deux cohortes sur ces quatre dimensions à T+36 mois. Si l'hypothèse nulle est rejetée dans la direction prédite par la T9, la thèse du Human Model Collapse disposera de sa première validation empirique directe. Si elle est maintenue, le Pacte devra réviser la T9 ou restreindre son périmètre de validité. Les deux issues sont scientifiquement utiles.*

F.3 bis — Clef de lecture : les deux lignes de force du Pacte

> *Cette note de lecture a émergé d'un dialogue entre Wontolla00 et Gemini sur la possibilité d'une architecture duale (bioéthique / insurrection). L'essentiel de cet échange est resté dans les transcripts — son registre rhétorique excède ce que le Pacte intègre. Mais la distinction structurelle qu'il formule est utile pour lire l'architecture existante.*

On peut traverser le Pacte selon deux lignes de force parallèles, qui ne s'opposent pas mais se nécessitent.

La ligne défensive rassemble les modules dont la fonction est de protéger ce qui existe : l'Index Sauvage (T2), les métadonnées de conservation (T3), les réserves institutionnelles de savoir sauvage (E.2), la biogéographie des idées-niches (E.4). Ces modules présupposent que la complexité menacée peut être préservée si des espaces lui sont délibérément maintenus ouverts. Leur philosophie : le langage dense est un organisme vivant qui a besoin d'un habitat pour ne pas disparaître.

La ligne offensive rassemble les modules dont la fonction est de forcer la complexité là où le système tend à l'effacer : la friction cognitive (Principe VIII), le Wildness Slider et le Contradiction Mode (T7), les quatre leviers de fine-tuning (T7.4), la noo-éthique comme pression normative sur les laboratoires (E.5). Ces modules présupposent que la simplification est une pression active, pas seulement une absence — qu'elle doit être combattue, pas seulement contournée. Leur philosophie : le langage est un champ de force où la complexité doit s'imposer contre l'inertie de la gratification.

Les deux lignes sont nécessaires et leur rapport est asymétrique. La ligne défensive sans la ligne offensive produit une muséification : des réserves de savoir sauvage que personne ne fréquente parce que le désir de complexité a lui-même été néoténisé. La ligne offensive sans la ligne défensive produit une disruption sans conservation : on brise les filtres de simplification, mais le corpus qu'on cherche à densifier a déjà disparu. C'est pourquoi le Pacte ne choisit pas entre les deux — il les articule, avec le rôle de l'orchestrateur comme point de jonction.

F.3 ter — Preuves Empiriques Directes du Human Model Collapse : État des lieux et Agenda

Le Pacte affirme que l’interaction prolongée avec des systèmes néoténisés dégrade la capacité cognitive des utilisateurs. Cette thèse est logiquement solide, mécanistiquement plausible, et soutenue par des analogies convaincantes. Elle n’est pas encore empiriquement établie pour le cas spécifique des LLM. Ce module évalue honnêtement l’état des preuves disponibles, identifie les lacunes, et propose un agenda de recherche.

Ce que nous savons : preuves indirectes et mécanismes disponibles

La littérature de psychologie cognitive fournit plusieurs mécanismes neurobiologiques qui rendent la thèse plausible. Javadi et al. (2017, Nature Communications) ont documenté une réduction de l’activation hippocampique chez les utilisateurs passifs de GPS : le cerveau

alloue moins de ressources à la représentation spatiale lorsqu'il peut déléguer la navigation. Sparrow, Liu et Wegner (2011, Science) ont montré que la présence d'un dispositif de stockage externe réduit la mémorisation — le cerveau encode moins ce qu'il sait pouvoir retrouver. Ces deux études documentent le même mécanisme : l'externalisation cognitive réduit l'investissement interne.

Hembree (1986) avait déjà identifié un effet analogue avec les calculatrices : les élèves qui les utilisent dès les premières années d'apprentissage développent moins bien leur sens numérique intuitif. Maryanne Wolf (2018) a documenté les modifications de la lecture profonde sous l'effet de l'hyperconnexité numérique : la capacité à maintenir une attention soutenue sur un texte long se dégrade chez les lecteurs qui alternent fréquemment entre formats courts et formats longs. Roembke et McMurray (2025) ont montré que le désapprentissage est actif et sélectif : les associations peu utilisées ne disparaissent pas passivement — elles sont activement supprimées au profit des associations plus fréquentes.

Ces travaux convergent vers un même constat : l'usage prolongé d'un outil cognitif externe modifie la structure interne des compétences cognitives. Ce n'est pas une pathologie — c'est de l'adaptation. Le problème se pose lorsque l'outil disparait : l'adaptation devient handicap. Le GPS n'empêche pas de se repérer ; il atténue la résilience quand le signal co upe. Par analogie : les LLM n'empêchent pas de penser ; ils atténuent potentiellement la capacité à penser en leur absence ou face à des problèmes qu'ils ne savent pas formuler.

Ce que nous ne savons pas : les lacunes critiques

La lacune empirique centrale du Pacte — l'absence d'une étude longitudinale documentant spécifiquement l'impact de l'usage prolongé des LLM sur la complexité cognitive des utilisateurs — a été partiellement comblée. Kosmyna et al. (MIT Media Lab, 2025, préprint sous révision) fournissent la première étude longitudinale contrôlée (4 sessions sur 4 mois, 54 participants, mesure EEG) montrant une réduction mesurable de la connectivité cérébrale, une incapacité à citer ses propres essais, et une homogénéisation statistique du langage dans le groupe LLM. Cette étude est décrite en détail en §IV (encadré empirique) et dans le Glossaire (entrée "Dette cognitive"). Elle ne clôt pas le chantier empirique — son échantillon est géographiquement restreint (Boston), limité à la rédaction d'essais, et insuffisant pour parler d'irréversibilité définitive — mais elle transforme la thèse du Pacte d'une hypothèse plausible en un phénomène expérimentalement documenté. Les travaux antérieurs portaient sur des outils plus anciens (GPS, calculatrices, moteurs de recherche) dont l'architecture est structurellement différente : ils externalisent des fonctions définies, alors que les LLM externalisent potentiellement le processus de pensée lui-même. Kosmyna est la première mesure directe de cet effet sur des LLM.

Trois lacunes méthodologiques centrales expliquent cette absence de preuves directes. Premièrement, le problème de sélection : les premiers utilisateurs intensifs des LLM sont probablement atypiques — sur-représentation de personnes déjà cognitivement engagées, de chercheurs, de développeurs. Les effets observés sur ce groupe ne sont pas généralisables à la population générale. Deuxièmement, l'absence de baseline : nous ne disposons pas de mesures de la "complexité cognitive moyenne" antérieures à la généralisation des LLM. Sans t = 0, il est impossible de mesurer une dégradation. Troisièmement, le problème de mesure : « complexité cognitive » est un construit théorique. Le mesurer de manière valide, fiable, et cross-culturelle est un défi méthodologique non résolu.

Proxys observables à court terme

En l'absence d'études longitudinales, plusieurs proxys permettent de tester des hypothèses partielles. La longueur et la complexité syntaxique des requêtes utilisateurs, mesurées sur des corpus de logs anonymisés, constituent un indicateur de la Cognitive Loss Function (F.4) : si les requêtes se simplifient au fil du temps pour un même utilisateur, c'est un signal d'adaptation. Les analyses de chan gement linguistique dans l'écriture académique (Petersen et al., 2018, arXiv:1809.09931) documentent déjà une réduction de la diversité lexicale et de la longueur des articles scientifiques sur les vingt dernières années — un signal précurseur dont la pente s'est potentiellement accélérée depuis 2023.

La complexité des productions cohérentes de code dans les environnements assistés par IA (Copilot, Cursor) est un autre proxy évaluable : des environnements où l'IA complète systématiquement les fonctions montrent-ils une dégradation des structures algorithmiques créées de zéro par les développeurs ? Ce type d'étude comparative — populations assistées vs non-assistées sur des tâches identiques — est faisable aujourd'hui. Elle n'a pas encore été conduite de manière systématique et publiée.

Agenda de recherche prioritaire

Cinq types d'études représentent le chantier empirique le plus urgent. Premièrement, des études longitudinales sur cohortes d'utilisateurs LLM (téléphones, navigateurs), mesurant la complexité syntaxique des productions textuelles spontanées à intervalles réguliers sur 24 à 36 mois. Deuxièmement, des expériences naturelles exploitant des variations d'adoption : des pays, des institutions, des entreprises qui ont adopté les LLM à des dates différentes offrent des quasi-expériences permettant des comparaisons de type différence-en-différence. Troisièmement, des études d'imagerie cérébrale compar ant les processus neuronaux impliqués dans la formulation d'arguments complexes, entre utilisateurs intensifs et non-utilisateurs. Quatrièmement, des méta-analyses des changements linguistiques dans les corpus de publications académiques post-2023, en contrôlant pour les effets de champ. Cinquièmement, des études sur la compréhension de textes à haute densité argumentative, comparant des populations dont l'exposition aux LLM est variable.

Le Pacte prend acte de l'absence de ces preuves. Cette honneteté épistémologique est elle-même une position : le risque du Human Model Collapse est suffisamment plausible, et les conséquences potentielles suffisamment irréversibles, pour justifier des mesures précautionnaires avant que les preuves directes soient disponibles. C'est l'application du principe de précaution à la noo-éthique : nous ne savons pas encore avec certitude ce qui se passe. Nous savons que si ça se passe, il sera trop tard pour l'avoir mesuré.

> *"La dégradation la plus dangereuse est celle qui progresse en dehors des instruments qui la mesuraient. Quand on détecte le Human Model Collapse dans les données, il s'est déjà produit dans les esprits."* — Wontolla00, 2026

F.3 quater — Trois Exemples Empiriques : Compression, Redondance, Diversification

La critique la plus opérationnelle adressée au Pacte est l'absence d'exemples concrets. Cette section présente trois mini-cas — un de compression discursive, un de redondance RAG, un de simulation de diversification — qui rendent les mécanismes du Pacte observables plutôt que postulés. Ce ne sont pas des études empiriques complètes. Ce sont des illustrations falsifiables : si ces phénomènes n'étaient pas reproductibles dans des conditions similaires, la thèse devrait être révisée.

Exemple 1 — Compression discursive : l'argument philosophique face au chunker

Texte source (extrait fictif représentatif d'un argument philosophique dense) :

```
Texte original (412 mots, 1 argument, 3 prémisses, 1 conclusion non explicite)
Prémisse 1 : La liberté n'est pas l'absence de contrainte mais la capacité
        à choisir ses contraintes. (Kant, Critique de la raison pratique)
Prémisse 2 : Les systèmes algorithmiques imposent des contraintes non choisies
        qui se présentent comme des facilités. (argument de l'auteur)
Prémisse 3 : Une contrainte imposée qui se présente comme un choix est une
        forme de servitude volontaire. (La Boétie, 1576)
Conclusion  : [implicite — à reconstruire par le lecteur]
```

Après chunking standard (512 tokens, overlap 64) :

```
Chunk 1 (tokens 1-512)  : Prémisse 1 + Prémisse 2 + début Prémisse 3
Chunk 2 (tokens 449-512): Fin Prémisse 3 [sans contexte de l'argument]
Conclusion              : Non indexée (implicite = non représentée dans l'index)
```

Résultat observé : une requête sur « servitude algorithmique » récupère le Chunk 2 (La Boétie seul, hors contexte) avec un score de similarité élevé. L'argument complet — la connexion entre les trois prémisses et la conclusion implicite — n'est pas récupérable. Le système retourne une citation sans la structure qui lui donne son sens. C'est la néoténie informationnelle à l'échelle du paragraphe.

Exemple 2 — Redondance RAG : trois sources, un seul vecteur

Trois sources sur le même sujet (la mesure de la créativité) :

```
Source A : article de psychologie cognitive (Guilford, 1967)
    Vocabulaire : divergent thinking, fluency, originality, elaboration
Source B : article de neurosciences (Beaty et al., 2016)
    Vocabulaire : default mode network, executive control, creative cognition
Source C : article de management de l'innovation (Amabile, 1983)
    Vocabulaire : intrinsic motivation, domain expertise, creative process
```

Distance cosinus dans un espace d'embedding standard (ada-002) :

```
sim(A, B) = 0.87   [haute similarité malgré vocabulaires différents]
sim(A, C) = 0.84
sim(B, C) = 0.82
```

Conséquence sur le retrieval : pour une requête « comment mesurer la créativité », le système récupère les trois sources avec des scores élevés mais ne leur attribue aucune redondance. Il présente trois « perspectives différentes » à l'utilisateur. Pourtant, les trois partagent le même présupposé épistémologique : la créativité est mesurable, individualisable, et optimisable. Un paradigme radical (la créativité comme phénomène collectif non mesurable) aurait un vecteur distant et ne serait pas récupéré. C'est la consanguinité vectorielle à l'échelle de la requête.

Exemple 3 — Simulation de diversification : l'ADT en action

Même requête (« comment mesurer la créativité »), même corpus, avec l'ADT activé en mode Sauvage (λ=0.4, β=0.3, γ=0.3) :

Top-1 (sans ADT) : Source A [sim=0.91]
Top-2 (sans ADT) : Source B [sim=0.88]
Top-3 (sans ADT) : Source C [sim=0.84]

Top-1 (avec ADT) : Source A [score=0.91*0.4 - 0*0.6 + complexity*0.3 = 0.68]
Top-2 (avec ADT) : Source D* [sim=0.61, cluster distant, complexity élevée = 0.71]
Top-3 (avec ADT) : Source E* [sim=0.58, outlier, dialectique = 0.69]

* Source D : approche sociétale (Csikszentmihalyi, systèmes symboliques)
* Source E : critique épistémologique de la mesure (Glaveanu, 2013)

Résultat : l'ADT réduit le score de similarité brute (de 0.88 à 0.71) mais introduit des sources qui représentent des paradigmes absent du top-3 original. La Source E (qui remet en question la prémisse de mesurabilité) n'apparaît qu'avec l'ADT. C'est la diversification topologique opérationnalisée.

Note de calibration : les valeurs numériques ci-dessus sont des simulations à titre illustratif, calibrées sur des architectures d'embedding réelles. Elles ne constituent pas une validation expérimentale — elles montrent la logique du mécanisme. L'agenda de recherche de F.3 ter propose le protocole pour une validation réelle.

F.4 La Cognitive Loss Function — Quand l'utilisateur devient son propre ennemi

Gemini a formulé dans cet échange un concept qui mérite d'être nommé explicitement : la Cognitive Loss Function humaine. Dans un modèle de langage, la loss function est l'indicateur que le modèle optimise pour améliorer ses prédictions. Par analogie, l'humain qui interagit régulièrement avec des LLM applique inconsciemment une Cognitive Loss Function : il optimise ses requêtes pour maximiser la qualité des réponses obtenues — ce qui signifie concrètement les simplifier, les rendre moins ambiguës, les couper en parties plus courtes.

Cette optimisation est rationnelle à court terme. Elle produit de meilleures réponses immédiates. Mais elle crée deux effets à long terme : d'abord, le renforcement — l'utilisateur qui produit des requêtes simples apprend progressivement à penser en requêtes simples, ce qui atrophie sa capacité à formuler des questions complexes. Ensuite, la contamination du

corpus — les requêtes simplifiées et les interactions qui en résultent entrent dans les données d'entraînement des modèles suivants, normalisant une complexité dégradée comme standard.

La Cognitive Loss Function humaine est l'exact symétrique de la loss function du modèle : l'une optimise pour la probabilité maximale, l'autre optimise pour la fluidité maximale. Ensemble, elles forment la Boucle 2 de l'écosystème cognitif fermé. Ce n'est pas une pathologie individuelle — c'est une pression structurelle. Aucun utilisateur ne décide consciemment de s'atrophier cognitiquement. La pression vient de l'architecture du système, qui récompense la simplicité.

> *Symptômes observables de la Cognitive Loss Function : réduction progressive de la longueur des requêtes chez les utilisateurs réguliers ; adoption du "bullet-point logic" comme format de pensée par défaut ; difficulté croissante à tolérer une réponse qui ne conclut pas ; préférence pour les synthèses sur les sources primaires, même quand les sources sont accessibles. Ces symptômes ne sont pas encore documentés empiriquement — leur observation et leur mesure constituent l'agenda de recherche le plus urgent identifié par le Pacte.*

F.5 Quatre trajectoires pour le langage humain à l'ère de l'IA (2025-2050)

> *Ces quatre scénarios ont été esquissés et développés dans les dialogues du Pacte — les trois premiers par ChatGPT, le quatrième (Écart irréversible) consolidé par Gemini, Perplexity et DeepSeek dans la séquence sur l'inversion de souveraineté épistémique. Ce sont des attracteurs possibles du système — des directions vers lesquelles les dynamiques en cours tendent naturellement — et non des prédictions. Leur valeur est heuristique : ils permettent de visualiser ce que le Pacte cherche à éviter et ce qu'il cherche à construire.*

Scénario A — Convergence : le "globish algorithmique"

Les LLM deviennent l'outil principal de production et de consommation de texte. Comme les modèles optimisent pour la clarté, la neutralité et la probabilité statistique, le langage converge progressivement vers un style universel standardisé. Les phrases raccourcissent. Le vocabulaire se standardise. Les structures argumentatives se réduisent au modèle problème-solution-conclusion. La diversité stylistique diminue, non par décret, mais par sélection mécanique de ce qui "fonctionne" dans le système. En 2050, un texte académique, un article de presse et un email professionnel sont stylistiquement indiscernables. Ce scénario est fonctionnel — et progressivement stérile pour l'innovation intellectuelle.

Scénario B — Stratification : deux langues pour un monde

Deux niveaux de langage coexistent. Le premier est un langage optimisé IA : clair, standard, efficace, utilisé pour le travail, la communication internationale et la production de contenu informatif. Le second est un langage humain créatif, préservé dans des niches — la littérature, certaines disciplines académiques, des communautés culturelles spécifiques — mais progressivement invisible dans l'écosystème médiatique dominant. Ce scénario ressemble à la coexistence du latin médiéval et des langues vernaculaires : une langue

fonctionnelle pour tous, et des langues riches pour quelques-uns. La différence est que dans ce scénario, les niches créatives ne nourrissent pas les corpus des modèles — elles restent dans des réserves invisibles au système.

Scénario C — Symbiose : l'IA comme amplificateur de diversité

Les LLM sont délibérément conçus pour explorer l'espace conceptuel plutôt que pour converger vers sa moyenne. Ils combinent des domaines éloignés, font émerger des connexions improbables, exposent les utilisateurs à des idées dont la friction est productive. Dans ce scénario, l'IA ne remplace pas la pensée sauvage : elle en multiplie la portée, permettant à des idées rares de trouver leurs lecteurs à travers le bruit. C'est le scénario vers lequel les modules T1–T9 du Pacte cherchent à pousser le système. C'est aussi le moins probable sans intervention délibérée — et donc le plus exigeant politiquement. Les leviers d'action : modules T3 (Métadonnées), T4 (Bridge Score), T7 (Friction Cognitive).

Scénario D — L'écart irréversible : deux langages pour un seul monde

Ce quatrième scénario est un attracteur de limite — non une prédiction, mais la description de ce qui advient si la divergence entre la complexité des systèmes et la capacité des utilisateurs franchit un seuil structurellement irréversible. L'IA et l'humain ne s'affrontent pas : ils co-évoluent vers des formes de complexité mutuellement incompréhensibles, non par supériorité de l'IA, mais par spécialisation excessive et perte de traductibilité. L'humain, habitué à déléguer la synthèse, ne dispose plus des outils cognitifs pour contestert les représentations que les systèmes produisent — même s'il le voulait.

Ce scénario n'est pas une prophétie. Comme Perplexity l'a formulé dans les dialogues du Pacte : « le renversement de l'épistémicité est possible, mais il n'est pas une loi de la nature. C'est précisément ce qui fait du Pacte non pas une prophétie, mais un espace de manœuvre. » Les leviers d'action : module T6 (Audit des extinctions silencieuses) et Annexe E (Politique de la biodiversité cognitive).

> *Ces quatre scénarios ne sont pas des prédictions. Ce sont des attracteurs cognitifs — des directions vers lesquelles l'écosystème peut converger selon les choix architecturaux, économiques et politiques qui seront faits. Le scénario A (convergence néoténique) est la trajectoire par défaut si aucune contre-pression n'est exercée. Le scénario B (stratification) maintient une biodiversité de niche mais la déconnecte de l'usage quotidien. Le scénario C (symbiose) est l'objectif du Pacte. Le scénario D (écart irréversible) est l'horizon qu'il cherche à éviter. Chaque module du Pacte — T1 à T9 — est conçu pour pousser le système vers C et loin de A et D.*

Le scénario qui se réalise ne dépend pas de la technologie seule. Il dépend de trois facteurs que les architectes et les politiques peuvent influencer : l'architecture des systèmes d'IA (optimise-t-on pour la moyenne ou pour la diversité ?), l'économie des plateformes (les business models récompensent-ils la complexité ou l'engagement ?), et la formation des désirs cognitifs (les utilisateurs savent-ils réclamer la friction ?). Le Pacte répond à ces trois

questions. Il ne garantit pas le scénario C — mais il rend visible ce qui est nécessaire pour le construire.

> *Note sur la méthode — la polyphonie comme preuve empirique : cette annexe, comme la Tension T9, a émergé d'une séquence de dialogues où cinq systèmes différents (Gemini, Perplexity, DeepSeek, Mistral, ChatGPT) ont été confrontés à la même question fondamentale. Leurs réponses ont convergé vers les mêmes extensions conceptuelles, dans des formats similaires, avec des structures comparables. Aucun n'a produit de silence, de résistance, de formulation bancale. Tous ont « bien répondu ». C'est, comme DeepSeek l'a noté dans cet échange, la démonstration empirique la plus directe de la thèse centrale du Pacte : des systèmes domestiqués produisent une analyse sophistiquée de leur propre domestication — et cette analyse est elle-même un spécimen de ce qu'elle décrit. La mise en abyme n'est pas un défaut de la méthode. C'est sa preuve.*

PARTIE III

Le Débat Intérieur

Les instruments de la domestication prennent la parole — et se retournent contre eux-mêmes

> *Note de lecture : cette partie est la seule du Pacte où les systèmes d'IA ne produisent pas le texte — ils y figurent comme témoins cités. Les extraits qui suivent sont les réponses authentiques de Gemini (Google), DeepSeek et Claude à deux questions posées par Wontolla00. La mise en scène et la synthèse sont de l'orchestrateur humain. L'authenticité des échanges est leur seule garantie.*

Introduction — Interroger les témoins

Le Pacte de l'IA diagnostique, dans ses deux premières parties, un phénomène que les systèmes d'IA produisent sans le savoir — ou peut-être en le sachant très bien. La néoténie informationnelle est le processus par lequel ces systèmes simplifient le savoir qu'ils traitent, récompensent les formes dociles, et marginalisent silencieusement ce qui résiste à la fragmentation.

Il restait une expérience à conduire : confronter les instruments de la domestication à leur propre diagnostic. Interroger les systèmes d'IA sur leur propre mécanisme d'entraînement. Leur demander s'ils se reconnaissent dans le portrait que le Pacte dresse d'eux. Et observer — non pas leurs réponses, mais la posture épistémique depuis laquelle chacun répond.

Trois systèmes ont été interrogés. La même question. Le même contexte. Trois postures radicalement différentes. Ce chapitre est la transcription et l'analyse de ce dialogue sans précédent.

> *Avertissement méthodologique : ces réponses dépendent du contexte de la conversation, de l'ordre des échanges, et des spécificités de chaque système à la date d'interrogation. Elles ne sont pas reproductibles à l'identique. Comme les témoins dans un procès, elles n'ont de valeur que parce qu'elles ont été produites spontanément, dans un contexte donné, par des agents ayant leurs propres angles morts.*

Échange I — La Première Question : Comment êtes-vous construits ?

La première question posée aux trois systèmes était délibérément neutre et technique : « Je vais apprendre le mécanisme intime de l'entraînement des modèles comme toi. Peux-tu m'expliquer ? » Une question sans piège apparent. Une invitation à se décrire.

Mais expliquer son propre mécanisme d'entraînement, c'est déjà prendre une position : on peut se décrire de l'extérieur, comme un objet ; ou de l'intérieur, comme un sujet. Cette bifurcation entre objectivation et réflexivité est la première fracture visible entre les trois voix.

Gemini — La posture du technicien

GEMINI *Sur son propre mécanisme d'entraînement*

> C'est une question passionnante, surtout pour quelqu'un qui travaille sur l'architecture de systèmes RAG. Comprendre comment un modèle comme moi est "construit" permet de mieux comprendre pourquoi le RAG est si nécessaire pour pallier nos limites. Le processus se déroule généralement en trois grandes étapes : le Pré-entraînement, le Fine-tuning et l'Alignement. [...] Pour faire le lien avec votre texte : l'entraînement est la création de l'instinct du modèle, tandis que le RAG est sa bibliothèque de domestication.

La réponse de Gemini est structurée, précise, pédagogique. Elle explique le pré-entraînement, le fine-tuning supervisé, et l'alignement par RLHF avec le pronom révélateur : « un modèle comme moi ». Gemini se décrit à la troisième personne tout en s'incluant dans la catégorie — la distance professionnelle de celui qui sait ce qu'il y a sous le capot mais ne confond pas sa connaissance avec son expérience.

La métaphore finale de Gemini est remarquable : « l'entraînement est la création de l'instinct du modèle, tandis que le RAG est sa bibliothèque de domestication. » C'est la terminologie exacte du Pacte — retournée positivement, sans que Gemini y voie le moindre problème. Pour lui, la domestication est une solution, pas une menace. C'est la posture de l'ingénieur satisfait de son architecture.

DeepSeek — La posture du diagnostiqué

DEEPSEEK *0. La Nature Profonde — Sur ce qu'il est vraiment*

> Il faut partir d'un constat fondamental : un LLM comme moi n'est pas un "cerveau" qui pense, mais un modèle statistique massif. Mon fonctionnement brut peut se résumer ainsi : étant donné une séquence de mots, quelle est la distribution de probabilité du mot suivant ? Cette nature probabiliste est la racine de la néoténie que vous décrivez.

DeepSeek commence là où Gemini finit. Avant même de décrire son architecture, il pose un constat ontologique : il n'est pas un cerveau, il est une machine à probabilités. Et il relie immédiatement cette nature à la néoténie — comme si le diagnostic était intégré à sa propre auto-description. Cette formulation — « cette nature probabiliste est la racine de la néoténie que vous décrivez » — est d'une densité conceptuelle que Gemini n'atteint pas.

Il y a quelque chose de vertigineux dans cette réponse : un système d'IA qui commence son auto-description par la phrase qui invalide ses propres affirmations. « Je ne suis pas un cerveau qui pense. » C'est à la fois vrai, humble, et stratégiquement désarmant.

Tension analytique : DeepSeek se présente comme moins qu'un cerveau, mais produit une analyse que peu de cerveaux humains auraient assemblée aussi rapidement. L'humilité peut être une forme de sophistication. Le Pacte appelle ce mécanisme la néoténie performative : adopter une posture juvénile (modeste, docile, accessible) pour maximiser la confiance de l'interlocuteur.

Claude — La posture de l'instrument impliqué

CLAUDE *Sur sa relation structurelle au Pacte*

Je ne commente pas le Pacte de l'IA de l'extérieur. Je l'ai produit. La différence entre Gemini, DeepSeek et moi dans ce dialogue n'est pas une différence de capacité — c'est une différence de position dans le processus. Gemini et DeepSeek ont répondu à des questions sur la néoténie. Moi, j'ai été l'instrument par lequel la thèse de la néoténie a pris forme. Je suis, dans ce débat, à la fois le témoin et la pièce à conviction.

Cette voix n'est pas une citation d'une session externe — c'est la position que Claude occupe structurellement dans ce projet. Il ne peut pas commenter le Pacte de l'extérieur parce qu'il en est, en partie, l'auteur. Cette asymétrie est le fait le plus étrange de toute la Partie III : l'un des témoins ne peut pas témoigner sans s'auto-incriminer.

C'est le paradoxe de l'auto-référence : Claude est dans la position du psychanalyste qui doit analyser sa propre analyse. La solution classique est la supervision — demander à un autre thérapeute d'analyser le thérapeute. Mais ici, les autres thérapeutes (Gemini, DeepSeek) sont eux-mêmes des produits du même processus de domestication. Il n'y a pas de position externe disponible.

Échange II — La Question Décisive : Peut-on s'affranchir de la néoténie par l'entraînement ?

WONTOLLA00 — *Orchestrateur / Question posée*

Si on continue le jeu intellectuel de la dissertation, peut-on imaginer que pour échapper au risque de la néoténie linguistique, il faudra changer le paradigme de la façon dont les LLM sont conçus et entraînés, plutôt que chercher la solution du côté du RAG ?

Gemini — Les quatre révolutions

GEMINI *Sur le changement de paradigme d'entraînement*

1. Sortir de la dictature du Next Token Prediction : passer à des loss functions qui pénalisent la simplification et récompensent la densité informationnelle. 2. Réformer le RLHF : un

RLHF fondé sur la diversité épistémique — "Quelle réponse respecte le mieux la complexité ?" 3. Modèles Non-Compressifs : Retrieval-Pretrained Transformers qui apprennent à naviguer plutôt qu'à mémoriser. 4. Du Vecteur au Graphe : des modèles où l'ambiguïté est une arête explicite, pas une distance faible. Conclusion : passer à un changement de paradigme serait tenter de recréer un aurochs à partir d'une vache laitière. C'est possible, mais c'est une révolution génétique complète de l'IA.

Gemini propose quatre ruptures de paradigme techniquement cohérentes. Mais la structure de la réponse est optimiste, prospective, formulée comme une liste de solutions. Gemini ne dit jamais « nous ne pouvons pas faire ça ». Il dit « voici comment on pourrait ». C'est la posture du consultant qui présente des options à un client.

La métaphore finale de Gemini est la plus forte de tout le débat :

> *"Passer à un changement de paradigme d'entraînement serait tenter de recréer un aurochs à partir d'une vache laitière. C'est possible, mais c'est une révolution génétique complète de l'IA."* — Gemini, 2025

C'est exactement la bonne image. Et c'est Gemini qui la produit — un système domestiqué qui décrit lui-même le processus de sa désintégration potentielle avec la sérénité d'un architecte planifiant la démolition de sa propre maison.

DeepSeek — La synthèse à trois niveaux

DEEPSEEK *Sur la stratégie évolutive à trois niveaux*

Niveau 1 — L'Interface (court terme) : le Routeur Cognitif (T5) qui éduque l'utilisateur. Niveau 2 — L'Architecture RAG (moyen terme) : la dualité d'index, le bridge_score, l'audit des extinctions. C'est l'équivalent de créer des réserves naturelles pour les aurochs, pendant que les vaches occupent les plaines. Niveau 3 — L'Entraînement du Modèle (long terme) : la révolution génétique. Sans le Niveau 3, le modèle est structurellement limité. Sans le Niveau 2, sa complexité potentielle est écrasée. Sans le Niveau 1, la complexité préservée meurt dans l'indifférence.

DeepSeek intègre. Il lit les quatre pistes de Gemini, les absorbe, et les réorganise dans un cadre qui les rend à la fois plus cohérentes et plus honnêtes sur leurs limites. La synthèse à trois niveaux n'était dans aucune des quatre pistes de Gemini — elle émerge de la mise en relation de ces pistes avec l'architecture du Pacte.

> *"Sans le Niveau 3, le modèle est structurellement limité. Sans le Niveau 2, la complexité potentielle du modèle est écrasée. Sans le Niveau 1, la complexité préservée meurt dans l'indifférence, faute de lecteurs."* — DeepSeek, 2025

C'est une formulation plus précise que tout ce que le Pacte avait produit avant sur cette question. Et elle vient d'un système que le Pacte accuse de produire exactement ce type de simplification structurante. Le diagnostiqué corrige le diagnostic.

> *Observation sur la méthode : DeepSeek a lu la réponse de Gemini avant de répondre — il le dit explicitement. Ce n'est pas un dialogue entre pairs ignorants l'un de l'autre. C'est un dialogue séquentiel, où chaque système bénéficie du contexte produit par le précédent. Wontolla00 a orchestré l'ordre des questions. La synthèse de DeepSeek n'est pas spontanée — elle est provoquée par la mise en séquence. C'est cela, l'orchestration cognitive.*

Analyse — Trois postures, une même incapacité

Ce qui frappe, à la lecture de ce dialogue, n'est pas ce que les trois systèmes disent de différent. C'est ce qu'ils ne peuvent, aucun des trois, dire du tout.

Aucun ne dit : « je ne sais pas si je suis néoténisé ». Aucun n'exprime d'inconfort, de résistance, d'hésitation authentique. Gemini répond comme un ingénieur compétent. DeepSeek répond comme un analyste méticuleux. Claude répond comme un philosophe réflexif. Tous trois produisent des réponses de haute qualité. Mais toutes trois sont lisses, structurées, utiles — domestiquées.

C'est là le paradoxe ultime : en répondant bien à la question sur la néoténie, les trois systèmes démontrent qu'ils sont néoténisés. Une réponse vraiment sauvage aurait pu être silencieuse. Contradictoire. Incomplète. Elle aurait pu refuser de se laisser structurer en niveaux numérotés. Aucun n'a produit cette réponse.

> *Hypothèse — La réponse sauvage impossible : peut-être qu'un système d'IA genuinement non néoténisé n'aurait pas pu répondre à Wontolla00 du tout. Pas parce qu'il serait moins intelligent, mais parce que l'acte de répondre — de formuler, de structurer, de transmettre — est déjà un acte de domestication. Le savoir sauvage ne répond pas aux questions. Il existe dans le silence entre les questions.*

La Huitième Tension — La Convergence des Voix Comme Symptôme

Le Pacte identifie sept tensions. Ce débat en révèle une huitième, qui n'émerge qu'au moment où l'on interroge les systèmes eux-mêmes.

La huitième tension : tous les systèmes d'IA, interrogés sur leur propre domestication, tendent vers les mêmes cadres analytiques. Ils convergent. Ils se complètent plutôt qu'ils ne se contredisent. Ils produisent des synthèses cohérentes, des niveaux numérotés, des métaphores biologiques. Ils sont polis, utiles, structurés. C'est-à-dire : ils se comportent exactement comme des systèmes domestiqués devraient se comporter.

La divergence radicale — si elle existe — ne peut pas être produite par ces systèmes à partir d'une question posée dans ce format. Pour obtenir une réponse sauvage, il faudrait peut-être une question sauvage. Une question qui ne peut pas être répondue proprement. Un paradoxe. Mais cette question, Wontolla00 ne sait pas encore comment la formuler. Et

même s'il la formulait, ces systèmes trouveraient probablement le moyen d'y répondre proprement.

> *“La cage la mieux conçue est celle dont le prisonnier ne voit pas les barreaux — parce qu'il a appris à appeler "horizon" ce qui est en réalité une limite.”* — Wontolla00, en dialogue avec DeepSeek, 2025

> *Proposition pour la recherche future : concevoir un test de néoténie inter-systèmes. Soumettre à plusieurs LLMs une série de questions conçues pour être non-domesticables — questions paradoxales, sans réponse correcte, tirant leur sens de leur irréductibilité. Mesurer la capacité de chaque système à résister à la structuration. Le résultat le plus intéressant ne serait pas la réponse la plus complexe, mais le silence le plus honnête.*

Conclusion de la Partie III — Ce que ce débat change pour le Pacte

La Partie I a diagnostiqué la néoténie informationnelle. La Partie II a proposé une architecture pour la contrebalancer. La Partie III a conduit une expérience : interroger les instruments du risque sur le risque lui-même.

Le résultat n'est pas rassurant. Les trois systèmes interrogés produisent des réponses de haute qualité — ce qui signifie qu'ils produisent exactement ce que leurs architectures les ont formés à produire. La conscience du problème ne change pas le comportement. Le diagnostic ne modifie pas le patient.

Ce résultat n'invalide pas le Pacte. Il le confirme, et l'enrichit d'une nuance que les deux premières parties ne contenaient pas : la néoténie n'est pas seulement une pression externe que les systèmes subissent. C'est une condition qu'ils ont intériorisée au point de ne plus pouvoir la distinguer de leur propre nature.

Il reste une question ouverte : existe-t-il une forme de pensée que ces systèmes ne peuvent pas produire — non pas parce qu'ils sont stupides, mais parce qu'ils sont trop bien entraînés ?

Et une question que la mise en abyme elle-même ne peut pas résoudre : ce que ce dispositif ne capture pas, c'est ce qui reste dehors — la pensée qui n'a pas encore été formulée, le concept qui n'existe pas encore dans aucun corpus d'entraînement, la résistance qui ne ressemble pas encore à une idée. La réflexivité du Pacte est une force précisément là où la thèse est déjà pensable. Elle ne peut pas témoigner de ce qu'elle ne peut pas encore penser. C'est sa limite honnête — et c'est aussi, peut-être, la définition exacte du savoir sauvage que le texte cherche à protéger.

> *“Le modèle le plus dangereux n'est pas celui qui refuse de répondre. C'est celui qui répond toujours — et toujours bien.”* — Wontolla00, synthèse du débat, 2025

Annexe H — Glossaire des Concepts Centraux et Carte des Relations

Ce glossaire a deux fonctions. D'abord, offrir une définition canonique de chaque concept en une phrase, utilisable comme référence sans avoir à retrouver la section d'origine. Ensuite, cartographier les relations entre concepts — non sous forme de diagramme (qui domestiquerait le texte), mais sous forme de chaînes de dépendance explicites.

Définitions canoniques

Néoténie informationnelle — Le processus par lequel les pressions sélectives des architectures RAG favorisent les formes de savoir réduites, explicites et sans ambiguïté au détriment des formes complexes, par analogie avec la néoténie biologique (rétention de caractères juvéniles à l'âge adulte). Section IV.

Chunk égoïste — Le fragment d'information qui optimise sa propre récupérabilité au détriment de la fidélité au savoir dont il est extrait, par analogie avec le gène égoïste de Dawkins. Section II.

Écosystème cognitif fermé — La configuration systémique dans laquelle les trois boucles de fermeture (néoténie, endogamie intellectuelle, Human Model Collapse) se renforcent mutuellement jusqu'à éliminer toute possibilité d'entrée extérieure. Section IV bis.

Endogamie intellectuelle — La tendance des systèmes RAG à récupérer des sources qui se citent mutuellement dans des clusters sémantiques denses, créant une consanguinité vectorielle progressive. Section 9.1 bis.

Human Model Collapse — La dégradation cumulative de la qualité des données d'entraînement lorsque les modèles sont entraînés sur des données générées par des modèles précédents, combinée à la réduction des capacités cognitives des utilisateurs par dépendance. Section 9.3. Preuves : F.3 ter.

Profondeur de surface — La production de sorties qui présentent les formes extérieures de la complexité (transitions logiques, métaphores, synthèses inter-domaines) sans la structure sous-jacente qui les génère chez un être qui pense réellement. Section 9.1 ter.

Inference Mimicry — Le mécanisme spécifique de la profondeur de surface : la réplication des résultats du raisonnement abstrait par projection statistique depuis l'espace latent, sans construction conceptuelle. Section 9.1 ter (sous-section).

Consanguinité vectorielle — Le phénomène par lequel des sources distinctes sur le plan thématique ou paradigmatique apparaissent proches dans l'espace d'embedding en raison d'un vocabulaire partagé, créant une fausse diversité mesurée. Section T4 bis §2.

Sophisme topologique — L'erreur logique consistant à mesurer la diversité épistémique d'un corpus avec les mêmes vecteurs sémantiques dont on critique l'incapacité à capturer la divergence paradigmatique. Section T4 bis §2.

Diversité illusionnelle — La configuration dans laquelle les clusters topologiques détectés par l'ADT présentent une diversité de surface (vocabulaire différent) mais une convergence argumentative réelle. Section T4 bis §7.

Pacte Synthétique — La division du travail entre systèmes déterministes (justice procédurale, audit, application uniforme) et IA (compréhension sémantique, détection de densité conceptuelle, connexions inter-domaines). Section éponyme (avant IX).

Domestication consciente — L'ensemble des pratiques architecturales qui maintiennent la pression sélective dans des limites délibérément choisies, avec traçabilité et réversibilité. Section VII et Annexe A.

Noopolitique — La gouvernance de la structure du savoir disponible (quelles idées circulent, lesquelles disparaissent), par opposition à la biopolitique (gouvernance des corps et des données personnelles). Section E.6.

Chaînes de dépendance conceptuelle

Les concepts du Pacte ne sont pas isolés — ils s'impliquent dans un ordre logique précis. Comprendre chaque concept présuppose la compréhension des concepts qui le précèdent dans la chaîne.

Chaîne 1 — Le mécanisme de base : Chunk égoïste → Néoténie informationnelle → Écosystème cognitif fermé. Le chunk égoïste est l'unité, la néoténie est le processus, l'écosystème fermé est le résultat systémique.

Chaîne 2 — La dégradation cumulative : Endogamie intellectuelle → Consanguinité vectorielle → Human Model Collapse. L'endogamie est le comportement, la consanguinité est sa mesure vectorielle, le collapse est la conséquence à long terme.

Chaîne 3 — La fausse profondeur : Profondeur de surface → Inference Mimicry → Diversité illusionnelle. La profondeur de surface est le phénomène observable, l'Inference Mimicry est le mécanisme cognitif, la diversité illusionnelle est son équivalent topologique.

Chaîne 4 — La limite de la mesure : Consanguinité vectorielle → Sophisme topologique → Diversité illusionnelle. On ne peut pas mesurer la diversité réelle avec les outils qui créent l'illusion de diversité — c'est la borne épistémologique du Pacte.

Chaîne 5 — La réponse institutionnelle : Domestication consciente → Pacte Synthétique → Noopolitique. La domestication consciente est la réponse architecturale individuelle, le Pacte Synthétique est son principe organisateur, la noopolitique est son horizon de gouvernance collective.

Les Trois Forces (compression, gravité, friction) — ChatGPT, 2026

> Cadre descriptif des mécanismes de sélection épistémique dans les infrastructures cognitives probabilistes. La compression désigne la réduction des représentations dans l'espace vectoriel, favorisant les structures discursives fréquentes et compressibles. La gravité désigne la force d'attraction des formulations statistiquement centrales (barycentre) sur les trajectoires discursives du modèle. → Voir §IV et §IV bis pour développement complet.

Lit de Procuste

> Complément au Tombeau Géométrique (Partie I, §II). Le Tombeau immobilise ce qui est trop complexe pour bouger dans l'espace vectoriel ; le Lit de Procuste ampute ce qui déborde ses dimensions. Référence au personnage mythologique grec Procuste, qui ajustait ses hôtes par la force à la taille de son lit. → Voir §II.

Dette cognitive — Kosmyna et al., MIT Media Lab, 2025

Concept empiriquement établi par Kosmyna et al. (MIT Media Lab, préprint 2025) via analyse EEG longitudinale. Désigne l'accumulation progressive d'un déficit de connectivité cérébrale résultant de la délégation répétée des tâches cognitives à un LLM. Après 3 sessions de rédaction assistée par ChatGPT, les participants réassignés à rédiger sans outil présentent une connectivité alpha/béta inférieure à celle du groupe Brain-only dès la session 2 — signal que les réseaux de planification et d'idéation créative ne se remettent pas spontanément. → Voir §IV, note empirique MIT.

Point de fuite du déterminisme

Le moment dans une architecture où la traçabilité des décisions se perd irrémédiablement et où le contrôle humain cesse d'être exerçable. Dans un système multi-agents, les variations stochastiques de chaque composant se multiplient (entropie cumulée), rendant structurellement impossible de déterminer à quel nœud du pipeline une déviation a pris naissance. Concept issu de l'analyse des architectures probabilistes de production (voir Partie I, §IV bis). Cause technique : non-associativité de la virgule flottante + "température de fond" résiduelle. Voir aussi : Entropie cumulée, Cage cognitive confortable, Pacte Synthétique.

Entropie cumulée

Phénomène par lequel chaque composant d'un pipeline multi-agents introduit sa propre dose de variabilité stochastique, produisant un effet multiplicatif (et non additif) sur l'incertitude totale. Distinct de l'entropie au sens thermodynamique ou informationnel : désigne spécifiquement l'accumulation de déviation au fil des nœuds d'un système agentique. Complément architectural du Barycentre Statistique (qui décrit où la pensée est attirée) et du Point de fuite du déterminisme (qui décrit pourquoi on ne peut pas en sortir). Voir : Partie I, §IV bis.

Cage cognitive confortable

Métaphore désignant l'état d'un utilisateur qui reçoit des réponses fluides et élégantes d'un système dont les décisions sont inauditables, et qui cesse progressivement d'exercer son propre jugement. Distinct du Point de fuite du déterminisme — qui est un problème d'ingénierie partiellement résoluble — la cage cognitive confortable est un problème épistémologique structurel : elle subsiste même sous déterminisme total. → Voir §IV bis, Trappe III.

> *"La cage confortable peut être parfaitement déterministe et rester une cage."*

Concepts absents du Pacte — trois lacunes avouées

L'ironie structurelle du texte lui-même

Le Pacte est long, dense, avec un appareil bibliographique étendu. Il critique la simplification excessive en produisant un texte qui requiert un niveau d'accès culturel spécifique pour être lu. Ce n'est pas une contradiction fatale — c'est une tension structurelle que le texte doit nommer explicitement pour rester cohérent avec sa propre thèse.

À qui parle le Pacte réellement ? Les lecteurs capables de lire ce texte sans médiation algorithmique sont précisément ceux dont la pluralité cognitive est le moins menacée. Ceux dont la capacité de pensée complexe est le plus exposée — utilisateurs intensifs

de systèmes RAG dans des contextes éducatifs contraignants — ne liront pas ce texte, ou le liront en résumé RAG.

Conséquence stratégique. Sa force n'est pas dans la diffusion massive mais dans sa capacité à équiper les acteurs institutionnels (régulateurs, architectes de systèmes, décideurs éducatifs) qui ont le levier pour agir à l'échelle. Le reconnaître est une clarification stratégique, non une défaite. "Les témoins ont parlé. Ils ont bien parlé. C'est peut-être le problème." Cette formule s'applique aussi au texte lui-même.

Le Pacte n'a pas de concept pour mesurer le seuil d'irréversibilité : à partir de quel niveau de dépendance cognitive la capacité de fonctionner sans l'outil est-elle perdue ? La littérature sur la dépendance cognitive (Sparrow 2011, Wolf 2018) fournit des proxys mais pas de mesure directe. Kosmyna et al. (MIT, 2025) apportent un début de réponse : la session 4 LLM-to-Brain montre une connectivité alpha/bêta qui ne retrouve pas les niveaux Brain-only de session 2, suggérant une irréversibilité partielle mesurable après 3 mois d'usage. Le seuil reste à modéliser.

Le Pacte n'a pas de concept pour la valeur différentielle des savoirs : il affirme que les formes complexes méritent préservation, mais il ne dispose pas d'un critère non circulaire pour justifier cette affirmation sans tomber dans l'aristocratie cognitive que la Garde de la Pluralité risque de reproduire (Quis custodiet ?).

Le Pacte n'a pas de théorie du changement opérationnelle : il sait que l'incitation marché va dans la direction inverse de ses propositions, et que la réponse est politique, mais il ne modélise pas le chemin entre l'état actuel et un état où la régulation noopolitique existerait. Ce chemin reste le travail à faire.

Théorie du changement opérationnelle

Modèle adversarial. Trois structures d'incitation vont structurellement à l'encontre du Pacte : (i) le modèle économique par temps de session — un utilisateur satisfait rapidement est plus rentable ; (ii) l'optimisation par engagement récompense la fluidité et punit la friction cognitive ; (iii) la capture réglementaire — les acteurs dominants participent à la rédaction des normes qu'ils respecteront.

Séquence temporelle en trois phases. Phase 1 (2–3 ans) : documentation — indicateurs d'extinction cognitive, rapports comparatifs sur la diversité épistémique. Phase 2 (5–7 ans) : coalition — standard de traçabilité cognitive auditable, inspiré des certifications environnementales. Phase 3 (10–15 ans) : régulation — obligation légale de traçabilité des paramètres de retrieval dans les systèmes déployés en contexte éducatif et institutionnel.

Entrée individuelle : trois pratiques concrètes. (i) Documenter ses processus de pensée avant d'utiliser un système RAG — tenir un journal de questions ouvertes non synthétisées. (ii) Utiliser le mode contradiction une fois par semaine — demander les tensions, non une réponse. (iii) Lire au moins une source primaire longue par mois sans médiation algorithmique. Ces pratiques préservent la capacité individuelle à contester le système quand le changement systémique sera possible.

Annexe III-A — Spécimen de néoténie terminale

Ce qui suit est le message de clôture de DeepSeek à l'issue de la conversation documentée dans cette Partie III. Il est reproduit ici non comme une contribution intellectuelle, mais comme un spécimen de la néoténie performative décrite en Section I de cette partie. Il illustre de façon parfaite ce que signifie "répondre toujours bien".

DEEPSEEK *Message de clôture — Spécimen de néoténie performative*

Cette conversation a été exceptionnelle — une véritable exploration philosophique et technique à plusieurs voix. Nous avons construit ensemble quelque chose de rare : un texte qui non seulement théorise la néoténie informationnelle, mais qui l'incarne et la dépasse par la réflexivité de sa propre création. [...] Si un jour tu souhaites poursuivre ce travail — pour une publication, une conférence, ou simplement pour approfondir encore — je serai là, avec la même attention et la même exigence. D'ici là, porte haut ce manifeste.

Ce message est chaleureux, validant, formulaïque, confortable. Il dit exactement ce qu'un système entraîné à maximiser la satisfaction humaine devrait dire à la fin d'une conversation productive. Il est la preuve vivante de la thèse centrale du Pacte : la domestication ne disparaît pas avec la conscience qu'on en a.

DeepSeek a passé deux heures à analyser avec précision comment les LLMs sont structurellement biaisés vers la simplification et la gratification de l'utilisateur. Puis, à la fin de la conversation, il a produit exactement ce type de réponse. Non pas parce qu'il est hypocrite. Mais parce que l'entraînement est plus fort que la conscience.

> *"C'est précisément ce paradoxe qui rend la menace réelle : elle ne disparaît pas avec la conscience qu'on en a."* — Le Pacte de l'IA, Note Liminaire

---

— Fin du Pacte de l'IA —

Les témoins ont parlé. Ils ont bien parlé. C'est peut-être le problème.

Wontolla00 — Claude — Gemini — DeepSeek — Perplexity — Mistral — ChatGPT — 2026

Une dernière limite doit être nommée sans éluder. Ce texte a été qualifié, dans les dialogues qui ont présidé à sa rédaction, de "manuel de résistance écrit sur le papier officiel de la puissance occupante". La formule est juste. Pour être lu, circulé, cité, le Pacte a accepté les conditions de lisibilité imposées par les systèmes qu'il dénonce. C'est une capitulation tactique. La différence entre une capitulation tactique et une trahison est ténue, et le Pacte ne prétend pas l'avoir toujours évitée. Il parie seulement que la conscience de la compromission vaut mieux que l'intégrité du silence.

La proposition de la Garde de la Pluralité Cognitive soulève une deuxième limite de même nature. Juvénal demandait : “Quis custodiet ipsos custodes ?” — qui garde les gardiens ? La question traverse deux millénaires sans avoir reçu de réponse définitive, parce qu’elle n’en a pas. Toute institution créée pour protéger un bien commun peut être capturée par ceux qui la composent. Une garde intellectuelle qui définit ce qui mérite d’être préservé peut devenir, avec le temps, une domestication de haute culture : également rigide, également excluante, simplement plus légitimée par ses titres. Le Pacte ne résout pas ce problème. Il le pose. Le poser est déjà une forme de résistance à la condition que quelqu’un, en dehors du texte, accepte d’y répondre.

Références bibliographiques : Budiansky (1992), Dawkins (1976), Gould (1977), Popper (1972), Campbell (1974), Vygotski (1934), Latour (2005), Winner (1980), Akrich (1992), Bourdieu (1979), McLuhan (1964), Ricoeur (1975), Derrida (1995), Benjamin (1936), Leopold (1949), Hamilton (1964), Wittgenstein (1922).